BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MT

TRƯỜNG ĐẠI HỌC THỦY LỢI



TỐNG THU PHƯƠNG

ỨNG DỤNG MÔ HÌNH HỌC SÂU CNN DENSENET121 TRONG PHÁT HIỆN DẤU HIỆU UNG THƯ PHỔI TỪ ẢNH X-QUANG LỒNG NGỰC

ĐỒ ÁN TỐT NGHIỆP

NGÀNH HỆ THỐNG THÔNG TIN

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO **BỘ NÔNG NGHIỆP VÀ MT**
TRƯỜNG ĐẠI HỌC THỦY LỢI

TỐNG THU PHƯƠNG

ỨNG DỤNG MÔ HÌNH HỌC SÂU CNN DENSENET121 TRONG PHÁT HIỆN DẤU HIỆU UNG THƯ PHỔI TỪ ẢNH X-QUANG LỒNG NGỰC

Ngành : Hệ Thống Thông Tin
Mã số: 7480104

GIÁO VIÊN HƯỚNG DẪN: TS. LÊ THỊ TÚ KIÊN

HÀ NỘI, NĂM 2026

CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập - Tự do - Hạnh phúc

-------□-------

NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ tên sinh viên: Tống Thu Phương **Hệ đào tạo:** Chính quy

Lớp: 63HTTT2 **Ngành:** Hệ thống thông tin

Khoa: Công nghệ thông tin

1. **TÊN ĐỀ TÀI:** ỨNG DỤNG MÔ HÌNH HỌC SÂU CNN DENSENET121 TRONG PHÁT HIỆN DẤU HIỆU UNG THƯ PHỔI TỪ ẢNH X-QUANG LỒNG NGỰC

2. NỘI DUNG CÁC PHẦN THUYẾT MINH VÀ TÍNH TOÁN: Tỷ lệ %

Nội dung các phần	Tỷ lệ %
Chương 1: Tổng quan đề tài	10%
Chương 2: Cơ sở lý thuyết	20%
Chương 3: Xây dựng mô hình	40%
Chương 4: Thực nghiệm và đánh giá	30%

3. GIÁO VIÊN HƯỚNG DẪN TỪNG PHẦN

Phần	Họ và tên giáo viên hướng dẫn
Chương 1: Tổng quan đề tài	TS. Lê Thị Tú Kiên
Chương 2: Cơ sở lý thuyết	TS. Lê Thị Tú Kiên
Chương 3: Xây dựng mô hình	TS. Lê Thị Tú Kiên
Chương 4: Thực nghiệm và đánh giá	TS. Lê Thị Tú Kiên

4. NGÀY GIAO NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Ngày .....tháng….. năm 2025

Trưởng Bộ môn

(Ký và ghi rõ Họ tên)

Giáo viên hướng dẫn chính

(Ký và ghi rõ Họ tên)

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua.

Ngày..... tháng năm 2025

Chủ tịch Hội đồng

(Ký và ghi rõ Họ tên)

Sinh viên đã hoàn thành và nộp bản Đồ án tốt nghiệp cho Hội đồng thi ngày.... tháng.....năm 2025

Sinh viên làm Đồ án tốt nghiệp

(Ký và ghi rõ Họ tên)

TRƯỜNG ĐẠI HỌC THUỶ LỢI
KHOA CÔNG NGHỆ THÔNG TIN

BẢN TÓM TẮT ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

Tên đề tài: ỨNG DỤNG MÔ HÌNH HỌC SÂU CNN DENSENET121 TRONG PHÁT HIỆN DẤU HIỆU UNG THƯ PHỔI TỪ ẢNH X-QUANG LỒNG NGỰC

Sinh viên thực hiện: Tống Thu Phương
Lớp: 63HTTT2
Mã sinh viên: 2151163715
Số điện thoại: 0393531006
Email: 2151163715@e.tlu.edu.vn
Giáo viên hướng dẫn: TS. Lê Thị Tú Kiên
*Email:*kienltt@tlu.edu.vn

TÓM TẮT ĐỀ TÀI

Ung thư phổi (UTP) là bệnh lý ác tính xuất phát từ biểu mô niêm mạc phế quản, phế nang, từ các tuyến của phế quản hoặc từ các thành phần khác của phổi. Đây là loại ung thư chiếm vị trí hàng đầu về tỷ lệ mắc cũng như tỷ lệ tử vong trên toàn thế giới. Đồ án tập trung vào việc xây dựng mô hình học sâu phát hiện dấu hiệu ung thư phổi dựa trên ảnh X-quang ngực. Bên cạnh đó, sinh viên tập trung phát triển một ứng dụng thử nghiệm có giao diện thân thiện, cho phép người dùng tải lên ảnh chụp X-quang lồng ngực và nhận kết quả dự đoán ngay lập tức, hướng đến tính ứng dụng thực tiễn trong chăm sóc sức khỏe.

CÁC MỤC TIÊU CHÍNH

- Nghiên cứu lý thuyết, tổng quan về ung thư phổi, các phương pháp học sâu trong phân tích ảnh y tế. Trong đó, mạng nơ-ron tích chập (CNN), đặc biệt là kiến trúc DenseNet121, được phân tích chi tiết và lựa chọn để xây dựng mô hình phân lớp ảnh có dấu hiệu ung thư phổi.
- Tiền xử lý và phân tích dữ liệu NIH Chest X-ray.

- Xây dựng mô hình học sâu phát hiện dấu hiệu ung thư phổi dựa trên ảnh X-quang ngực.
- Xây dựng Demo ứng dụng.

NỘI DUNG CHÍNH

- Thu thập và tiền xử lý dữ liệu
- Cài đặt, huấn luyện và đánh giá mô hình phân lớp ảnh dựa trên DenseNet121
- Xây dựng giao diện thử nghiệm
- Báo cáo và tổng kết: Viết báo cáo, đánh giá kết quả đạt được và đề xuất hướng phát triển tiếp theo.

KẾT QUẢ DỰ KIẾN

- Báo cáo đồ án
- Chương trình demo thử nghiệm phát hiện dấu hiệu ung thư phổi dựa trên ảnh X-quang ngực

LỜI CAM ĐOAN

Tác giả xin cam đoan đây là Đồ án tốt nghiệp của bản thân tác giả. Các kết quả trong Đồ án tốt nghiệp này là trung thực, và không sao chép từ bất kỳ một nguồn nào và dưới bất kỳ hình thức nào. Việc tham khảo các nguồn tài liệu (nếu có) đã được thực hiện trích dẫn và ghi nguồn tài liệu tham khảo đúng quy định.

Tác giả ĐATN

Tống Thu Phương

LỜI CẢM ƠN

Trong thời gian làm đồ án tốt nghiệp, em đã nhận được nhiều sự giúp đỡ, đóng góp ý kiến và chỉ bảo nhiệt tình của thầy cô, gia đình và bạn bè.

Em xin gửi lời cảm ơn chân thành đến TS. Lê Thị Tú Kiên, người đã tận tình hướng dẫn, chỉ bảo em trong suốt quá trình làm đồ án tốt nghiệp.

Em cũng xin chân thành cảm ơn các thầy cô giáo trong trường Đại học Thủy Lợi nói chung, các thầy cô trong khoa Công Nghệ Thông Tin nói riêng đã dạy dỗ cho em kiến thức về các môn đại cương cũng như các môn chuyên ngành, giúp em có được cơ sở lý thuyết vững vàng và tạo điều kiện giúp đỡ em trong suốt quá trình học tập.

Cuối cùng, em xin chân thành cảm ơn gia đình và bạn bè, đã luôn tạo điều kiện, quan tâm, giúp đỡ, động viên em trong suốt quá trình học tập và hoàn thành khoá luận tốt nghiệp.

Với điều kiện thời gian cũng như kinh nghiệm còn hạn chế của một sinh viên, đồ án này không thể tránh được những thiếu sót. Em rất mong nhận được sự chỉ bảo, đóng góp ý kiến của các thầy cô để em có điều kiện bổ sung, nâng cao ý thức của mình, phục vụ tốt hơn công tác thực tế sau này

Em xin chân thành cảm ơn!

MỤC LỤC

MỤC LỤC iii
DANH MỤC BẢNG BIỂU v
DANH MỤC HÌNH ẢNH vi
DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ vii
PHẦN MỞ ĐẦU 1
CHƯƠNG 1. GIỚI THIỆU 6
1.1 Giới thiệu bài toán 6
1.2 Mạng Neural network 7
1.3 Học Sâu (Deep Learning) 9
1.4 Tổng quan các phương pháp và nghiên cứu liên quan 13
1.5 Kết luận 14
CHƯƠNG 2. XÂY DỰNG MÔ HÌNH PHÂN LỚP ẢNH CÓ DẤU HIỆU UNG THƯ PHỔI DỰA TRÊN DENSENET121 16
2.1 Mạng Nơ-ron tích chập 16
2.2 Mô hình DenseNet (Densely Connected Convolutional Network) 20
2.2.1 Densenet 20
2.2.2 Các biến thể của Densenet 24
2.2.3 Ưu điểm của DenseNet 24
2.3 Mô hình DenseNet121 25
2.4 Học chuyển giao (Transfer Learning) 26
2.5 Xây dựng mô hình hỗ trợ phát hiện dấu hiệu ung thư phổi dựa trên ảnh X-quang ngực 28
2.6 Các độ đo được sử dụng để đánh giá mô hình phân lớp 31
2.6.1 Ma trận nhầm lẫn (Confusion Matrix) 31
2.6.2 Accuracy – Độ chính xác tổng thể 32
2.6.3 Precision – Độ chính xác theo lớp dương 32
2.6.4 Recall – Độ bao phủ (Sensitivity) 32
2.6.5 F1-Score – Trung bình điều hòa giữa Precision và Recall 32
2.6.6 ROC Curve và AUC – Khả năng phân biệt mô hình 33

CHƯƠNG 3. CÀI ĐẶT VÀ THỰC NGHIỆM 34
3.1 Tập dữ liệu.....34
3.2 Huấn luyện mô hình phân lớp ảnh.....34
3.3 Phân tích kết quả thực nghiệm 38
3.4 So sánh với mô hình Densenet121 thuần 42
3.5 Ứng dụng hỗ trợ phát hiện dấu hiệu ung thư phổi.....45
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN CỦA ĐỀ TÀI 50
TÀI LIỆU THAM KHẢO.....52
PHỤ LỤC 53

DANH MỤC BẢNG BIỂU

Bảng 3. 1 Bảng kết quả mô hình Densenet121 39

DANH MỤC HÌNH ẢNH

Hình 1. 1 Kiến trúc mạng Nơ-ron nhân tạo dạng lan truyền tiến (Feedforward Neural Network) gồm một lớp ẩn. 8
Hình 1. 2 Minh họa cách CNN học đặc trưng từ mức thấp đến mức cao trong nhận dạng hình ảnh. 10
Hình 2. 1 Tổng quan kiến trúc mô hình CNN 16
Hình 2. 2 Minh họa quá trình tích chập với kernel 3×3 để phát hiện cạnh dọc tại vùng chuyển tiếp giữa da sáng và vùng nốt ruồi sẫm màu 17
Hình 2. 3 Minh họa kiến trúc Dense Block trong mạng DenseNet 21
Hình 2. 4 Sơ đồ kiến trúc tổng thể của mô hình DenseNet 22
Hình 2. 5 Sơ đồ kiến trúc xây dựng mô hình phân lớp ảnh ung thư phổi 29
Hình 3. 1 Ma trận nhầm lẫn trên mô hình Densenet121 39
Hình 3. 2 Biểu đồ chỉ số ROC trên mô hình 40
Hình 3. 3 Biểu đồ chỉ số Precision-Recall AUC trên mô hình 40
Hình 3. 4 Biểu đồ huấn luyện giữa các epoch trên mô hình kết hợp 41
Hình 3. 5 Ma trận nhầm lẫn trên mô hình Densenet121 thuần 43
Hình 3. 6 Biểu đồ ROC trên mô hình Densenet121 thuần 43
Hình 3. 7 Biểu đồ Precision-Recall AUC trên mô hình Densenet121 thuần 44
Hình 3. 8 Biểu đồ huấn luyện giữa các epoch trên mô hình Densenet121 thuần 44
Hình 3. 9 Giao diện thao tác của chức năng Chẩn đoán ca bệnh 46
Hình 3. 10 Giao diện thao tác của chức năng Sàng lọc hàng loạt 46
Hình 3. 11 Giao diện kết quả phân tích của chức năng Chẩn đoán ca bệnh 47
Hình 3. 12 Giao diện kết quả phân tích của chức năng Sàng lọc hàng loạt 47
Hình 3. 13 Giao diện Vùng chú ý 48
Hình 3. 14 Giao diện chức năng xem Lịch sử 49

DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ

Từ viết tắt	Thuật ngữ	Giải thích
AI	Artificial Intelligence	Trí tuệ nhân tạo
DL	Deep Learning	Học sâu
ML	Machine Learning	Học máy
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
ANN	Artificial Neural Network	Mạng nơ-ron nhân tạo
UTP	Ung thư phổi	Ung thư phổi

PHẦN MỞ ĐẦU

Đặt vấn đề

Ung thư phổi là một trong những nguyên nhân gây tử vong hàng đầu trên toàn thế giới, với tỷ lệ phát hiện muộn rất cao. Nguyên nhân chủ yếu là do các triệu chứng ở giai đoạn đầu thường mơ hồ, dễ nhầm lẫn với các bệnh hô hấp thông thường. Khi bệnh được chẩn đoán ở giai đoạn muộn, khả năng điều trị hiệu quả giảm mạnh, đồng thời chi phí điều trị và nguy cơ tử vong tăng lên đáng kể, gây gánh nặng lớn cho bệnh nhân và hệ thống y tế.

Trong bối cảnh đó, chẩn đoán sớm dấu hiệu ung thư phổi đóng vai trò then chốt trong việc nâng cao tỷ lệ sống sót và cải thiện chất lượng cuộc sống cho người bệnh. Chụp X-quang ngực là một trong những phương pháp chẩn đoán hình ảnh phổ biến, chi phí thấp và được sử dụng rộng rãi trong sàng lọc ban đầu. Tuy nhiên, việc khai thác hiệu quả thông tin từ ảnh X-quang vẫn còn nhiều hạn chế, đặc biệt đối với các dấu hiệu ung thư phổi ở giai đoạn sớm. Điều này đặt ra nhu cầu cần có các phương pháp hỗ trợ nhằm nâng cao hiệu quả phát hiện các dấu hiệu bất thường trên ảnh X-quang.

Trong thực tế lâm sàng, việc phát hiện và đánh giá các dấu hiệu ung thư phổi trên ảnh X-quang lồng ngực chủ yếu dựa vào kinh nghiệm và chuyên môn của bác sĩ chẩn đoán hình ảnh. Quy trình này bao gồm việc quan sát trực tiếp các đặc điểm bất thường trên phim X-quang, kết hợp với tiền sử bệnh và các kết quả cận lâm sàng liên quan. Trong những trường hợp phức tạp, kết luận cuối cùng thường cần sự tham gia của nhiều bác sĩ hoặc hội đồng chuyên môn nhằm đảm bảo độ chính xác. Phương pháp đánh giá thủ công này không chỉ **tốn nhiều thời gian** mà còn phụ thuộc lớn vào kinh nghiệm cá nhân, dẫn đến khả năng **khác biệt trong kết luận** giữa các bác sĩ. Ngoài ra, các tổn thương nhỏ hoặc mờ ở giai đoạn sớm thường khó nhận biết trên ảnh X-quang, làm tăng nguy cơ bỏ sót hoặc phát hiện muộn.

Trước những hạn chế đó, sự phát triển mạnh mẽ của trí tuệ nhân tạo, đặc biệt là học sâu (Deep Learning), đã mở ra hướng tiếp cận mới trong lĩnh vực phân tích ảnh y tế. Các mô hình mạng nơ-ron tích chập (Convolutional Neural Network – CNN) có khả năng tự động học và trích xuất các đặc trưng hình ảnh phức tạp, từ đó hỗ trợ hiệu quả

cho bài toán phát hiện và phân loại bệnh từ ảnh X-quang. Trong số đó, DenseNet121 là một kiến trúc CNN hiện đại, nổi bật với khả năng truyền đặc trưng hiệu quả và giảm hiện tượng mất gradient khi huấn luyện mô hình sâu.

Tuy nhiên, việc ứng dụng học sâu trong trong lĩnh vực phân tích ảnh X-quang ngực vẫn phải đối mặt với nhiều thách thức như chất lượng và sự mất cân bằng của dữ liệu y tế, yêu cầu tài nguyên tính toán lớn, cũng như nhu cầu đánh giá mô hình theo các độ đo phù hợp với bối cảnh y khoa. Do đó, việc nghiên cứu, xây dựng và đánh giá mô hình DenseNet121 cho bài toán phát hiện dấu hiệu ung thư phổi từ ảnh X-quang là cần thiết, có ý nghĩa khoa học và giá trị ứng dụng thực tiễn cao.

Mục tiêu nghiên cứu:

Mục tiêu của đề tài là nghiên cứu, xây dựng và đánh giá mô hình học sâu dựa trên kiến trúc DenseNet121 nhằm hỗ trợ phát hiện các dấu hiệu nghi ngờ ung thư phổi trên ảnh X-quang lồng ngực, góp phần nâng cao hiệu quả sàng lọc ban đầu. Để đạt được mục tiêu này đầu tiên, đề tài tập trung tìm hiểu tổng quan về ung thư phổi, bao gồm các dạng tổn thương thường gặp và các dấu hiệu nghi ngờ ung thư thể hiện trên ảnh X-quang lồng ngực như nốt phổi (nodule), khối u (mass). Đồng thời, nghiên cứu các phương pháp chẩn đoán hình ảnh hiện nay và vai trò của trí tuệ nhân tạo trong việc hỗ trợ phát hiện sớm ung thư phổi.

Tiếp theo, đề tài tiến hành nghiên cứu các phương pháp học sâu, trong đó tập trung vào mạng nơ-ron tích chập (Convolutional Neural Network – CNN) nhằm tìm ra giải pháp phù hợp cho bài toán phân tích ảnh X-quang lồng ngực. Kiến trúc DenseNet121 được lựa chọn để trích xuất các đặc trưng quan trọng từ ảnh X-quang như cấu trúc mô phổi, hình dạng và mật độ tổn thương, phục vụ cho quá trình phân loại ảnh. Trên cơ sở đó mô hình CNN DenseNet121 được sử dụng để huấn luyện và nhận diện các ảnh X-quang có hoặc không có dấu hiệu nghi ngờ ung thư phổi. Thông qua quá trình huấn luyện và kiểm thử trên tập dữ liệu X-quang lồng ngực, mô hình được đánh giá khả năng học đặc trưng và phân loại ảnh một cách hiệu quả.

Mục tiêu cuối cùng của đề tài là ứng dụng kiến thức đã thu thập để phát triển một mô hình học sâu dựa trên DenseNet121 nhằm hỗ trợ sàng lọc và phát hiện sớm các dấu hiệu nghi ngờ ung thư phổi từ ảnh X-quang lồng ngực. Hiệu quả của mô

hình được đánh giá thông qua các độ đo phổ biến, từ đó phân tích ưu điểm, hạn chế và đề xuất các hướng cải tiến nhằm nâng cao độ chính xác và tính ứng dụng của mô hình trong thực tiễn.

Đối tượng và phạm vi nghiên cứu:

Đối tượng nghiên cứu của đề tài này là dấu hiệu ung thư phổi, các mô hình học sâu dựa trên mạng nơ-ron tích chập (CNN), cụ thể là DenseNet121, và các độ đo đánh giá hiệu năng mô hình phân loại trong bài toán y tế.

Phạm vi nghiên cứu:

- Sử dụng bộ dữ liệu con của bộ dữ liệu công khai NIH Chest X-ray.
- Ứng dụng mô hình học sâu Densenet121.
- Tập trung vào giai đoạn dự đoán và đánh giá hiệu năng.

Phương pháp nghiên cứu:

Để đạt được các mục tiêu đã đề ra, đề tài trước hết tiến hành nghiên cứu lý thuyết về ung thư phổi, các dạng tổn thương thường gặp và các yếu tố nguy cơ liên quan; đồng thời tìm hiểu cơ sở lý thuyết của các phương pháp học sâu, đặc biệt là các mô hình mạng nơ-ron tích chập (CNN) được ứng dụng trong bài toán phân loại ảnh y tế. Trên cơ sở đó, đề tài tiến hành khảo sát và tiền xử lý tập dữ liệu ảnh X-quang lồng ngực (tập con của bộ dữ liệu NIH ChestX-ray14) nhằm đảm bảo chất lượng dữ liệu cho quá trình huấn luyện. Tiếp theo, mô hình DenseNet121 được xây dựng và huấn luyện để học các đặc trưng quan trọng từ ảnh X-quang phục vụ cho bài toán phát hiện các dấu hiệu nghi ngờ ung thư phổi. Cuối cùng, hiệu năng của mô hình được đánh giá thông qua các độ đo phù hợp, kết quả thực nghiệm được phân tích nhằm rút ra nhận xét và đề xuất các hướng cải tiến trong tương lai.

Phương pháp thực nghiệm:

- Tiền xử lý dữ liệu.
- Huấn luyện mô hình Densenet121.
- Đánh giá hiệu năng: dùng Accuracy, Precision, Recall, F1, ROC-AUC.
- Phân tích so sánh

- Đánh giá ưu, nhược điểm và khả năng ứng dụng thực tế.

Xây dựng ứng dụng demo: Thiết kế giao diện bằng Streamlit với chức năng phát hiện dấu hiệu ung thư phổi dựa trên ảnh X-quang ngực và chức năng xem lại lịch sử chẩn đoán.

Ý nghĩa và tính ứng dụng thực tiễn

Ý nghĩa khoa học:

Ung thư phổi là một trong những nguyên nhân gây tử vong hàng đầu trên thế giới, trong đó việc phát hiện sớm đóng vai trò then chốt trong nâng cao khả năng điều trị và kéo dài thời gian sống cho bệnh nhân. Tuy nhiên, việc đọc và phân tích ảnh X-quang ngực phụ thuộc nhiều vào kinh nghiệm chủ quan của bác sĩ và có thể bỏ sót các tổn thương nhỏ hoặc không điển hình. Việc ứng dụng mô hình học sâu, cụ thể là mạng nơ-ron tích chập DenseNet121, cho phép tự động trích xuất các đặc trưng hình ảnh phức tạp và phi tuyến, từ đó hỗ trợ phát hiện các dấu hiệu bất thường mà các phương pháp truyền thống khó nhận biết.

Tính ứng dụng thực tiễn:

Kết quả nghiên cứu của đề tài được ứng dụng trong các nội dung thực tiễn như:

- **Hỗ trợ sàng lọc sớm:** Mô hình được sử dụng như một công cụ hỗ trợ, giúp sàng lọc nhanh các ảnh X-quang có nguy cơ cao trong các chương trình khám sức khỏe định kỳ.
- **Hỗ trợ bác sĩ chẩn đoán:** Kết quả dự đoán từ mô hình đóng vai trò như "ý kiến thứ hai", giúp bác sĩ giảm tải công việc và nâng cao độ tin cậy trong quá trình ra quyết định.
- **Nền tảng cho hệ thống y tế thông minh:** Kết quả nghiên cứu có thể làm cơ sở để phát triển các hệ thống hỗ trợ chẩn đoán dựa trên trí tuệ nhân tạo trong lĩnh vực chẩn đoán hình ảnh y tế.

Cấu trúc đồ án:

Ngoài các phần Mở đầu, Kết luận và Tài liệu tham khảo, nội dung chính của đồ án được bố cục thành ba chương như sau:

- Chương 1 – Trình bày các kiến thức nền tảng về ung thư phổi, mô tả bài toán nghiên cứu, giới thiệu các khái niệm và thuật toán cơ bản trong học sâu được áp dụng trong đề tài.
- Chương 2 – Trình bày cơ sở lý thuyết và quá trình xây dựng mô hình phân lớp ảnh dựa trên học sâu. Nội dung chương tập trung vào mạng nơ-ron tích chập (CNN), kiến trúc DenseNet và mô hình DenseNet121. Bên cạnh đó, chương cũng mô tả quá trình xây dựng mô hình hỗ trợ phát hiện dấu hiệu ung thư phổi và giới thiệu các độ đo được sử dụng để đánh giá hiệu năng mô hình
- Chương 3 – Thực nghiệm và đánh giá: Trình bày quá trình thử nghiệm, phân tích kết quả, đối chiếu các mô hình và đánh giá mức độ hiệu quả của hệ thống dự đoán được xây dựng cũng như triển khai giao diện ứng dụng bằng Streamlit.

CHƯƠNG 1. GIỚI THIỆU

1.1 Giới thiệu bài toán

Ung thư phổi (UTP) là bệnh lý ác tính xuất phát từ biểu mô niêm mạc phế quản, phế nang, từ các tuyến của phế quản hoặc từ các thành phần khác của phổi. UTP là loại ung thư chiếm vị trí hàng đầu về tỷ lệ mắc cũng như tỷ lệ tử vong trên toàn thế giới. Theo các thống kê gần đây của hiệp hội quốc tế về nghiên cứu ung thư (IARC) và cơ sở dữ liệu GLOBOCAN 2018 [1], ung thư phổi và ung thư vú ở nữ giới đang dẫn đầu về số ca được chẩn đoán mắc mới; với mỗi loại, ước tính khoảng 2,09 triệu ca mắc mới được phát hiện trong năm 2018, chiếm đến 11,6% tất cả các loại ung thư. Ung thư phổi cũng là loại ung thư gây tử vong nhiều nhất (1,76 triệu ca tử vong, chiếm 18,4% tất cả các loại ung thư).

Các nguyên nhân chính của ung thư phổi bao gồm việc **hút thuốc lá**, tiếp xúc với chất gây ung hại như amiăng, ô nhiễm không khí và yếu tố di truyền. Ung thư phổi được chia thành hai loại chính:

- **Ung thư phổi tế bào nhỏ (Small Cell Lung Cancer - SCLC)**: phát triển nhanh, thường liên quan tới hút thuốc lá;
- **Ung thư phổi không tế bào nhỏ (Non-Small Cell Lung Cancer - NSCLC)**: chiếm phần lớn các trường hợp ung thư phổi.

Tuy nhiên, ung thư phổi nếu được phát hiện sớm thì cơ hội chữa khỏi rất cao, có thể lên đến khoảng 80% đến 90% [2]. Chính vì vậy, việc phát hiện và nhận dạng vị trí khối u ở giai đoạn đầu là hết sức cần thiết, có thể giảm được tỷ lệ tử vong cho người bệnh.

Trong thời đại công nghệ số, trí tuệ nhân tạo (AI) và học máy (Machine Learning – ML) đã và đang trở thành nền tảng cốt lõi trong việc xử lý dữ liệu lớn và hỗ trợ ra quyết định trong nhiều lĩnh vực, đặc biệt là y tế. Một trong những nhánh nổi bật của học máy là **học sâu (Deep Learning)** – lĩnh vực tập trung vào việc sử dụng các mạng nơ-ron nhân tạo nhiều lớp để mô phỏng cơ chế học của con người, giúp máy tính có khả năng tự động phát hiện và trích xuất đặc trưng từ dữ liệu phức tạp, điển hình là hình ảnh y khoa.

Trong bối cảnh đó, nhu cầu phát hiện sớm và hỗ trợ nhận diện các dấu hiệu ung thư phổi từ ảnh X-quang lồng ngực đặt ra những yêu cầu cao về hiệu quả, độ tin cậy

và khả năng tổng quát hóa của các mô hình phân loại hình ảnh. Việc ứng dụng **mạng nơ-ron tích chập (Convolutional Neural Networks – CNN)** đã cho thấy nhiều kết quả tích cực trong lĩnh vực phân tích và phân loại ảnh y tế. Tuy nhiên, một trong những thách thức lớn của bài toán này là sự hạn chế về dữ liệu huấn luyện có chất lượng cao và đa dạng, đặc biệt đối với các bộ dữ liệu y tế thực tế, nơi việc thu thập và gán nhãn dữ liệu thường tốn nhiều thời gian, chi phí và phụ thuộc vào chuyên môn của bác sĩ.

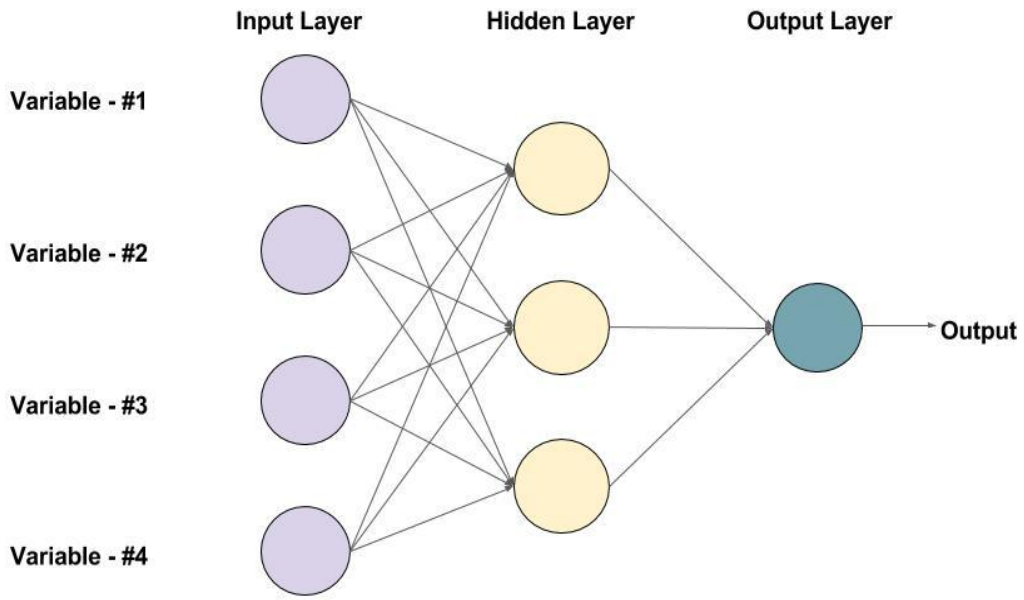
Thách thức chính của bài toán là thiết kế một quy trình xử lý dữ liệu hiệu quả để giải quyết các vấn đề thực tế trong bộ dữ liệu ChestXray như xử lý tình trạng mất cân bằng dữ liệu (imbalanced data), do số lượng mẫu "không mắc bệnh" nhiều hơn đáng kể so với mẫu "mắc bệnh".

1.2 Mạng Neural network

Mạng Nơ-ron Nhân tạo (ANN) đại diện cho một sự thay đổi mô hình (paradigm shift) trong khoa học máy tính: thay vì lập trình tường minh các quy tắc để xử lý dữ liệu, chúng ta xây dựng các hệ thống có khả năng tự học các quy luật đó từ các ví dụ thực tế. Lấy cảm hứng từ cấu trúc kết nối phức tạp của các nơ-ron thần kinh trong não bộ con người, ANN là một mô hình toán học bao gồm các đơn vị xử lý thông tin được kết nối với nhau, gọi là các nơ-ron nhân tạo.

Về bản chất, mỗi nơ-ron là một đơn vị tính toán thực hiện một quy trình gồm hai bước chính. Đầu tiên, nó nhận một tập hợp các tín hiệu đầu vào từ lớp trước đó, trong đó mỗi tín hiệu có một "trọng số" (weight) riêng thể hiện mức độ quan trọng. Nơ-ron sẽ tính toán một tổng hợp của tất cả các tín hiệu này dựa trên trọng số của chúng. Sau đó, kết quả tổng hợp này sẽ được đưa qua một **hàm kích hoạt (activation function)**. Hàm này hoạt động như một "cổng quyết định" phi tuyến, có nhiệm vụ xác định xem tín hiệu có đủ mạnh để được truyền đi hay không và định hình tín hiệu đầu ra cuối cùng mà nơ-ron sẽ gửi đến lớp tiếp theo.

Tuy nhiên, sức mạnh thực sự của ANN không nằm ở một nơ-ron đơn lẻ, mà nằm ở kiến trúc kết nối đa lớp của chúng. Một kiến trúc mạng nơ-ron truyền thẳng (Feed-forward Neural Network) điển hình được cấu thành từ ba thành phần chính:



Hình 1. 1 Kiến trúc mạng Nơ-ron nhân tạo dạng lan truyền tiến (Feedforward Neural Network) gồm một lớp ẩn.

Kiến trúc phân lớp: Các nơ-ron được tổ chức thành các lớp tuần tự.

Lớp đầu vào (Input Layer): Đóng vai trò là "cổng cảm biến" của mạng, có nhiệm vụ duy nhất là tiếp nhận và truyền dữ liệu thô ban đầu (ví dụ: các giá trị pixel của ảnh, các đặc trưng của bệnh nhân) vào hệ thống. Số lượng nơ-ron ở lớp này luôn bằng số lượng đặc trưng của dữ liệu đầu vào.

Lớp ẩn (Hidden Layer): Đây là "bộ não xử lý" của mạng, nơi các phép tính toán chính diễn ra. Một mạng có thể có một hoặc nhiều lớp ẩn. Chính tại đây, mạng học cách kết hợp các thông tin từ lớp trước để tạo ra các biểu diễn ngày càng trừu tượng và phức tạp hơn. Chiều sâu của một mô hình học sâu chính là được quyết định bởi số lượng các lớp ẩn này.

Lớp đầu ra (Output Layer): Là lớp cuối cùng, có nhiệm vụ đưa ra kết quả dự đoán cuối cùng của mô hình. Cấu trúc của lớp này (số nơ-ron và hàm kích hoạt) được thiết kế riêng để phù hợp với từng bài toán cụ thể.

Hệ tham số có thể học được (Learnable Parameters): Mỗi kết nối giữa hai nơ-ron trong các lớp khác nhau được gắn với một **trọng số (weight)**. Toàn bộ các trọng số

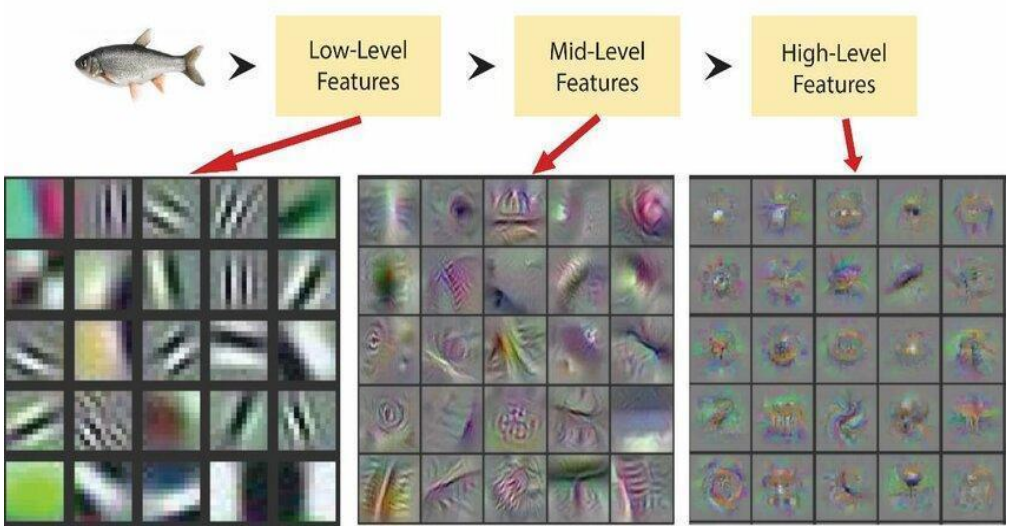
và các giá trị ngưỡng (biases) trong mạng tạo thành một hệ thống tham số có thể điều chỉnh được. Các tham số này đại diện cho "kiến thức" mà mạng học được từ dữ liệu. Mục tiêu của quá trình huấn luyện chính là tìm ra một bộ tham số tối ưu.

Quá trình học (Huấn luyện): Quá trình này là một vòng lặp tối ưu hóa tinh vi. Nó bắt đầu bằng việc cho dữ liệu lan truyền tiến (forward propagation) qua mạng để tạo ra một dự đoán. Sau đó, một **hàm mất mát (loss function)** sẽ so sánh dự đoán này với kết quả thực tế để định lượng mức độ sai sót. Điểm kỳ diệu nằm ở thuật toán **Lan truyền ngược (Backpropagation)**. Nó hoạt động như một hệ thống "phân bổ trách nhiệm", tính toán xem mỗi trọng số trong mạng đã "đóng góp" vào sai sót chung đó như thế nào, sau đó điều chỉnh các trọng số đó một cách từ từ theo hướng làm giảm thiểu sai sót. Quá trình này được lặp đi lặp lại hàng nghìn lần, giống như một người quản lý liên tục đưa ra phản hồi cho từng nhân viên để cả hệ thống hoạt động ngày càng hiệu quả và chính xác hơn.

Từ nền tảng của mạng nơ-ron nhân tạo, các kiến trúc chuyên biệt hơn như **mạng nơ-ron tích chập (CNN)** đã được phát triển nhằm xử lý dữ liệu dạng lưới, đặc biệt là hình ảnh, và trở thành nền tảng cho các mô hình hiện đại như DenseNet121 được sử dụng trong đồ án này.

1.3 Học Sâu (Deep Learning)

Học sâu (Deep Learning) là một phân ngành chuyên biệt và tiên tiến của Học máy (Machine Learning), dựa trên nền tảng của các Mạng Nơ-ron Nhân tạo (ANN). Đặc trưng định danh của học sâu là việc sử dụng các mạng nơ-ron có kiến trúc "sâu" – tức là sở hữu nhiều lớp ẩn được xếp chồng lên nhau. Sự gia tăng về chiều sâu này không chỉ đơn thuần làm cho mô hình trở nên lớn hơn, mà nó mang lại một năng lực tính toán hoàn toàn mới: khả năng tự động học hỏi các biểu diễn dữ liệu ở nhiều cấp độ trừu tượng khác nhau, từ các chi tiết cơ bản nhất đến các khái niệm phức tạp và toàn cục.



Hình 1. 2 Minh họa cách CNN học đặc trưng từ mức thấp đến mức cao trong nhận dạng hình ảnh.

Khả năng tự động học đặc trưng của học sâu được thực hiện thông qua một cơ chế phân cấp tinh vi, có thể được hình dung như cách bộ não con người xử lý thông tin thị giác:

- **Các lớp đầu (Low-Level Features):** Các lớp gần với dữ liệu đầu vào nhất hoạt động như một "võng mạc nhân tạo". Chúng tiếp xúc với dữ liệu pixel thô và học cách nhận diện các đặc trưng cơ bản và nguyên thủy nhất. Đây là "bảng chữ cái" của ngôn ngữ thị giác, bao gồm các đường thẳng, cạnh viền ở các góc độ khác nhau, các gradient màu, hay các đốm sáng-tối.
- **Các lớp giữa (Mid-Level Features):** Các lớp này nhận đầu vào là các đặc trưng cơ bản từ lớp trước và học cách tổng hợp chúng để tạo thành các "từ vựng" phức tạp hơn. Ví dụ, nó có thể học cách kết hợp các đường cong và các mảng màu để nhận diện các bộ phận có ý nghĩa hơn như mắt, mũi, vây cá, hoặc trong bài toán y tế là các cấu trúc mạng lưới sắc tố, các đốm không đều.
- **Các lớp cuối (High-Level Features):** Các lớp sâu nhất sẽ nhận các "từ vựng" này và học cách kết hợp chúng thành các "câu" hoàn chỉnh, mang ý nghĩa trừu tượng và toàn cục. Chúng có thể nhận diện toàn bộ một đối tượng như "khuôn mặt người" hay "con cá". Trong bối cảnh của đồ án này, đây là nơi mô hình học cách kết hợp các dấu hiệu bệnh lý đã được phát hiện để đưa ra quyết định phân loại cuối cùng.

Từ nền tảng của Mạng Nơ-ron Nhân tạo, thực tiễn các bài toán với những dạng dữ liệu đa dạng đã thúc đẩy sự ra đời của các kiến trúc chuyên biệt. Mỗi kiến trúc được thiết kế với một triết lý riêng, tối ưu hóa cho việc xử lý một loại cấu trúc dữ liệu cụ thể.

Trước khi đi vào chi tiết từng kiến trúc, việc hiểu cách các mô hình học sâu được phân loại sẽ cung cấp một bối cảnh hữu ích. Về cơ bản, các mô hình thường được phân loại dựa trên phương thức học của chúng, chủ yếu là Học có giám sát và Học không giám sát.

- **Học có giám sát (Supervised Learning):** Đây là phương thức học phổ biến nhất. Mô hình được huấn luyện trên một tập dữ liệu đã được gán nhãn đầy đủ, tức là mỗi điểm dữ liệu đầu vào đều đi kèm với một kết quả đầu ra (nhãn) chính xác. Mục tiêu của mô hình là học một hàm ánh xạ từ đầu vào đến đầu ra để có thể dự đoán kết quả cho các dữ liệu mới chưa từng thấy. Các bài toán phân loại và hồi quy thuộc nhóm này.
- **Học không giám sát (Unsupervised Learning):** Trong phương thức này, mô hình được huấn luyện trên một tập dữ liệu không có nhãn. Thay vì dự đoán một đầu ra cụ thể, mục tiêu của nó là tự khám phá ra các cấu trúc, các mẫu hình, hoặc các mối quan hệ tiềm ẩn bên trong dữ liệu. Các bài toán như phân cụm (clustering) hay giảm chiều dữ liệu thuộc nhóm này.

Mạng Nơ-ron Tích chập (Convolutional Neural Network – CNN) ra đời như một lời giải cho những hạn chế của mạng nơ-ron truyền thống khi xử lý dữ liệu có cấu trúc không gian như hình ảnh. Lấy cảm hứng từ cách vỏ não thị giác của con người xử lý thông tin theo từng vùng tiếp nhận cục bộ, CNN không kết nối toàn bộ các nơ-ron giữa các lớp. Thay vào đó, mạng sử dụng các bộ lọc tích chập (kernels) hoạt động như những "máy dò đặc trưng" di động, trượt trên toàn bộ ảnh để phát hiện các mẫu cục bộ như cạnh, góc và kết cấu, từ đó tạo ra các bản đồ đặc trưng (feature maps). Bằng cách xếp chồng nhiều lớp tích chập, CNN có khả năng học được các biểu diễn ngày càng trừu tượng, từ các đặc trưng mức thấp đến các đặc trưng mức cao. Nhờ cơ chế này, CNN được lựa chọn làm kiến trúc chủ đạo trong đề tài để phân tích và phân loại ảnh X-quang lồng ngực, phục vụ cho bài toán phát hiện dấu hiệu ung thư phổi.

Mạng DenseNet (Densely Connected Convolutional Network) đại diện cho

một hướng phát triển hiệu quả của mạng nơ-ron tích chập trong lĩnh vực học sâu. Nếu các kiến trúc CNN truyền thống chỉ kết nối tuần tự giữa các lớp, thì DenseNet được thiết kế với cơ chế kết nối dày đặc (dense connections), trong đó mỗi lớp nhận đầu vào trực tiếp từ tất cả các lớp trước đó và truyền đặc trưng của mình cho các lớp sau. Cách kết nối này giúp tăng cường khả năng lan truyền thông tin và gradient trong quá trình huấn luyện, đồng thời giảm hiện tượng mất mát gradient khi mạng trở nên rất sâu.

Trong kiến trúc DenseNet121, mô hình bao gồm 121 lớp với các khối Dense Block và Transition Layer, cho phép học được các đặc trưng hình ảnh ở nhiều mức độ khác nhau. Nhờ khả năng tái sử dụng đặc trưng và hiệu quả huấn luyện cao, DenseNet121 được lựa chọn trong đề tài này để trích xuất đặc trưng và phân loại ảnh X-quang lồng ngực, phục vụ cho bài toán phát hiện dấu hiệu ung thư phổi.

1. Huấn luyện mô hình (Model Training):

Sau khi tiền xử lý, các ảnh X-quang được đưa vào mô hình **DenseNet121**, một kiến trúc mạng nơ-ron tích chập sâu đã được huấn luyện trước trên tập dữ liệu ImageNet. Mô hình được tinh chỉnh (fine-tuning) để phù hợp với bài toán phát hiện dấu hiệu ung thư phổi. Trong quá trình huấn luyện, các lớp trích xuất đặc trưng của DenseNet121 học các đặc điểm hình ảnh quan trọng liên quan đến tổn thương phổi, trong khi các lớp phân loại ở cuối mạng được huấn luyện để đưa ra dự đoán nhị phân. Quá trình huấn luyện được thực hiện trên tập huấn luyện, với các siêu tham số như tốc độ học, số epoch và batch size được lựa chọn phù hợp nhằm tối ưu hiệu năng mô hình và tránh hiện tượng quá khớp.

2. Đánh giá mô hình (Model Evaluation):

- Hiệu năng của mô hình được đánh giá trên tập kiểm thử (test set) dựa trên 5 chỉ số đo lường quan trọng trong y tế : Accuracy, Precision, Recall, F1-score, và ROC-AUC.
- Việc này giúp lựa chọn mô hình tối ưu, cân bằng giữa khả năng dự đoán chính xác (Precision) và khả năng phát hiện bệnh (Recall).

3. Xây dựng ứng dụng Demo:

- Triển khai mô hình học máy vào một ứng dụng web tương tác bằng Streamlit.

- Ứng dụng cho phép người dùng nhập thông tin, nhận dự đoán.

1.4 Tổng quan các phương pháp và nghiên cứu liên quan

Trong bài toán phân tích ảnh y tế nói chung và ảnh X-quang lồng ngực nói riêng, nhiều phương pháp xử lý ảnh và học máy đã được đề xuất nhằm hỗ trợ phát hiện các dấu hiệu bệnh lý. Các phương pháp truyền thống thường dựa trên **xử lý ảnh cổ điển**, bao gồm các bước tiền xử lý, trích xuất đặc trưng thủ công và sử dụng các bộ phân loại học máy.

Cụ thể, trong các phương pháp học máy truyền thống, ảnh X-quang thường được **biểu diễn dưới dạng các vector đặc trưng** thông qua các kỹ thuật như histogram mức xám, đặc trưng kết cấu (GLCM), đặc trưng hình dạng hoặc các phương pháp trích xuất đặc trưng cục bộ. Sau đó, các vector đặc trưng này được đưa vào các mô hình phân loại như **Support Vector Machine (SVM)**, **k-Nearest Neighbors (k-NN)** hoặc **Random Forest** để thực hiện phân loại. Mặc dù các phương pháp này đạt được một số kết quả nhất định nhưng chúng phụ thuộc lớn vào chất lượng của quá trình trích xuất đặc trưng thủ công và thường gặp hạn chế khi xử lý các cấu trúc phức tạp trong ảnh X-quang.

Một trong những nhược điểm chính của các phương pháp học máy truyền thống là quá trình **vector hóa ảnh có thể làm mất đi các mối quan hệ không gian quan trọng** giữa các điểm ảnh. Đối với ảnh X-quang lồng ngực, nơi các dấu hiệu ung thư phổi thường biểu hiện dưới dạng các đường nét mờ, hình dạng không đồng nhất hoặc chồng lấp cấu trúc giải phẫu, việc biểu diễn ảnh bằng các đặc trưng thủ công khó có thể phản ánh đầy đủ thông tin cần thiết, dẫn đến hiệu quả phân loại còn hạn chế.

Trước những hạn chế đó, **học sâu (Deep Learning)**, đặc biệt là **mạng nơ-ron tích chập (Convolutional Neural Network – CNN)**, đã được phát triển nhằm tự động học các đặc trưng phân cấp trực tiếp từ dữ liệu ảnh. CNN cho phép mô hình khai thác thông tin không gian và ngữ cảnh cục bộ thông qua các phép tích chập, từ đó nhận diện hiệu quả các đường nét, hình dạng và cấu trúc đặc trưng trong ảnh X-quang mà không cần thiết kế đặc trưng thủ công. Tuy nhiên, việc huấn luyện các mô hình học sâu từ đầu thường đòi hỏi lượng dữ liệu lớn và tài nguyên tính toán đáng kể, điều này gây khó khăn trong bối cảnh dữ liệu y tế thường hạn chế. Để khắc phục vấn đề này, các phương pháp **học chuyển giao (Transfer Learning)** đã được đề xuất, trong đó các kiến trúc CNN

sâu được huấn luyện sẵn trên các tập dữ liệu lớn và sau đó được tinh chỉnh cho các bài toán cụ thể.

Các **mạng nơ-ron tích chập (Convolutional Neural Networks – CNNs)** đã và đang đóng vai trò trung tâm trong lĩnh vực nhận dạng đối tượng thị giác. Từ mô hình tiên phong LeNet cho đến các kiến trúc được sử dụng rộng rãi như VGG và ResNet, quá trình nghiên cứu luôn hướng tới việc xây dựng các mạng ngày càng sâu hơn và hiệu quả hơn. Một bước đột phá quan trọng trong quá trình phát triển này là sự ra đời của **Mạng nơ-ron tích chập kết nối dày đặc (Densely Connected Convolutional Network – DenseNet)**, được giới thiệu bởi Gao Huang, Zhuang Liu, Laurens van der Maaten và Kilian Q. Weinberger. Kiến trúc mới mẻ của DenseNet giúp cải thiện đáng kể khả năng lan truyền thông tin và gradient trong quá trình huấn luyện, từ đó mang lại nhiều ưu điểm vượt trội so với các mạng CNN truyền thống cũng như kiến trúc ResNet. Một nghiên cứu với 108,948 ảnh báo cáo DenseNet121 đạt AUC khoảng 94 % khi xác định các tình trạng như pneumothorax và oedema trên X-quang [3]. Trong một bài so sánh với VGG16, DenseNet121 đạt độ chính xác ~98.8 %, cho thấy khả năng nhận diện các đặc trưng đường nét phức tạp trong ảnh X-quang hiệu quả hơn so với kiến trúc CNN truyền thống [4].

Xuất phát từ những ưu điểm trên, đề tài đã lựa chọn **mô hình DenseNet121** làm nền tảng để xây dựng hệ thống hỗ trợ phát hiện các dấu hiệu nghi ngờ ung thư phổi từ ảnh X-quang lồng ngực.

1.5 Kết luận

Chương 1 đã trình bày các khái niệm và kiến thức nền tảng làm cơ sở cho việc xây dựng mô hình hỗ trợ phát hiện dấu hiệu ung thư phổi trên ảnh X-quang ngực. Nội dung chương bắt đầu với việc giới thiệu tổng quan về trí tuệ nhân tạo và học sâu, sau đó đi sâu vào nguyên lý hoạt động của mạng nơ-ron nhân tạo (ANN), mạng nơ-ron tích chập (CNN) và các kiến trúc học sâu trong xử lý ảnh.

Những kiến thức lý thuyết này giúp làm rõ cách các mô hình học sâu tiếp cận, trích xuất đặc trưng và phân loại dữ liệu hình ảnh y tế, đặc biệt là ảnh X-quang lồng ngực. Đồng thời, chương cũng đã tổng quan các phương pháp và nghiên cứu liên quan, qua đó cho thấy tiềm năng ứng dụng của học sâu trong bài toán hỗ trợ phát hiện sớm

các dấu hiệu ung thư phổi.

Trên cơ sở các kiến thức nền tảng đã trình bày, chương tiếp theo sẽ tập trung vào việc xây dựng mô hình phân lớp ảnh dựa trên kiến trúc DenseNet121 và phương pháp học chuyển giao, bao gồm quá trình thiết kế mô hình, tiền xử lý dữ liệu và các độ đo được sử dụng để đánh giá hiệu năng của hệ thống.

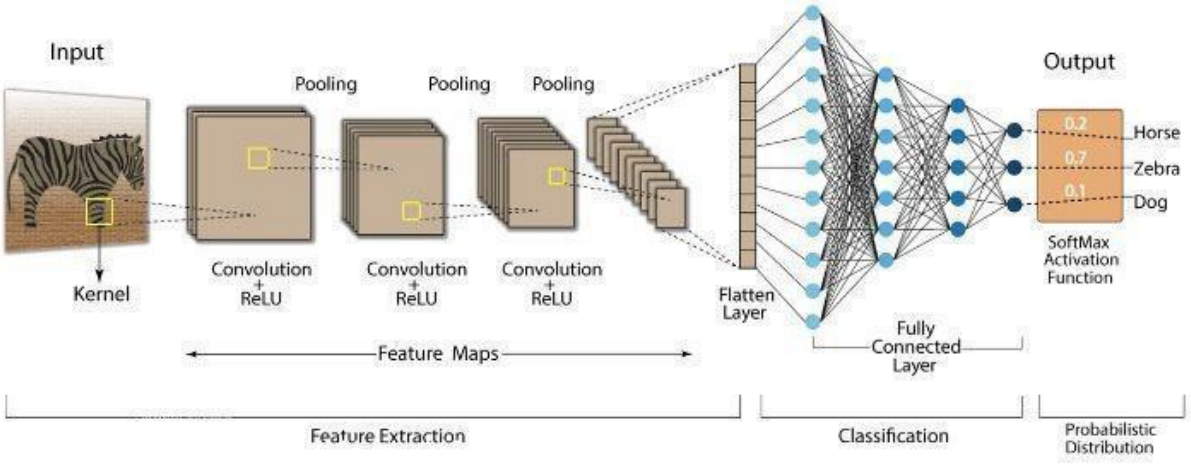
CHƯƠNG 2. XÂY DỰNG MÔ HÌNH PHÂN LỚP ẢNH CÓ DẤU HIỆU UNG THƯ PHỔI DỰA TRÊN DENSENET121

2.1 Mạng Nơ-ron tích chập

Mạng Nơ-ron Tích chập (Convolutional Neural Network – CNN) là một kiến trúc học sâu chuyên biệt, và là công nghệ nền tảng được lựa chọn trong đề tài này để trích xuất đặc trưng và phân loại các ảnh X-quang lồng ngực với cấu trúc không gian phức tạp. Để hiểu cơ chế hoạt động và ưu điểm của CNN, chúng ta sẽ phân tích các thành phần cấu tạo và triết lý thiết kế của mô hình.

Các lớp cơ bản của mạng CNN

Một mạng CNN có thể được hình dung như một "dây chuyền lắp ráp" thông tin, trong đó mỗi công đoạn là một lớp (layer) thực hiện một nhiệm vụ chuyên biệt. Sự kết hợp của các lớp này tạo nên sức mạnh cho toàn bộ kiến trúc.



Hình 2. 1 Tổng quan kiến trúc mô hình CNN

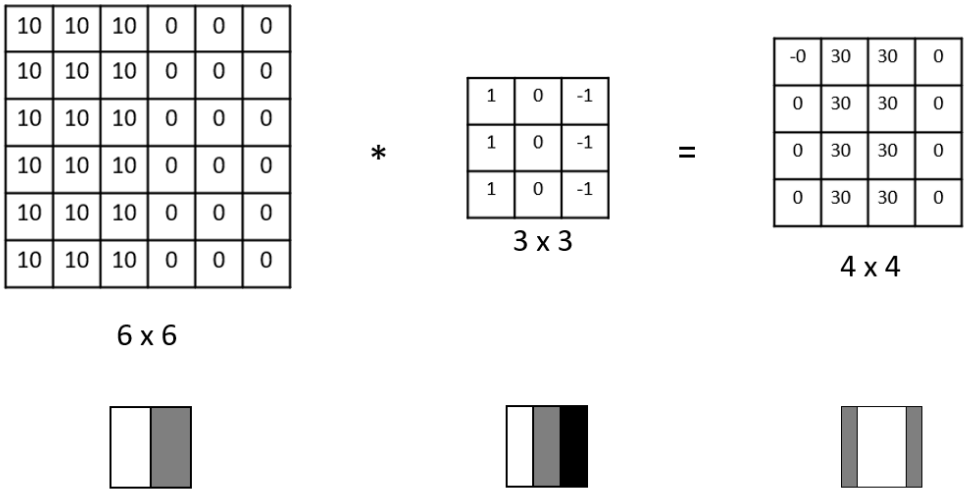
1. Lớp Tích chập (Convolutional Layer): Trái tim của việc trích xuất đặc trưng

Đây là thành phần mang tính định danh và quan trọng nhất của CNN, đóng vai trò như "võng mạc" và "vỏ não thị giác sơ cấp" của mạng nơ-ron. Nhiệm vụ của nó không chỉ đơn thuần là xử lý, mà là "nhìn" và "hiểu" dữ liệu ảnh bằng cách phát hiện các mẫu hình ảnh (patterns) có ý nghĩa.

Lớp này vận hành một tập hợp các bộ lọc (Filter hay Kernel), là những ma trận trọng số nhỏ có thể học được. Hãy xem mỗi bộ lọc như một "máy dò đặc trưng" được

đào tạo chuyên biệt. Ban đầu, các trọng số của bộ lọc này được khởi tạo ngẫu nhiên, nhưng qua quá trình huấn luyện, chúng sẽ được tinh chỉnh một cách tỉ mỉ thông qua thuật toán lan truyền ngược để trở thành chuyên gia phát hiện một loại mẫu cụ thể. Bộ lọc này sẽ trượt trên toàn bộ ảnh đầu vào, thực hiện phép tích chập tại mỗi vị trí. Phép tính này bao gồm việc nhân từng giá trị của bộ lọc với giá trị pixel tương ứng trên ảnh, sau đó cộng tất cả các kết quả đó lại và cộng thêm một hệ số thiên vị (bias) để ra một giá trị duy nhất. Giá trị này thể hiện mức độ phản ứng hay "kích hoạt" của bộ lọc tại vị trí đó. Tập hợp tất cả các giá trị này tạo thành một ma trận hai chiều gọi là bản đồ đặc trưng (Feature Map). Về cơ bản, bản đồ đặc trưng là một "bản đồ nhiệt" trực quan, cho thấy đặc trưng mà bộ lọc tìm kiếm xuất hiện ở đâu và mạnh mẽ như thế nào trên ảnh gốc.

- **Ví dụ:**



Hình 2. 2 Minh họa quá trình tích chập với kernel 3×3 để phát hiện cạnh dọc tại vùng chuyển tiếp giữa da sáng và vùng nốt ruồi sẫm màu

Để minh họa, có một vùng ảnh nhỏ 5x5 pixel, chụp ngay tại đường viền của một nốt ruồi. Các giá trị pixel của vùng da sáng là 10, và vùng nốt ruồi sẫm màu là 90. Chúng ta áp dụng một kernel 3x3 chuyên phát hiện cạnh dọc.

Khi kernel này trượt qua một vùng hoàn toàn là da (tất cả pixel là 10) hoặc hoàn toàn là nốt ruồi (tất cả pixel là 90), kết quả của phép tích chập sẽ gần bằng 0, vì không có sự thay đổi.

Nhưng khi kernel trượt đến đúng vị trí đường viền, nó sẽ bao phủ cả các pixel 10 và 90. Phép tính sẽ cho ra một giá trị có độ lớn cao (ví dụ: +240 hoặc -240).

Kết quả là, bản đồ đặc trưng đầu ra sẽ làm nổi bật rõ nét đường viền của tổn thương bằng các giá trị cao, trong khi các vùng phẳng khác có giá trị gần 0. Việc xác định được các đường viền rõ ràng là bước đầu tiên và cơ bản nhất để sau này mô hình có thể đánh giá được tính bất đối xứng (Asymmetry) và đường viền không đều (Border irregularity) của tổn thương.

2. Hàm kích hoạt ReLU (ReLU Activation): Ngưỡng quyết định phi tuyến

Đầu ra từ lớp tích chập sẽ được đưa qua một hàm kích hoạt phi tuyến. Nếu không có bước này, một mạng CNN dù có bao nhiêu lớp cũng chỉ tương đương với một phép biến đổi tuyến tính lớn hơn, và sẽ thất bại trong việc học các mối quan hệ phức tạp trong dữ liệu. **ReLU (Rectified Linear Unit)** là lựa chọn phổ biến nhất.

ReLU hoạt động như một "cổng kiểm soát" hay một "bộ lọc tín hiệu nhiễu" cực kỳ đơn giản và hiệu quả. Nó sẽ loại bỏ tất cả các giá trị âm bằng cách chuyển chúng thành 0, và giữ nguyên tất cả các giá trị dương. Cơ chế này giúp tạo ra sự thưa thớt (sparsity) trong các biểu diễn, nghĩa là chỉ những tín hiệu kích hoạt tích cực và quan trọng nhất mới được giữ lại và truyền đến các lớp sau, giúp mạng tập trung vào những thông tin thực sự có giá trị.

Tiếp nối ví dụ trên, bản đồ đặc trưng về cạnh viền chứa cả các giá trị dương (ví dụ: +240, phát hiện cạnh từ sáng sang tối) và âm (ví dụ: -240, phát hiện cạnh từ tối sang sáng). Giả sử em có bản đồ đặc trưng này, khi đưa nó qua hàm ReLU, tất cả các giá trị -240 sẽ bị chuyển thành 0. Kết quả là một bản đồ đặc trưng mới, "sạch" hơn, chỉ còn lại những điểm sáng thể hiện sự kích hoạt mạnh mẽ, đại diện cho những bằng chứng rõ ràng nhất về sự tồn tại của một đường viền.

3. Lớp Gộp (Pooling Layer): Tầng tinh giản và tổng quát hóa

Lớp gộp có nhiệm vụ chính là thực hiện một quá trình tổng hợp và cô đọng thông tin, thường được gọi là lấy mẫu phụ (downsampling), nhằm giảm kích thước không gian (chiều rộng và cao) của các bản đồ đặc trưng.

Max Pooling (Gộp Cực đại) là phương pháp phổ biến nhất. Nó hoạt động bằng cách trượt một cửa sổ (ví dụ: 2x2) trên bản đồ đặc trưng và chỉ giữ lại giá trị lớn nhất trong mỗi cửa sổ. Việc này mang lại hai lợi ích chiến lược: (1) giảm số lượng tham số và khối lượng tính toán, giúp mạng hoạt động hiệu quả hơn; và (2) tạo ra một biểu diễn có tính bất biến cao hơn với các thay đổi nhỏ về vị trí (local translation invariance), làm cho mô hình trở nên mạnh mẽ hơn trước các biến dạng nhỏ trong ảnh.

Để làm rõ hơn, **có** một bản đồ đặc trưng kích thước 4x4 sau khi đi qua lớp ReLU. Khi áp dụng phép Max Pooling với cửa sổ 2x2 và bước trượt là 2, quy trình sẽ chia vùng này thành bốn khu vực 2x2 không chồng chéo. Trong mỗi khu vực 2x2, nó sẽ tìm và chỉ giữ lại giá trị pixel lớn nhất. Kết quả là một ma trận 4x4 ban đầu được nén lại thành một ma trận 2x2, chỉ chứa những tín hiệu đặc trưng nổi bật nhất. Mạng đã "hy sinh" thông tin về vị trí chính xác của đặc trưng trong từng vùng nhỏ, để đổi lấy một thông tin "cái gì" mạnh mẽ và tổng quát hơn, ví dụ: "có một đặc trưng cạnh rất mạnh đã xuất hiện trong góc phần tư trên bên trái này".

4. Lớp Kết nối đầy đủ (Fully Connected Layer): Khối ra quyết định cuối cùng

Sau khi chuỗi các lớp tích chập và gộp đã trích xuất thành công một tập hợp các đặc trưng bậc cao, các bản đồ đặc trưng cuối cùng sẽ được "làm phẳng" (flatten) thành một vector một chiều. Thao tác này là một bước chuyển đổi quan trọng, nơi cấu trúc không gian được hy sinh một cách có chủ đích để chuẩn bị cho giai đoạn suy luận và phân loại cuối cùng.

Vector đặc trưng này sau đó được đưa vào một hoặc nhiều lớp kết nối đầy đủ. Lớp FC này đóng vai trò như một bộ phân loại. Nó sẽ kết hợp và phân tích tất cả các đặc trưng đã được học để đưa ra quyết định cuối cùng.

Giả sử vector đặc trưng cuối cùng sau khi làm phẳng có 512 giá trị. Mỗi giá trị này là kết quả tổng hợp của toàn bộ quá trình trước đó, có thể được xem như một "bằng chứng" định lượng cho một đặc trưng trừu tượng. Ví dụ, giá trị ở vị trí thứ nhất là điểm số cho "mức độ bất đối xứng của tổn thương", giá trị ở vị trí thứ hai là điểm số cho "sự hiện diện của cấu trúc mạng lưới sắc tố không điển hình", giá trị ở vị trí thứ ba là "sự đa dạng của màu sắc trên toàn bộ tổn thương",... Lớp kết nối đầy đủ hoạt động như một "ban giám khảo" tinh vi. Các trọng số của nó, được học qua quá trình huấn luyện, đại

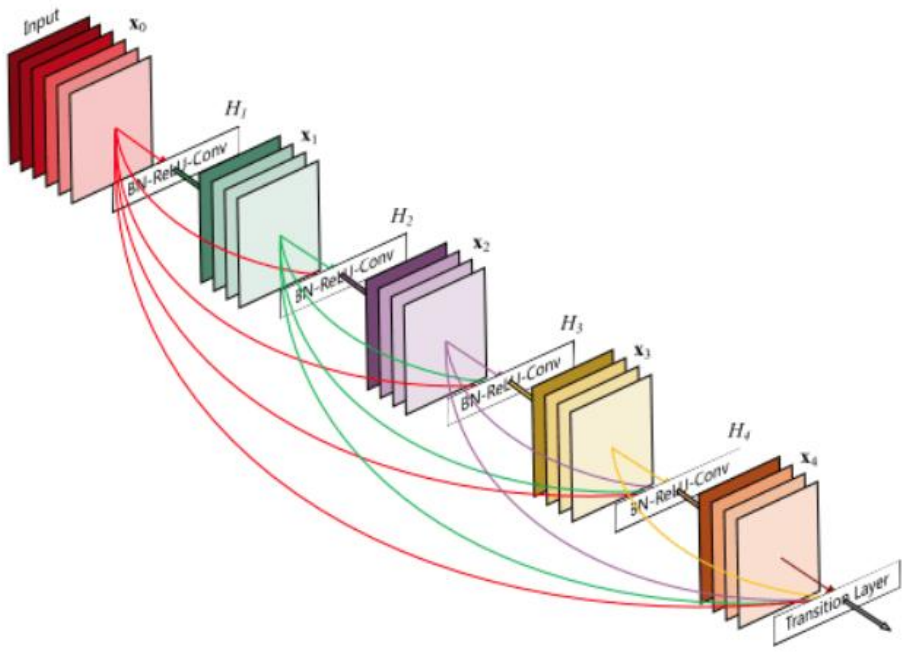
diện cho "kinh nghiệm" của ban giám khảo này. Nó học cách cân nhắc và kết hợp tất cả các bằng chứng này. Ví dụ, nó có thể học được một quy tắc phức tạp rằng: "Nếu bằng chứng về 'bất đối xứng' cao, và bằng chứng về 'đa dạng màu sắc' cao, thì xác suất ác tính sẽ tăng lên đáng kể". Dựa trên sự kết hợp phức tạp này, nó sẽ đưa ra phán quyết cuối cùng dưới dạng một phân phối xác suất trên các lớp.

2.2 Mô hình DenseNet (Densely Connected Convolutional Network)

2.2.1 Densenet

DenseNet, viết tắt của *Dense Convolutional Network* là một kiến trúc mạng nơ-ron tích chập sâu được giới thiệu bởi Gao Huang,và cộng sự trong bài báo có tiêu đề *"Densely Connected Convolutional Networks"* công bố năm 2017, với mục tiêu cải thiện hiệu suất học của các mạng CNN sâu thông qua việc tăng cường khả năng lan truyền thông tin và gradient trong mạng. Trong các kiến trúc CNN truyền thống, khi số lượng lớp tăng lên, mô hình thường gặp phải các vấn đề như hiện tượng mất gradient, trùng lặp đặc trưng và số lượng tham số lớn, làm giảm hiệu quả huấn luyện và khả năng khái quát hóa. DenseNet được thiết kế nhằm giải quyết trực tiếp các hạn chế này thông qua một cơ chế kết nối mới, gọi là kết nối dày đặc (dense connectivity).

Điểm khác biệt cốt lõi của DenseNet so với các mô hình CNN trước đó nằm ở cách các lớp trong mạng được kết nối với nhau. Trong khi hầu hết các kiến trúc CNN truyền thống chỉ cho phép mỗi lớp nhận đầu vào từ lớp liền trước, DenseNet cho phép mỗi lớp nhận đầu vào là tập hợp đặc trưng của tất cả các lớp trước đó trong cùng một khối (Dense Block). Nói cách khác, đầu ra của mỗi lớp sẽ được truyền trực tiếp tới tất cả các lớp phía sau thông qua phép nối đặc trưng (concatenation). Cơ chế kết nối dày đặc này giúp đảm bảo rằng các đặc trưng đã học ở những lớp nông không bị mất đi khi mạng trở nên sâu hơn, đồng thời cho phép các lớp phía sau khai thác trực tiếp những thông tin quan trọng từ các lớp trước.



Hình 2. 3 Minh họa kiến trúc Dense Block trong mạng DenseNet

Connectivity

Trong DenseNet, tại mỗi lớp, **các bản đồ đặc trưng của tất cả các lớp trước đó không được cộng (sum) mà được nối (concatenate)** và sử dụng làm đầu vào. Nhờ cơ chế này, DenseNet **yêu cầu số lượng tham số ít hơn** so với các mạng CNN truyền thống có độ sâu tương đương, đồng thời cho phép **tái sử dụng đặc trưng**, vì các bản đồ đặc trưng dư thừa có thể được loại bỏ.

Cụ thể, **lớp thứ *l*** sẽ nhận các bản đồ đặc trưng của tất cả các lớp trước đó x_0, x_1, …, x_{l-1} làm đầu vào, được biểu diễn bởi công thức:

$$X_l = H_l. ([x_0, x_1, ..., x_{l-1}])$$

trong đó $[x_0, x_1, ..., x_{l-1}]$ biểu thị phép nối (concatenation) các bản đồ đặc trưng, tức là đầu ra được tạo ra từ toàn bộ các lớp đứng trước lớp l (từ lớp 0 đến lớp l−1). Các đầu vào này của hàm biến đổi H_l được kết hợp thành một tensor duy nhất, giúp đơn giản hóa việc cài đặt và triển khai mô hình.

Dense Block

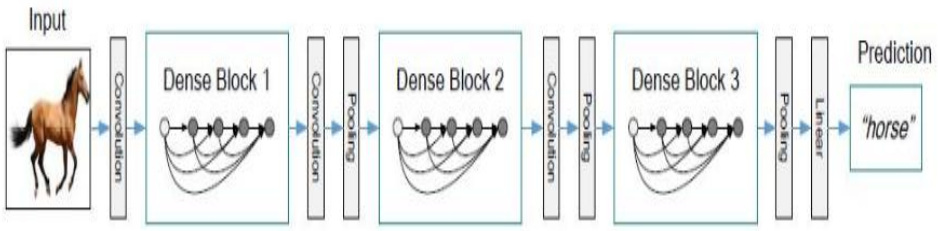
Trong kiến trúc DenseNet, các lớp tích chập được nhóm lại thành các khối gọi là Dense Block. Dense Block là thành phần cơ bản cấu thành nên kiến trúc DenseNet. Mỗi

dense block bao gồm nhiều lớp tích chập, thường được theo sau bởi chuẩn hóa theo lô (Batch Normalization) và hàm kích hoạt phi tuyến (ví dụ: ReLU). Điểm đặc biệt của dense block là mỗi lớp bên trong đều nhận các bản đồ đặc trưng từ tất cả các lớp trước đó làm đầu vào, qua đó thúc đẩy việc tái sử dụng đặc trưng và tăng cường khả năng lan truyền thông tin. Trong một dense block, đầu vào của mỗi lớp là phép nối (concatenation) giữa đầu ra của toàn bộ các lớp phía trước. Giả sử một dense block có m lớp, và mỗi lớp sinh ra k bản đồ đặc trưng, trong đó k được gọi là tốc độ tăng trưởng (growth rate). Khi đó, lớp thứ l sẽ có tổng số bản đồ đặc trưng đầu vào là:

$$k \times (l + l_0)$$

trong đó l_0 là số kênh đầu vào ban đầu của dense block.

Cơ chế này giúp DenseNet duy trì số lượng tham số ở mức hợp lý, đồng thời đảm bảo rằng các đặc trưng được học ở các lớp sớm có thể được khai thác trực tiếp ở các lớp sâu hơn, góp phần cải thiện hiệu quả huấn luyện và độ chính xác của mô hình.



Hình 2. 4 Sơ đồ kiến trúc tổng thể của mô hình DenseNet

Trong hình minh họa, một mô hình DenseNet sâu với ba Dense Block được trình bày. Các lớp nằm giữa hai dense block liền kề là các transition layers, thực hiện quá trình down-sampling (tức là thay đổi kích thước của feature maps) thông qua các phép tích chập và pooling. Ngược lại, bên trong mỗi dense block, kích thước của các feature maps được giữ cố định nhằm đảm bảo khả năng nối đặc trưng (feature concatenation) giữa các lớp.

Transition Layer

Transition Layer được sử dụng để kết nối giữa các Dense Block trong kiến trúc DenseNet. Các lớp chuyển tiếp này đảm nhiệm hai vai trò chính: giảm số lượng bản đồ

đặc trưng (feature maps) và giảm kích thước không gian (downsampling) của các bản đồ đặc trưng. Điều này giúp duy trì hiệu quả tính toán và độ gọn nhẹ của mạng khi độ sâu của mô hình ngày càng tăng. Một transition layer điển hình bao gồm các thành phần sau:

- Batch Normalization: Chuẩn hóa các bản đồ đặc trưng nhằm ổn định và tăng tốc quá trình huấn luyện.
- Tích chập 1×1 (1×1 Convolution): Giảm số lượng kênh đặc trưng, qua đó hạn chế số tham số và chi phí tính toán.
- Gộp trung bình (Average Pooling): Thực hiện giảm kích thước không gian của bản đồ đặc trưng, giúp trích xuất đặc trưng ở mức trừu tượng cao hơn.

Thông qua việc sử dụng transition layers, DenseNet có thể kiểm soát độ phức tạp của mô hình, tránh hiện tượng bùng nổ số lượng đặc trưng khi các dense block được xếp chồng lên nhau, đồng thời vẫn giữ được khả năng lan truyền thông tin hiệu quả giữa các tầng.

Growth rate (k)

Growth rate hay còn gọi là tham số *k* là một siêu tham số quan trọng trong kiến trúc DenseNet, dùng để điều tiết lượng thông tin được bổ sung tại mỗi lớp.Giá trị của *k* càng lớn thì lượng thông tin mới được bổ sung tại mỗi lớp càng nhiều, tuy nhiên điều này cũng đồng thời làm tăng chi phí tính toán và số lượng tham số của mô hình.

Giả sử mỗi hàm biến đổi H_l tạo ra *k* bản đồ đặc trưng, thì lớp thứ *l* sẽ có tổng số bản đồ đặc trưng đầu vào là:

$$k_0 + k \times (l - 1)$$

trong đó k_0 là số lượng kênh của lớp đầu vào ban đầu. Nhờ cơ chế này, mỗi lớp trong DenseNet có thể truy cập trực tiếp vào toàn bộ các đặc trưng đã được học ở các lớp trước, giúp tăng cường khả năng lan truyền thông tin và tái sử dụng đặc trưng.

Việc lựa chọn giá trị *k* có ảnh hưởng trực tiếp đến khả năng biểu diễn (capacity) và hiệu năng tổng thể của mạng. Do đó, *k* cần được cân nhắc hợp lý nhằm đạt được sự cân bằng giữa độ chính xác của mô hình và hiệu quả tính toán, đặc biệt trong các ứng

dụng yêu cầu tài nguyên hạn chế như hệ thống chẩn đoán y khoa.

2.2.2 Các biến thể của Densenet

DenseNet bao gồm nhiều biến thể khác nhau, chủ yếu được phân biệt dựa trên độ sâu và số lượng lớp của mạng:

- DenseNet-121: Gồm 121 lớp, nổi bật với sự cân bằng giữa hiệu quả tính toán và độ chính xác. Kiến trúc này phù hợp cho các bài toán yêu cầu tài nguyên tính toán ở mức trung bình.
- DenseNet-169: Với 169 lớp, biến thể này cho khả năng trích xuất đặc trưng sâu hơn, phù hợp với các tập dữ liệu phức tạp hoặc các bài toán đòi hỏi độ chính xác cao hơn.
- DenseNet-201 và DenseNet-264: Đây là các biến thể có kiến trúc rất sâu, thích hợp cho những bài toán phức tạp yêu cầu khả năng biểu diễn đặc trưng mạnh mẽ và dữ liệu huấn luyện quy mô lớn.

2.2.3 Ưu điểm của DenseNet

- Giảm hiện tượng mất gradient (Reduced Vanishing Gradient Problem):
  Các kết nối dày đặc trong DenseNet giúp cải thiện khả năng lan truyền gradient, từ đó hỗ trợ hiệu quả quá trình huấn luyện các mạng nơ-ron rất sâu.
- Tái sử dụng đặc trưng (Feature Reuse): Mỗi lớp trong DenseNet có quyền truy cập trực tiếp vào các bản đồ đặc trưng của tất cả các lớp trước đó, khuyến khích việc tái sử dụng các đặc trưng đã học và nâng cao hiệu quả học tập của mô hình.
- Giảm số lượng tham số (Fewer Parameters): Nhờ cơ chế tái sử dụng đặc trưng hiệu quả, DenseNet thường có ít tham số hơn so với các mạng CNN truyền thống có độ sâu tương đương, giúp giảm chi phí tính toán và nguy cơ quá khớp.
- Cải thiện độ chính xác (Improved Accuracy): DenseNet đã chứng minh được độ chính xác cao trên nhiều bộ dữ liệu chuẩn như ImageNet và CIFAR, khẳng định tính hiệu quả và khả năng tổng quát hóa của kiến trúc này.

Từ những ưu điểm trên, DenseNet được xem là một kiến trúc CNN hiện đại và hiệu quả, đặc biệt phù hợp cho các bài toán phân tích ảnh y tế. Trên cơ sở kiến trúc

DenseNet, nhiều biến thể đã được phát triển, trong đó DenseNet121 là một trong những mô hình phổ biến và được sử dụng rộng rãi nhất. Mô hình này sẽ được trình bày chi tiết trong mục tiếp theo và được lựa chọn để áp dụng trong bài toán phát hiện dấu hiệu ung thư phổi trên ảnh X-quang ngực của luận văn.

2.3 Mô hình DenseNet121

DenseNet121 là một trong những biến thể tiêu biểu và được sử dụng rộng rãi nhất của kiến trúc DenseNet. Mô hình này được xây dựng dựa trên ý tưởng kết nối dày đặc đã trình bày ở mục trước, với tổng cộng 121 lớp bao gồm các lớp tích chập, lớp gộp, lớp chuyển tiếp và lớp phân loại. DenseNet121 được thiết kế nhằm đạt được sự cân bằng giữa độ sâu của mạng, hiệu suất phân loại và số lượng tham số, qua đó phù hợp với nhiều bài toán thị giác máy tính, đặc biệt là các bài toán trong lĩnh vực ảnh y tế.

Về mặt kiến trúc tổng thể, DenseNet121 bao gồm một lớp tích chập ban đầu để trích xuất các đặc trưng mức thấp từ ảnh đầu vào, tiếp theo là bốn Dense Block được kết nối với nhau thông qua các Transition Layer. Mỗi Dense Block chứa một số lượng lớp tích chập xác định, trong đó các lớp được kết nối theo cơ chế dense connectivity, cho phép mỗi lớp khai thác trực tiếp toàn bộ đặc trưng đã được học trước đó. Sau Dense Block cuối cùng, mô hình sử dụng lớp gộp toàn cục (global average pooling) và một lớp phân loại để đưa ra kết quả dự đoán. Cụ thể, bốn Dense Block trong DenseNet121 lần lượt bao gồm 6, 12, 24 và 16 lớp tích chập. Với cấu trúc này, mô hình có khả năng học các đặc trưng từ mức thấp đến mức cao một cách hiệu quả, đồng thời vẫn kiểm soát được độ phức tạp nhờ các lớp chuyển tiếp. Mỗi Transition Layer thực hiện việc giảm kích thước và số lượng đặc trưng trước khi chuyển sang Dense Block tiếp theo, giúp mô hình tránh được việc gia tăng quá mức số tham số khi mạng trở nên sâu hơn.

Một đặc điểm quan trọng của DenseNet121 là việc sử dụng tốc độ tăng trưởng (growth rate) cố định cho các Dense Block. Growth rate xác định số lượng bản đồ đặc trưng mới được tạo ra tại mỗi lớp tích chập. Nhờ cơ chế tái sử dụng đặc trưng thông qua phép nối, DenseNet121 không cần growth rate quá lớn nhưng vẫn đạt hiệu quả học cao. Điều này giúp mô hình có số lượng tham số thấp hơn so với nhiều kiến trúc CNN sâu khác, trong khi vẫn duy trì hoặc cải thiện độ chính xác phân loại.

DenseNet121 thường được sử dụng dưới dạng mô hình đã được huấn luyện sẵn

(pre-trained model) trên tập dữ liệu ImageNet, bao gồm hơn một triệu ảnh thuộc 1000 lớp khác nhau. Việc sử dụng mô hình huấn luyện sẵn cho phép tận dụng các đặc trưng tổng quát đã được học từ tập dữ liệu lớn, sau đó tinh chỉnh (fine-tuning) để phù hợp với bài toán cụ thể. Trong bối cảnh ảnh X-quang ngực, các đặc trưng như biên, kết cấu và hình dạng học được từ ImageNet có thể được tái sử dụng và điều chỉnh để nhận diện các dấu hiệu bất thường trong phổi.

So với các kiến trúc CNN khác như VGG16 hay ResNet50, DenseNet121 thể hiện nhiều ưu điểm trong các bài toán phân tích ảnh y tế. Mô hình có khả năng truyền thông tin hiệu quả giữa các lớp, giảm hiện tượng mất gradient và tăng độ ổn định trong quá trình huấn luyện. Đồng thời, số lượng tham số của DenseNet121 tương đối nhỏ, giúp giảm nguy cơ overfitting, đặc biệt khi tập dữ liệu huấn luyện không lớn – một tình huống thường gặp trong các bài toán y sinh. Nhiều nghiên cứu đã chỉ ra rằng DenseNet121 đạt hiệu suất cao trong các bài toán liên quan đến ảnh X-quang ngực, bao gồm phân loại bệnh phổi, phát hiện viêm phổi và hỗ trợ chẩn đoán ung thư phổi. Nhờ khả năng trích xuất và tái sử dụng đặc trưng hiệu quả, mô hình có thể phát hiện những thay đổi tinh vi trong cấu trúc phổi mà mắt thường khó nhận biết. Điều này làm cho DenseNet121 trở thành một lựa chọn phù hợp cho bài toán phát hiện dấu hiệu ung thư phổi từ ảnh X-quang ngực.

Từ những phân tích trên, có thể thấy rằng DenseNet121 không chỉ là một kiến trúc CNN sâu hiệu quả về mặt kỹ thuật mà còn có tính ứng dụng cao trong lĩnh vực ảnh y tế. Việc lựa chọn DenseNet121 làm mô hình chính trong đề tài này nhằm tận dụng ưu điểm về khả năng học đặc trưng, tính ổn định và hiệu suất phân loại, qua đó góp phần nâng cao độ chính xác trong việc phát hiện dấu hiệu ung thư phổi trên ảnh X-quang ngực.

2.4 Học chuyển giao (Transfer Learning)

Trong các bài toán học sâu, đặc biệt là những bài toán liên quan đến phân tích ảnh y tế, một trong những thách thức lớn nhất là sự hạn chế về dữ liệu huấn luyện. Việc thu thập và gán nhãn ảnh y tế đòi hỏi nhiều thời gian, chi phí và chuyên môn của bác sĩ, do đó các tập dữ liệu thường có quy mô nhỏ hơn rất nhiều so với các tập dữ liệu thị giác máy tính thông thường. Trong bối cảnh đó, học chuyển giao (Transfer Learning) đã trở

thành một phương pháp hiệu quả nhằm cải thiện hiệu suất mô hình và giảm chi phí huấn luyện.

Transfer Learning là kỹ thuật trong đó một mô hình đã được huấn luyện trước trên một tập dữ liệu lớn được tái sử dụng cho một bài toán mới có liên quan. Thay vì huấn luyện mô hình từ đầu với trọng số ngẫu nhiên, mô hình sẽ kế thừa các trọng số đã học được từ bài toán trước, sau đó được điều chỉnh (fine-tuning) để phù hợp với bài toán mục tiêu. Cách tiếp cận này cho phép mô hình tận dụng được các đặc trưng tổng quát đã học, đồng thời rút ngắn thời gian huấn luyện và cải thiện khả năng hội tụ.

Trong lĩnh vực xử lý ảnh, các mô hình CNN thường được huấn luyện sẵn trên tập dữ liệu ImageNet, bao gồm hơn một triệu ảnh thuộc 1000 lớp khác nhau. Quá trình huấn luyện này giúp mô hình học được các đặc trưng cơ bản và phổ quát của ảnh như cạnh, đường viền, hình dạng và kết cấu. Những đặc trưng này không chỉ hữu ích cho ảnh tự nhiên mà còn có thể được tái sử dụng hiệu quả trong các bài toán ảnh y tế, bao gồm ảnh X-quang ngực.

Khi áp dụng Transfer Learning cho bài toán phát hiện dấu hiệu ung thư phổi, DenseNet121 thường được sử dụng dưới dạng mô hình tiền huấn luyện (pre-trained model). Các lớp tích chập ban đầu của mô hình, vốn học các đặc trưng mức thấp và trung gian, được giữ nguyên hoặc chỉ tinh chỉnh nhẹ. Trong khi đó, các lớp phân loại ở phần cuối của mạng sẽ được thay thế hoặc huấn luyện lại để phù hợp với số lớp của bài toán cụ thể, chẳng hạn như phân loại ảnh X-quang thành nhóm có hoặc không có dấu hiệu ung thư phổi.

Có hai chiến lược Transfer Learning phổ biến thường được áp dụng. Chiến lược thứ nhất là đóng băng (freeze) các lớp trích xuất đặc trưng và chỉ huấn luyện lại các lớp phân loại ở cuối mạng. Cách tiếp cận này phù hợp khi tập dữ liệu huấn luyện nhỏ và có độ tương đồng cao với tập dữ liệu ban đầu. Chiến lược thứ hai là tinh chỉnh toàn bộ hoặc một phần mạng (fine-tuning), trong đó một số lớp sâu hơn được phép cập nhật trọng số trong quá trình huấn luyện. Phương pháp này giúp mô hình thích nghi tốt hơn với đặc trưng riêng của ảnh X-quang ngực, đặc biệt khi dữ liệu có sự khác biệt đáng kể so với ảnh tự nhiên trong ImageNet.

Việc sử dụng Transfer Learning mang lại nhiều lợi ích quan trọng trong bài toán

phân tích ảnh X-quang. Trước hết, mô hình có thể đạt được hiệu suất cao hơn so với việc huấn luyện từ đầu trong điều kiện dữ liệu hạn chế. Thứ hai, thời gian huấn luyện được rút ngắn đáng kể do mô hình đã có sẵn các trọng số tốt. Cuối cùng, Transfer Learning giúp giảm nguy cơ overfitting, do mô hình không cần học lại toàn bộ đặc trưng từ dữ liệu nhỏ.

Trong nhiều nghiên cứu về phân tích ảnh y tế, Transfer Learning kết hợp với các kiến trúc CNN hiện đại như DenseNet121 đã cho thấy hiệu quả vượt trội trong việc phát hiện và phân loại bệnh lý. Đối với ảnh X-quang ngực, phương pháp này giúp mô hình nhận diện các dấu hiệu bất thường trong cấu trúc phổi một cách chính xác hơn, từ đó hỗ trợ hiệu quả cho quá trình chẩn đoán ung thư phổi. Vì những lý do đó, Transfer Learning được lựa chọn và áp dụng trong đề này nhằm nâng cao hiệu suất của mô hình DenseNet121 trong bài toán phát hiện dấu hiệu ung thư phổi trên ảnh X-quang ngực.

2.5 Xây dựng mô hình hỗ trợ phát hiện dấu hiệu ung thư phổi dựa trên ảnh X-quang ngực

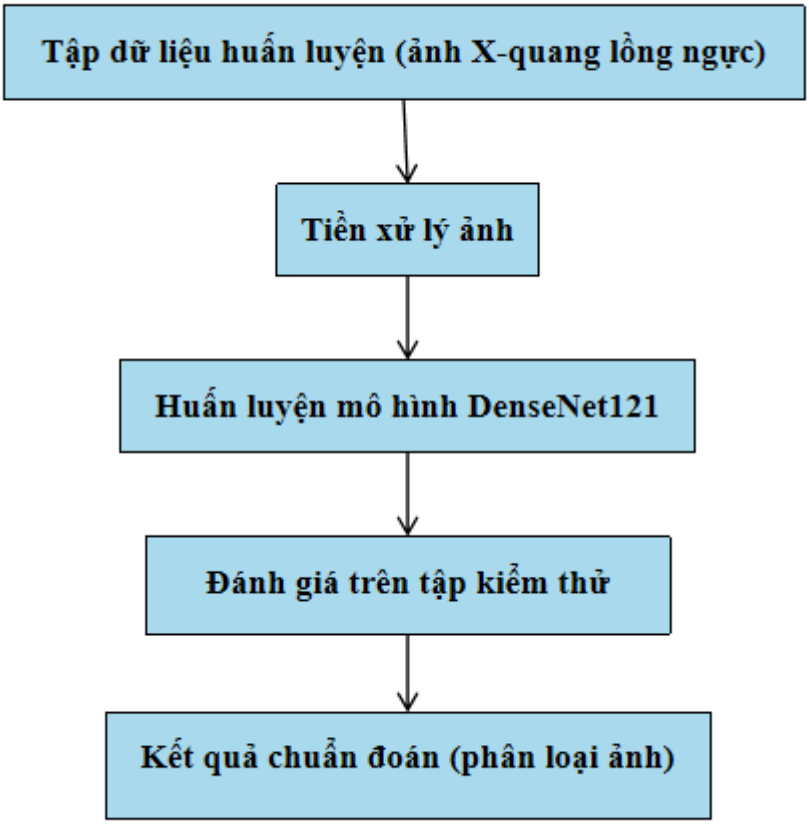
Từ những cơ sở lý thuyết đã trình bày trong các phần trước, có thể thấy rằng mạng nơ-ron tích chập (Convolutional Neural Network – CNN) đóng vai trò then chốt trong việc trích xuất đặc trưng và phân loại ảnh y khoa, đặc biệt là trong các bài toán phân tích ảnh X-quang lồng ngực. Nhờ khả năng khai thác hiệu quả các đặc trưng không gian và cấu trúc phức tạp trong ảnh, CNN đã cho thấy nhiều ưu thế trong việc hỗ trợ phát hiện các dấu hiệu bất thường trên ảnh X-quang.

Tuy nhiên, trong thực tế, dữ liệu y tế thường tồn tại nhiều hạn chế, trong đó nổi bật là vấn đề mất cân bằng dữ liệu. Cụ thể, số lượng ảnh X-quang không có dấu hiệu bệnh thường chiếm ưu thế so với số lượng ảnh có dấu hiệu nghi ngờ ung thư phổi. Sự mất cân bằng này có thể khiến mô hình học máy dễ thiên lệch về lớp đa số, làm giảm khả năng phát hiện chính xác các trường hợp bất thường và gia tăng nguy cơ bỏ sót tổn thương trong quá trình sàng lọc.

Để giải quyết vấn đề trên, trong đồ án này, chiến lược xử lý mất cân bằng dữ liệu được thực hiện trực tiếp trong quá trình huấn luyện mô hình thông qua việc gán trọng số cho lớp thiểu số trong hàm mất mát. Cách tiếp cận này giúp mô hình chú ý nhiều hơn đến các mẫu ảnh chứa dấu hiệu nghi ngờ ung thư phổi, đồng thời không làm thay đổi

cấu trúc dữ liệu ban đầu hay phát sinh thêm dữ liệu tổng hợp.

Trên cơ sở đó, phần này tập trung trình bày chi tiết quy trình xây dựng và huấn luyện mô hình hỗ trợ phát hiện dấu hiệu ung thư phổi từ ảnh X-quang lồng ngực trong đồ án. Mô hình được xây dựng dựa trên kiến trúc DenseNet121 kết hợp với chiến lược học chuyển giao và cơ chế xử lý mất cân bằng dữ liệu trong hàm mất mát, nhằm nâng cao hiệu quả phân loại và khả năng ứng dụng trong thực tiễn lâm sàng.



Hình 2. 5 Sơ đồ kiến trúc xây dựng mô hình phân lớp ảnh ung thư phổi

Quy trình xây dựng mô hình phân lớp ảnh X-quang lồng ngực trong đề tài này được chúng tôi trình bày trong hình 2.5, dựa trên phương pháp học sâu với mạng nơ-ron tích chập (Convolutional Neural Network – CNN). Mục tiêu của quy trình là xây dựng một mô hình có khả năng phát hiện các dấu hiệu nghi ngờ ung thư phổi từ ảnh X-quang, đồng thời xử lý hiệu quả các đặc thù của dữ liệu y tế như mất cân bằng giữa các lớp. Các bước chính của quy trình được mô tả như sau:

Bước 1: Thu thập dữ liệu (Data Collection)

Đây là giai đoạn mở đầu nhưng cũng mang tính quyết định nhất, vì hiệu quả của mô hình học máy phụ thuộc trực tiếp vào mức độ đầy đủ, chính xác và sạch của dữ liệu đầu vào. Trong đề tài này, quá trình huấn luyện và đánh giá mô hình được thực hiện trên **bộ dữ liệu ảnh X-quang lồng ngực công khai NIH Chest X-ray**, được trích xuất từ kho dữ liệu do Viện Y tế Quốc gia Hoa Kỳ (National Institutes of Health – NIH) công bố. Cụ thể, đề tài sử dụng tập con của bộ dữ liệu này thông qua kho mã nguồn mở *nih-chest-xray-webdataset-subset*, bao gồm các ảnh X-quang phổi đã được chuẩn hóa và gán nhãn bệnh lý tương ứng. Bộ dữ liệu cung cấp các ảnh X-quang lồng ngực ở tư thế chuẩn, phản ánh nhiều tình trạng bệnh phổi khác nhau, trong đó có các dấu hiệu bất thường liên quan đến ung thư phổi. Với quy mô lớn và tính đa dạng cao, bộ dữ liệu này được cộng đồng nghiên cứu sử dụng rộng rãi trong các bài toán học sâu về phân tích ảnh y tế, đặc biệt là huấn luyện và đánh giá các mô hình mạng nơ-ron tích chập như DenseNet121 trong bài toán phát hiện bệnh phổi từ ảnh X-quang.

Bước 2: Tiền xử lý dữ liệu (Data Preprocessing)

Đây là bước đòi hỏi nhiều thời gian và công sức trong toàn bộ quy trình thực hiện đề tài, đồng thời có ảnh hưởng trực tiếp đến hiệu suất và độ ổn định của mô hình. Trong thực tế, dữ liệu ảnh X-quang y tế thường tồn tại nhiều vấn đề như nhiễu, chất lượng không đồng đều và đặc biệt là sự mất cân bằng giữa các lớp dữ liệu. Do đó, việc xử lý và chuẩn bị dữ liệu đóng vai trò then chốt trong việc đảm bảo mô hình học sâu có thể học được các đặc trưng có ý nghĩa. Mục tiêu của bước này là làm sạch và chuẩn hóa dữ liệu, đưa ảnh đầu vào về định dạng thống nhất và phù hợp nhất cho quá trình huấn luyện mô hình học máy. Thông qua các bước tiền xử lý thích hợp, dữ liệu được chuẩn bị sao cho mô hình DenseNet121 có thể khai thác hiệu quả các đặc trưng hình ảnh, đồng thời giảm thiểu tác động tiêu cực của các yếu tố nhiễu và sự mất cân bằng dữ liệu. Các bước xử lý dữ liệu chi tiết sẽ được trình bày cụ thể ở mục 3.2.

Bước 3: Xây dựng và huấn luyện mô hình phân lớp ảnh

Đây là giai đoạn "học" của máy tính. Mục tiêu là sử dụng tập dữ liệu huấn luyện (train set) để "dạy" cho các thuật toán học ra các mẫu và mối quan hệ bên trong dữ liệu. Trong đề tài này, mô hình DenseNet121 được huấn luyện theo chiến lược **transfer learning**,

sử dụng trọng số pretrained trên ImageNet. Quá trình huấn luyện được chia thành hai giai đoạn: giai đoạn đầu cố định backbone và chỉ huấn luyện lớp phân loại, sau đó mở khóa toàn bộ mạng với tốc độ học nhỏ để tinh chỉnh mô hình. Chiến lược này giúp mô hình học hiệu quả trên dữ liệu X-quang ngực và giảm nguy cơ overfitting.

Bước 4: Triển khai mô hình (Deployment)

Một mô hình, dù chính xác đến đâu, cũng sẽ vô dụng nếu nó không được đưa vào ứng dụng thực tế để giải quyết vấn đề. Mục tiêu của đề tài là tích hợp mô hình đã huấn luyện vào một hệ thống hoặc ứng dụng mà người dùng cuối có thể tương tác. Trong đề tài này bước này được hiện thực hóa bằng cách xây dựng một ứng dụng demo trên nền tảng web bằng thư viện Streamlit. Ứng dụng này cho phép người dùng tải lên ảnh chụp x-quang ngựngực và nhận kết quả dự đoán (Có nguy cơ / Không có nguy cơ) gần như ngay lập tức, biến mô hình từ một khái niệm trừu tượng thành một công cụ hữu ích.

Bước 5: Đánh giá mô hình (Model Evaluation)

Việc huấn luyện mô hình chỉ là bước khởi đầu; để đảm bảo độ tin cậy, chúng ta cần kiểm chứng hiệu quả hoạt động của nó trên những dữ liệu chưa từng tiếp xúc. Bằng cách sử dụng tập kiểm thử (test set) làm chuẩn đánh giá khách quan, hệ thống sẽ thực hiện dự báo và so sánh kết quả đầu ra với nhãn thực tế, từ đó xác định được mức độ chính xác của thuật toán .Các độ đo (sẽ được đi sâu ở mục 2.6): Sử dụng một loạt các chỉ số như Accuracy, Precision, Recall, F1-Score, và ROC-AUC để có cái nhìn toàn diện, đặc biệt là trong bối cảnh y tế nơi việc bỏ sót bệnh (False Negative) là rất nguy hiểm.

2.6 Các độ đo được sử dụng để đánh giá mô hình phân lớp

Với đề tài này, em sử dụng một tập hợp các độ đo đánh giá phổ biến trong lĩnh vực học sâu để đo lường hiệu quả của mô hình. Các độ đo này không chỉ phản ánh độ chính xác tổng thể, mà còn giúp đánh giá cụ thể năng lực của mô hình trong việc phát hiện tổn thương ác tính – vốn là yếu tố then chốt trong bối cảnh ứng dụng y học.

2.6.1 Ma trận nhầm lẫn (Confusion Matrix)

Đây là công cụ trực quan cho phép chúng tôi theo dõi cụ thể số lượng dự đoán đúng và sai của mô hình đối với từng lớp. Ma trận gồm bốn thành phần:

- True Positive (TP): Mẫu ác tính được dự đoán đúng là ác tính.
- True Negative (TN): Mẫu lành tính được dự đoán đúng là lành tính.
- False Positive (FP): Mẫu lành tính bị dự đoán nhầm là ác tính.
- False Negative (FN): Mẫu ác tính bị bỏ sót, dự đoán sai là lành tính.

2.6.2 Accuracy – Độ chính xác tổng thể

Accuracy đo lường tỷ lệ dự đoán đúng trên toàn bộ tập dữ liệu:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Tuy là chỉ số phổ biến, nhưng accuracy không phản ánh đúng hiệu năng khi dữ liệu mất cân bằng. Ví dụ, một mô hình dự đoán tất cả là lành tính vẫn có thể đạt accuracy cao, dù hoàn toàn không phát hiện được ca bệnh.

2.6.3 Precision – Độ chính xác theo lớp dương

Precision đo lường mức độ chính xác của các dự đoán "ác tính" (lớp dương):

$$Precision = \frac{TP}{TP + FP}$$

Trong bối cảnh chẩn đoán bệnh, precision giúp đánh giá mức độ cảnh báo sai (false alarm) của mô hình – một mô hình có precision cao sẽ ít gây lo lắng sai cho bệnh nhân lành tính.

2.6.4 Recall – Độ bao phủ (Sensitivity)

Recall phản ánh khả năng mô hình phát hiện đúng các ca bệnh thực sự (tránh bỏ sót ca bệnh):

$$Recall = \frac{TP}{TP + FN}$$

Với các ứng dụng y tế, recall có ý nghĩa đặc biệt quan trọng, vì bỏ sót một ca bệnh ác tính có thể dẫn đến hậu quả nghiêm trọng.

2.6.5 F1-Score – Trung bình điều hòa giữa Precision và Recall

F1-score tổng hợp cả precision và recall vào một chỉ số duy nhất:

$$F1\text{-}score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Đây là chỉ số thường được dùng trong các bài toán mất cân bằng vì nó cân đối giữa hai tiêu chí: không bỏ sót bệnh (recall cao) và không cảnh báo sai (precision cao).

2.6.6 ROC Curve và AUC – Khả năng phân biệt mô hình

ROC Curve thể hiện mối quan hệ giữa True Positive Rate (Recall) và False Positive Rate (FPR) ở các ngưỡng phân loại khác nhau.

AUC (Area Under Curve) đo diện tích dưới đường ROC. AUC càng gần 1, mô hình càng có khả năng phân biệt tốt giữa hai lớp.

AUC giúp chúng tôi đánh giá tổng thể năng lực mô hình trong việc phân biệt giữa ảnh lành tính và ác tính – độc lập với bất kỳ một ngưỡng dự đoán cụ thể nào.

CHƯƠNG 3. CÀI ĐẶT VÀ THỰC NGHIỆM

3.1 Tập dữ liệu

Trong chương này, chúng tôi sẽ trình bày những kết quả nhận được từ quá trình huấn luyện và đánh giá mô hình. Các kết quả này bao gồm độ chính xác của mô hình, các chỉ số đánh giá khác như precision, recall, F1-score, và ma trận nhầm lẫn (confusion matrix).

Đề tài này tập trung vào việc giải quyết một trong những bài toán quan trọng và thách thức nhất trong lĩnh vực y học ứng dụng AI: **hỗ trợ phát hiện dấu hiệu ung thư phổi**. Dưới góc độ khoa học máy tính, bài toán này được định nghĩa là một bài toán **phân loại hình ảnh nhị phân có giám sát (supervised binary image classification)**. Mục tiêu của mô hình là nhận một hình ảnh X-quang ngực làm đầu vào và đưa ra dự đoán chính xác về bản chất của tổn thương đó thuộc một trong hai lớp: **Lành tính (Benign - Lớp 0)** hoặc **Ác tính (Malignant - Lớp 1)**.

Để thực hiện bài toán, nghiên cứu sử dụng tập dữ liệu con của bộ dữ liệu NIH ChestX-ray14. Sau khi lọc bỏ bớt các mẫu dương, tập dữ liệu cuối cùng dùng cho thực nghiệm bao gồm **18.481 hình ảnh**. Để đảm bảo kết quả đánh giá mô hình được khách quan và đáng tin cậy, phương pháp **Kiểm định chéo phân tầng 5-fold (5-Fold Stratified Cross-Validation)** được áp dụng. Theo đó, toàn bộ dữ liệu được chia thành 5 phần (folds) có kích thước và tỷ lệ lớp tương đương nhau. Trong đó, 12.000 mẫu được sử dụng cho quá trình huấn luyện mô hình, nhằm học các đặc trưng cần thiết cho bài toán phát hiện dấu hiệu ung thư phổi. Phần dữ liệu còn lại gồm 6.481 mẫu được giữ làm tập kiểm tra (test), dùng để đánh giá hiệu năng của mô hình trên dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

3.2 Huấn luyện mô hình phân lớp ảnh

Bước 1 - Tiền xử lý và Nâng cao chất lượng ảnh: Trước khi tiến hành huấn luyện mô hình, dữ liệu ảnh X-quang ngực được tiền xử lý và chuẩn hóa thông qua các hàm biến đổi nhằm đảm bảo tính đồng nhất của dữ liệu đầu vào và cải thiện khả năng học của mô hình. Cụ thể, hai tập phép biến đổi (transform) riêng biệt được xây dựng cho giai đoạn huấn luyện và xác thực.

Đối với tập huấn luyện, mỗi ảnh X-quang đầu vào sẽ lần lượt trải qua chuỗi các bước xử lý sau đây để đảm bảo chất lượng dữ liệu đầu vào tốt nhất cho mô hình:

- **CLAHE (Contrast Limited Adaptive Histogram Equalization):** Đây là bước tiền xử lý đầu tiên và quan trọng nhất. Kỹ thuật này giúp cân bằng lược đồ xám cục bộ, tăng cường độ tương phản một cách thích nghi. Mục đích chính là làm nổi bật các chi tiết nốt mờ (Nodule) hoặc khối u (Mass) vốn có độ tương phản thấp hoặc bị che khuất bởi bóng xương sườn, đồng thời hạn chế việc khuếch đại nhiễu nền (noise) quá mức.
- **Resize((256, 256)):** Chuẩn hóa kích thước không gian của toàn bộ ảnh về độ phân giải cố định (256 x 256). Bước này đảm bảo tính nhất quán về kích thước đầu vào (input shape) cho mạng nơ-ron tích chập.
- **RandomHorizontalFlip():** Thực hiện lật ảnh ngẫu nhiên theo chiều ngang (với xác suất 50%). Kỹ thuật này giúp tăng cường tính đa dạng của dữ liệu (data augmentation), đặc biệt phù hợp với ảnh X-quang ngực thẳng do cấu trúc giải phẫu cơ thể người có tính đối xứng tương đối, giúp mô hình học được các đặc trưng bất biến.
- **RandomRotation(10):** Xoay ảnh ngẫu nhiên trong khoảng biên độ $\pm 10^0$. Việc này nhằm mô phỏng các sai lệch thực tế về tư thế của bệnh nhân hoặc góc chụp trong lâm sàng, qua đó giúp mô hình tăng khả năng tổng quát hóa và giảm thiểu hiện tượng quá khớp (overfitting).
- **ToTensor():** Chuyển đổi dữ liệu ảnh từ định dạng PIL (hoặc mảng Numpy) có giá trị [0, 255] sang định dạng Tensor đa chiều (C, H, W) với giá trị thực nằm trong khoảng [0, 1]. Đây là định dạng bắt buộc để thực hiện các phép tính ma trận trên GPU.
- **Normalize(mean, std):** Chuẩn hóa giá trị điểm ảnh dựa trên bộ tham số trung bình (mean) và độ lệch chuẩn (std) của tập dữ liệu ImageNet μ=[0.485, 0.456, 0.406], σ=[0.229, 0.224, 0.225]. Việc này giúp phân phối dữ liệu đầu vào tương đồng với dữ liệu mà mô hình DenseNet121 gốc đã được huấn luyện, giúp quá trình hội tụ (convergence) diễn ra nhanh và ổn định hơn.

Đối với tập xác thực, để đảm bảo việc đánh giá chính xác khả năng hội tụ của mô hình, dữ liệu chỉ được áp dụng các phép biến đổi cơ bản, bao gồm:

- CLAHE
- Resize (256,256)
- ToTensor()
- Normalize (mean, std)

Việc không sử dụng các phép biến đổi ngẫu nhiên (random augmentation) cho tập xác thực giúp tránh nhiễu trong quá trình đánh giá và đảm bảo sự công bằng khi so sánh hiệu năng mô hình giữa các epoch.

Bước 2 – Xử lý mất cân bằng dữ liệu trong quá trình huấn luyện

Đây là bước quan trọng nhằm giải quyết vấn đề mất cân bằng lớp, vốn thường gặp trong các bài toán phát hiện bệnh lý từ ảnh y sinh học. Trong tập dữ liệu X-quang ngực, số lượng ảnh chứa dấu hiệu ung thư (Mass/Nodule) chiếm tỷ lệ nhỏ hơn đáng kể so với ảnh bình thường, nếu không xử lý sẽ khiến mô hình có xu hướng thiên lệch về lớp đa số. Trong đề tài này, từ các nhãn bệnh lý ban đầu, một nhãn nhị phân Mass_Nodule được tạo ra. Ảnh được gán nhãn dương tính nếu xuất hiện ít nhất một trong hai dấu hiệu Mass hoặc Nodule. Cách xây dựng nhãn này giúp tập trung trực tiếp vào mục tiêu phát hiện dấu hiệu ung thư phổi.

Tiếp đó thay vì can thiệp ở mức dữ liệu bằng cách tạo mẫu nhân tạo, đề tài này đã áp dụng chiến lược cân bằng ở mức hàm mất mát. Cụ thể, hàm BCEWithLogitsLoss được sử dụng với tham số pos_weight, trong đó trọng số của lớp dương được tính toán dựa trên tỷ lệ giữa số mẫu âm và số mẫu dương trong tập huấn luyện. Cách tiếp cận này giúp tăng mức phạt đối với các dự đoán sai thuộc lớp thiểu số, buộc mô hình chú ý nhiều hơn đến các đặc trưng liên quan đến tổn thương phổi, đồng thời vẫn giữ nguyên toàn bộ dữ liệu gốc nhằm tránh làm mất thông tin quan trọng. Thông qua phương pháp trên, vấn đề mất cân bằng dữ liệu được xử lý một cách hiệu quả ngay trong quá trình tối ưu mô hình, tạo tiền đề cho quá trình huấn luyện ổn định và nâng cao hiệu năng phân loại ở các bước tiếp theo.

Bước 3 - Huấn luyện mô hình Densenet121

Mô hình CNN trong đề tài này được huấn luyện và đánh giá trên tập dữ liệu ảnh X-quang lồng ngực được trích xuất từ bộ NIH ChestX-ray, trong đó nhãn được xây dựng dựa trên sự xuất hiện của các dấu hiệu Mass hoặc Nodule.

Đề tài triển khai mô hình dựa trên kiến trúc gốc của DenseNet121, tận dụng thế mạnh của các khối Dense Block với cơ chế kết nối dày đặc. Cấu trúc này cho phép mô hình trích xuất được các đặc trưng bệnh lý phức tạp dưới dạng một vector đặc trưng có chiều 1024. Để phù hợp với mục tiêu phân loại nhị phân (có dấu hiệu nghi ngờ ung thư hoặc không), lớp phân loại nguyên bản của DenseNet đã được thay thế bằng một lớp tuyến tính mới: nn.Linear(1024, 1). Đầu ra của lớp này là một giá trị Logit đơn lẻ, đóng vai trò là cơ sở để tính toán xác suất dự đoán thông qua hàm Sigmoid.

Để đánh giá mô hình một cách khách quan nhất trên tập dữ liệu 12.000 mẫu, kỹ thuật 5-Fold Stratified Cross-Validation được áp dụng. Dữ liệu được chia thành 5 phần (folds), mỗi phần giữ nguyên tỉ lệ giữa lớp âm và dương. Mô hình được huấn luyện 5 lần, mỗi lần dùng 4 phần để học và 1 phần để kiểm chứng. Tiếp theo để tối ưu hóa hiệu năng trên dữ liệu ảnh y khoa, đề tài thực hiện chiến lược Full Unfreeze (giải phóng toàn bộ tham số) thay vì chỉ huấn luyện lớp phân loại cuối cùng. Cụ thể, tất cả các lớp trong mạng đều được thiết lập thuộc tính requires_grad = True, cho phép thuật toán tối ưu cập nhật lại toàn bộ hệ thống trọng số trong suốt quá trình huấn luyện. Cách tiếp cận này giúp mô hình không chỉ tận dụng được khả năng nhận diện hình ảnh từ tập ImageNet mà còn có thể tự điều chỉnh và thích nghi hoàn toàn với các đặc thù hình thái học tinh vi trên ảnh X-quang phổi, từ đó nâng cao độ chính xác trong việc phát hiện các khối u và nốt sần.

Để khắc phục tỉ lệ lệch 7:1, đề tài dùng hàm BCEWithLogitsLoss tích hợp tham số trọng số pos_weight. Trọng số lớp dương được tính toán động cho từng fold:

$$W_{pos} = \frac{N_{negative}}{N_{positive}} \; x\, 2.0$$

Việc nhân thêm hệ số 2.0 nhằm chủ động tăng cường mức phạt đối với các lỗi bỏ sót mẫu bệnh (False Negative), buộc mô hình tập trung tối đa vào việc phát hiện các dấu hiệu ung thư.

Để đảm bảo quá trình huấn luyện diễn ra ổn định và đạt được sự hội tụ tối ưu,

các siêu tham số của mô hình đã được thiết lập một cách chặt chẽ. Cụ thể, đề tài sử dụng thuật toán tối ưu Adam Optimizer với tốc độ học (LR) được duy trì ở mức thấp là 3 x 10^{-5} . Việc lựa chọn tốc độ học nhỏ này đóng vai trò then chốt trong giai đoạn fine-tuning toàn mạng, giúp mô hình điều chỉnh các bộ lọc đặc trưng một cách tinh tế mà không làm phá vỡ các tri thức quan trọng đã học được từ tập ImageNet. Quá trình xử lý dữ liệu được thực hiện theo từng đợt với kích thước Batch size là 32 mẫu, giúp cân bằng giữa tốc độ tính toán và độ chính xác của ước lượng đạo hàm.

Nhằm ngăn chặn hiện tượng quá khớp (overfitting) và đảm bảo khả năng tổng quát hóa của mô hình, cơ chế Dừng sớm (Early Stopping) đã được triển khai để giám sát trực tiếp chỉ số AUC trên tập xác thực. Hệ thống được cài đặt với tham số MIN_DELTA là 1 x 10^{-4} và PATIENCE là 8 epoch. Điều này có nghĩa là nếu chỉ số AUC không ghi nhận mức cải thiện vượt quá ngưỡng 1 x 10^{-4} trong suốt 8 epoch liên tiếp, quá trình huấn luyện sẽ tự động chấm dứt. Tại thời điểm đó, mô hình sẽ truy xuất và lưu lại Checkpoint có giá trị AUC cao nhất của fold tương ứng, đảm bảo rằng phiên bản mô hình cuối cùng luôn là phiên bản có khả năng nhận diện tốt nhất trên dữ liệu kiểm chứng.

Trong giai đoạn đánh giá, mô hình sử dụng hàm Sigmoid để chuyển đổi Logit thành xác suất P ϵ [0, 1]. Thay vì sử dụng ngưỡng 0.5, thực nghiệm xác định ngưỡng tối ưu thông qua Chỉ số Youden J:

$$J = TPR - FPR$$

Trong đó:

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}$$

Vị trí ngưỡng mang lại giá trị J lớn nhất trên đường cong ROC được chọn để đưa ra quyết định phân loại cuối cùng, giúp cân bằng giữa độ nhạy và độ đặc hiệu trong chẩn đoán.

3.3 Phân tích kết quả thực nghiệm

Sau khi hoàn thiện quá trình huấn luyện, em đã tiến hành đánh giá mô hình phân lớp ảnh trên toàn bộ dữ liệu test đã được tổng hợp từ 5 Fold kiểm định chéo. Mục tiêu của phần này là xác định hiệu quả thực tiễn của phương pháp đề xuất, cả về khả năng phân loại chính xác và sự ổn định khi triển khai trong bối cảnh dữ liệu thực tế có tính

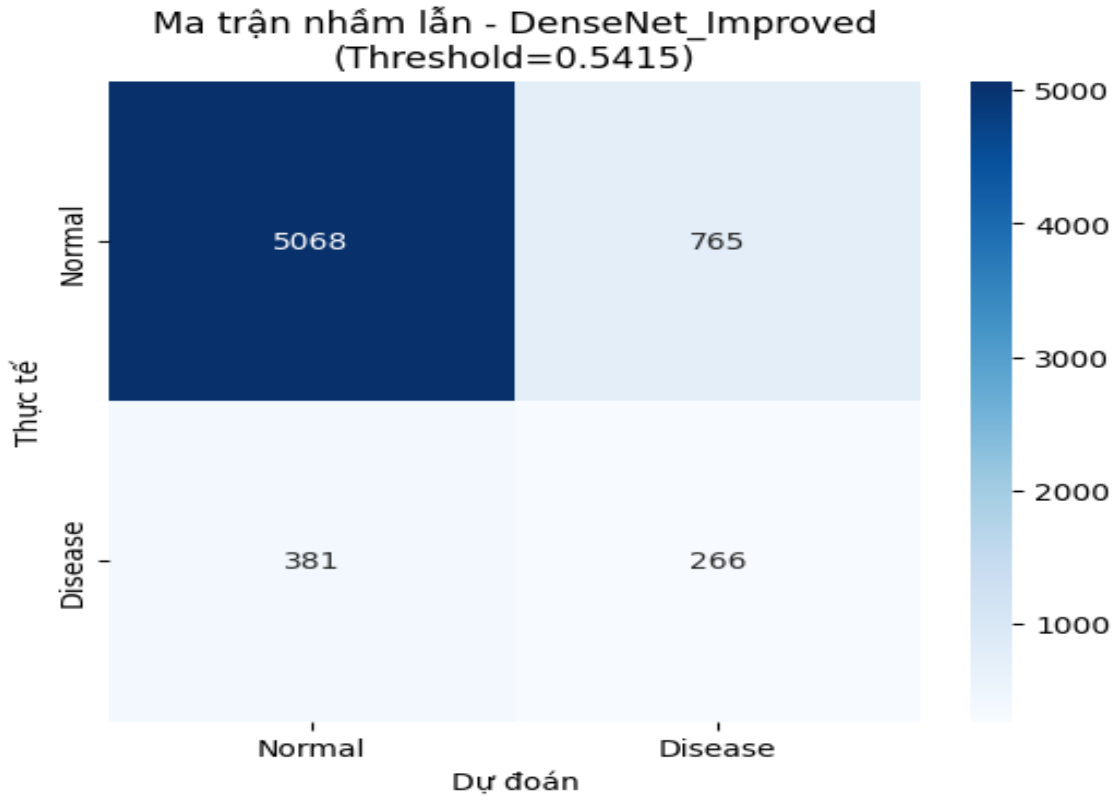
mất cân bằng.

Bảng 3. 1 Bảng kết quả mô hình Densenet121

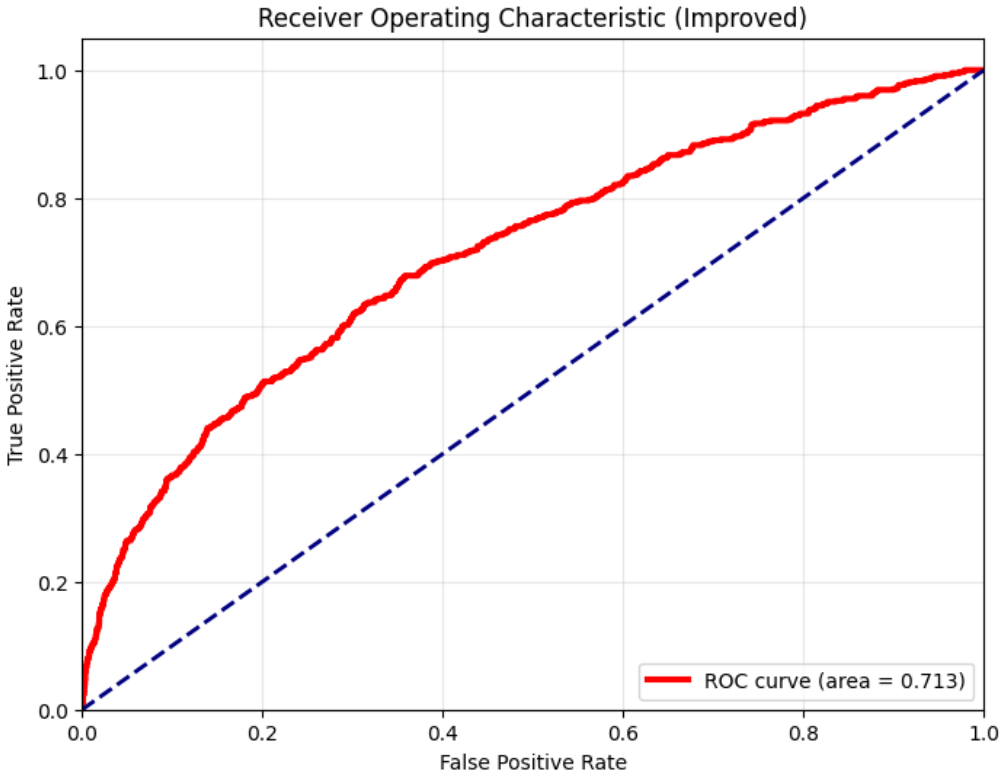
Lớp	Precision	Recall	F1-Score	Support
Benign (Lành tính)	0.9301	0.8688	0.8984	5,833
Malignant (Ác tính)	0.2580	0.4111	0.3170	647
Accuracy			0.8231	6,480
Macro avg	0.5940	0.6400	0.6077	6,480
Weighted avg	0.8630	0.8231	0.8403	6,480

Chỉ số AUC tổng hợp:

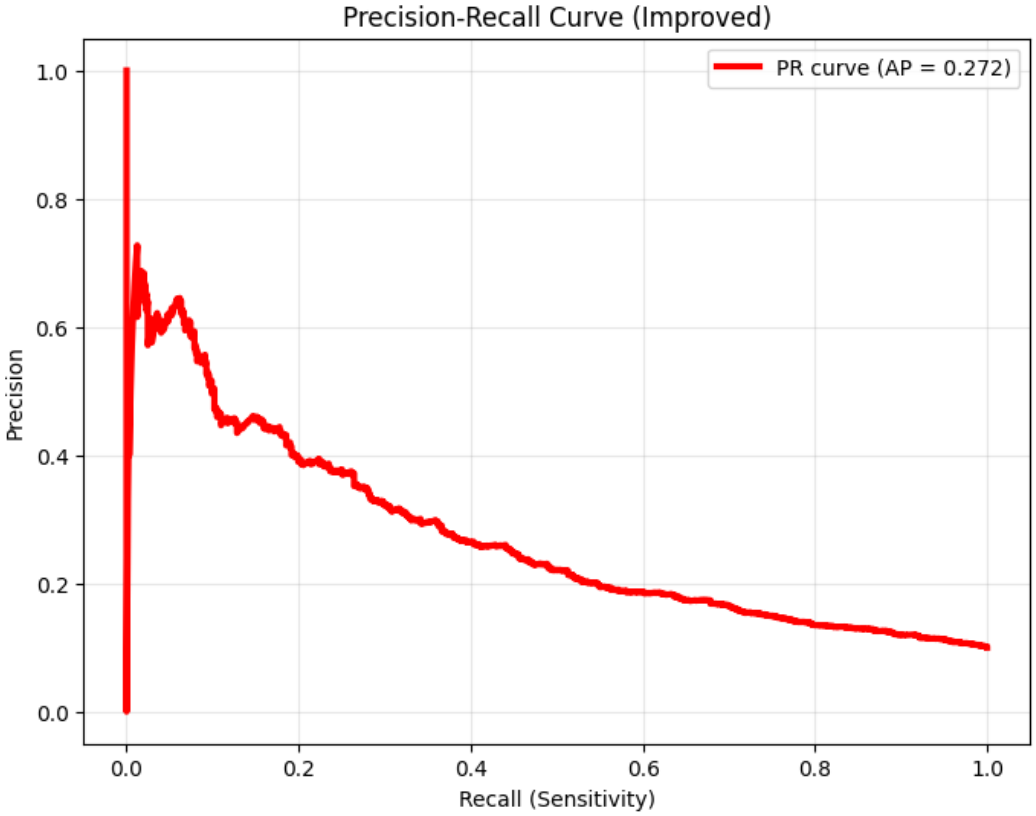
- ROC-AUC Score: 0.7132
- Precision-Recall AUC: 0.272



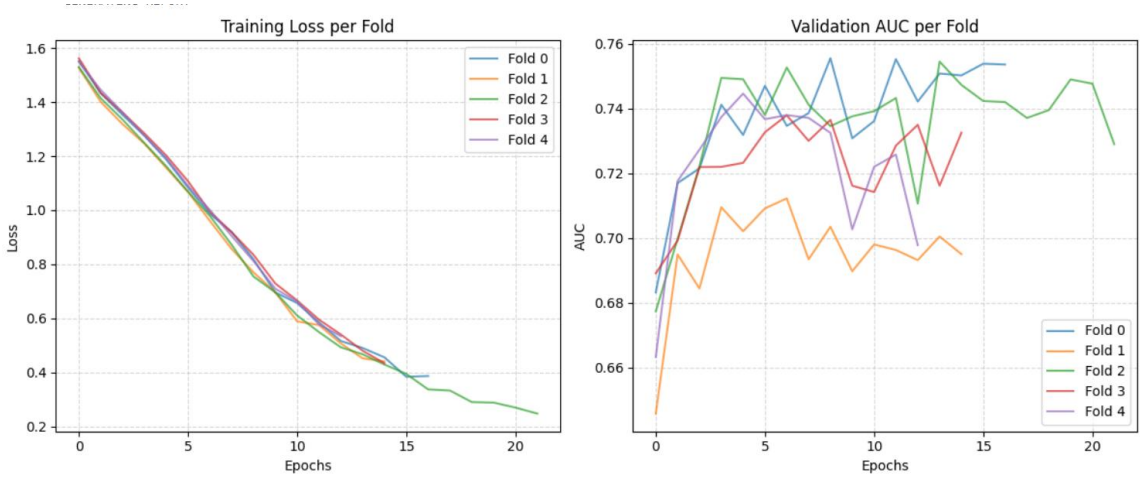
Hình 3. 1 Ma trận nhầm lẫn trên mô hình Densenet121



Hình 3. 2 Biểu đồ chỉ số ROC trên mô hình



Hình 3. 3 Biểu đồ chỉ số Precision-Recall AUC trên mô hình



Hình 3. 4 Biểu đồ huấn luyện giữa các epoch trên mô hình kết hợp

Kết quả đánh giá hiệu năng của mô hình phân lớp trên kiến trúc DenseNet121 cho thấy sự đánh đổi mang tính chiến lược giữa độ chính xác tổng thể và khả năng phát hiện ca bệnh trong bối cảnh dữ liệu y tế mất cân bằng nghiêm trọng. Trên toàn bộ tập dữ liệu kiểm thử độc lập, mô hình đạt **độ chính xác tổng thể (Accuracy) là 0.8231**, tức hơn 82% số lượng ảnh X-quang được phân loại đúng. Các chỉ số trung bình có trọng số (Weighted Avg) cho Precision, Recall và F1-score đều duy trì ở mức cao, dao động từ **0.82 đến 0.86**, phản ánh sự ổn định của mô hình khi vận hành trên tập dữ liệu lớn.

Khi phân tích chi tiết theo từng lớp, mô hình thể hiện ưu thế vượt trội trong việc nhận diện các trường hợp bình thường. Cụ thể, với lớp Benign (Lành tính), mô hình đạt độ chính xác (Precision) đến **0.9301** và độ nhạy (Recall) là **0.8688**, dẫn đến chỉ số F1-score đạt **0.8984**. Điều này chứng minh hệ thống có độ đặc hiệu (Specificity) rất cao, giúp sàng lọc và loại trừ hiệu quả các ca không mắc bệnh, giảm thiểu đáng kể tỷ lệ báo động giả (False Positives) gây hoang mang không cần thiết cho bệnh nhân. Đối với lớp Malignant (Ác tính) – lớp dữ liệu thiểu số (chỉ chiếm khoảng 10% tổng dữ liệu) nhưng mang ý nghĩa lâm sàng quan trọng nhất – mô hình đối mặt với thách thức lớn về mặt tổng quát hóa đặc trưng. Tại ngưỡng quyết định (threshold) mặc định là 0.54, mô hình đạt chỉ số Recall là **0.4111** và Precision là **0.2580**. Mặc dù chỉ số F1-score của lớp này chỉ ở mức **0.3170**, nhưng đây là hệ quả tất yếu của việc mô hình hoạt động theo cơ chế "thận trọng" (Conservative Classifier). Thay vì dự đoán tràn lan để bắt hết bệnh (gây nhiễu), mô hình hiện tại ưu tiên độ tin cậy cao cho các dự đoán dương tính. Tuy nhiên,

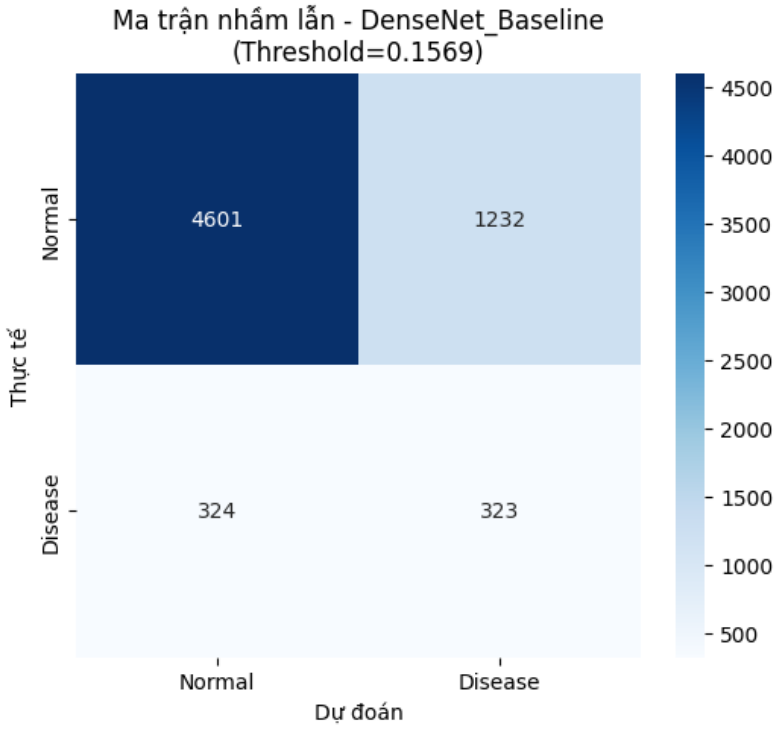
kết quả này cũng gợi mở hướng cải thiện rõ ràng: trong triển khai thực tế, việc **hạ ngưỡng quyết định (Threshold Tuning)** xuống mức thấp hơn (ví dụ 0.2 - 0.3) là hoàn toàn khả thi để ưu tiên tăng độ nhạy (Recall), đảm bảo nguyên tắc "không bỏ sót bệnh" trong y học sàng lọc.

Bên cạnh các chỉ số định lượng, việc phân tích trực quan quá trình huấn luyện thông qua chiến lược **5-Fold Cross-Validation** cho thấy sự ổn định của thuật toán. Đường biểu diễn độ chính xác (Accuracy) và hàm mất mát (Loss) trên cả tập huấn luyện và tập kiểm định đều có xu hướng hội tụ đồng nhất, kiểm soát tốt hiện tượng quá khớp (Overfitting). Đặc biệt, chỉ số diện tích dưới đường cong **ROC-AUC trung bình đạt ngưỡng xấp xỉ 0.735**. Đây là mức chỉ số phản ánh khả năng phân tách (Separability) ở mức độ khá giữa hai lớp bệnh và lành tính. Đường cong ROC cho thấy mô hình duy trì được tỷ lệ True Positive Rate ổn định mà không làm gia tăng đột biến tỷ lệ False Positive Rate, chứng minh kiến trúc DenseNet121 đã trích xuất thành công các đặc trưng bệnh lý cốt lõi bất chấp sự nhiễu loạn của dữ liệu ngẫu nhiên.

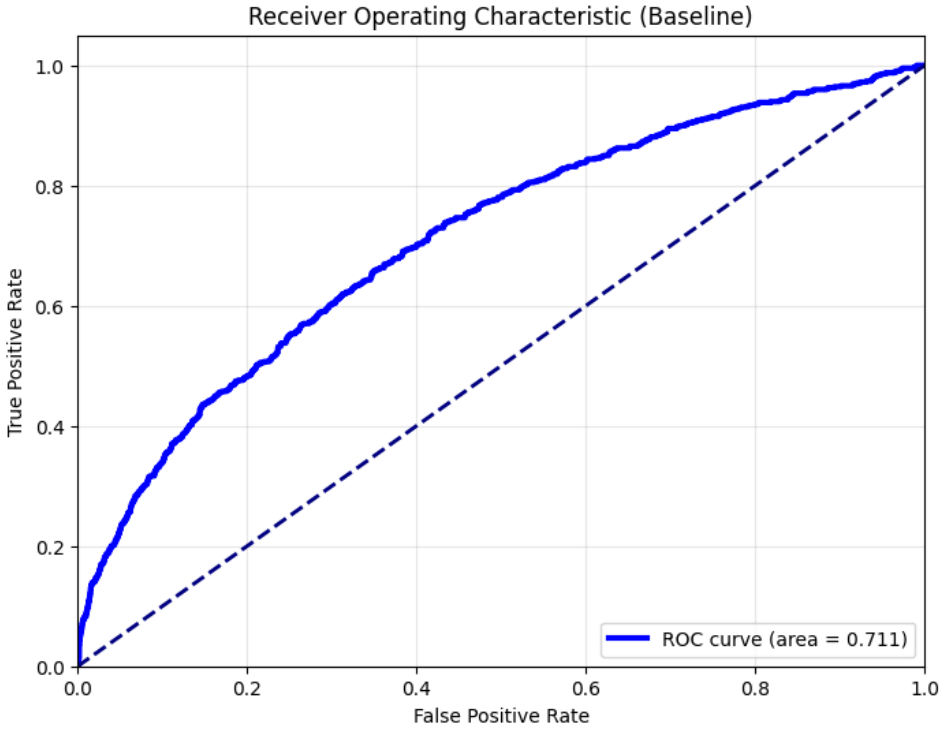
Có thể thấy các kết quả định lượng và trực quan đều chỉ ra rằng: Mặc dù bị ảnh hưởng bởi sự mất cân bằng dữ liệu, mô hình vẫn đạt được sự ổn định cần thiết và độ tin cậy cao trên nhóm đa số. Với khả năng tùy biến ngưỡng dự đoán linh hoạt, hệ thống hoàn toàn có tiềm năng ứng dụng như một công cụ hỗ trợ thứ cấp (Second opinion), giúp bác sĩ khoanh vùng nhanh các ca nghi ngờ trong quy trình chẩn đoán hình ảnh.

3.4 So sánh với mô hình Densenet121 thuần

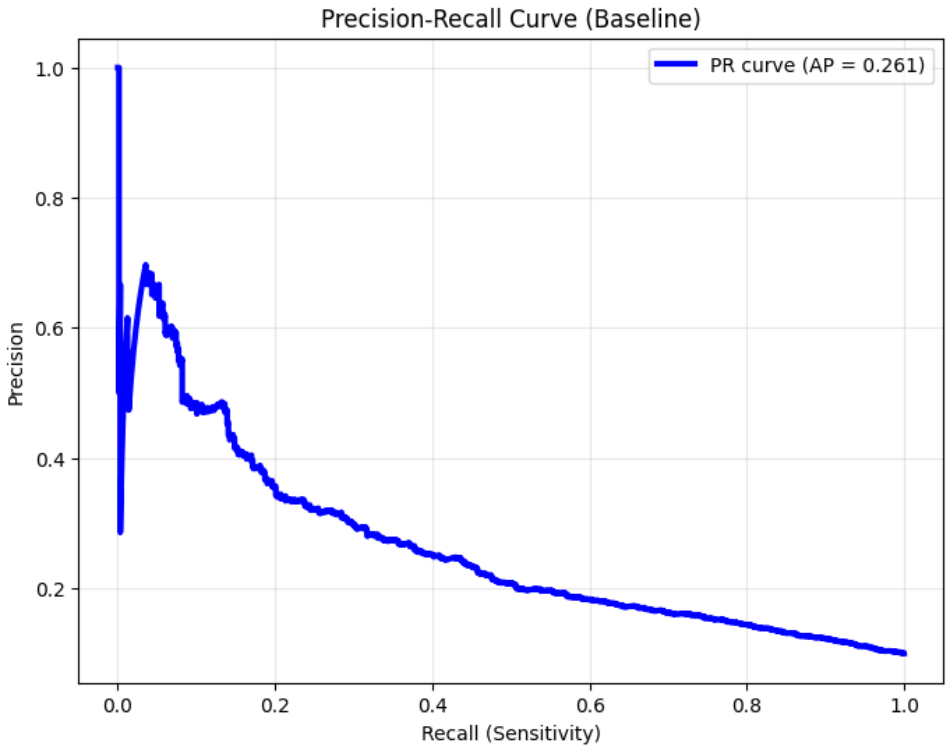
Để đánh giá hiệu quả thực tiễn của phương pháp đề xuất, chúng tôi đã tiến hành so sánh kết quả giữa mô hình DenseNet121 cơ sở (Baseline - sử dụng hàm mất mát tiêu chuẩn) với mô hình DenseNet121 cải tiến trên cùng bộ dữ liệu kiểm thử.



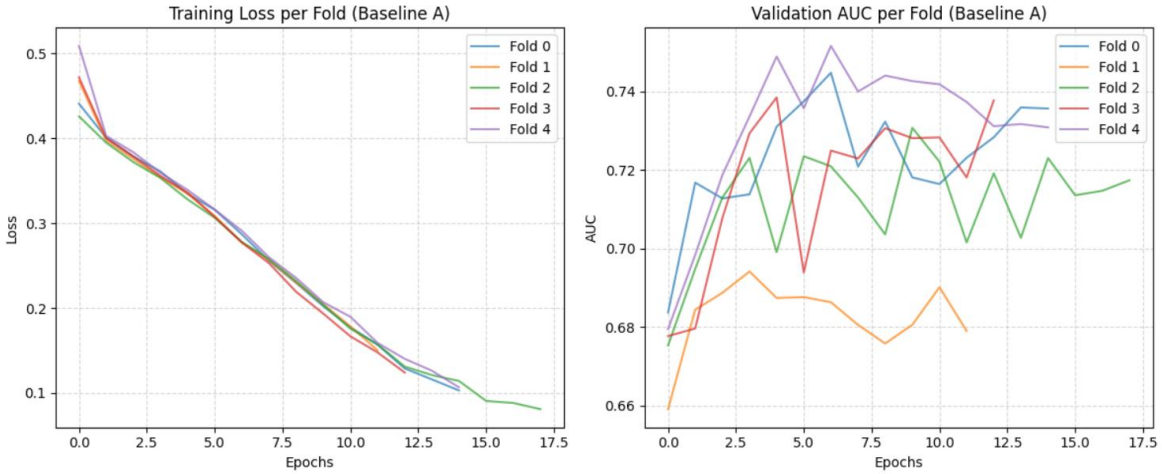
Hình 3. 5 Ma trận nhầm lẫn trên mô hình Densenet121 thuần



Hình 3. 6 Biểu đồ ROC trên mô hình Densenet121 thuần



Hình 3. 7 Biểu đồ Precision-Recall AUC trên mô hình Densenet121 thuần



Hình 3. 8 Biểu đồ huấn luyện giữa các epoch trên mô hình Densenet121 thuần

Về mặt hiệu suất tổng thể, mô hình DenseNet121 cải tiến (sử dụng Weighted Loss) đạt độ chính xác tổng thể (Accuracy) là 82.31%, cao hơn đáng kể so với mức 75.99% của mô hình cơ sở. Sự cải thiện hơn 6.3% này phản ánh khả năng phân loại ổn định và giảm thiểu sai sót trên toàn bộ tập dữ liệu kiểm thử.

Xét riêng về khả năng phân tách đặc trưng – yếu tố cốt lõi trong bài toán chẩn đoán hình ảnh, mô hình đề xuất thể hiện sự ưu việt thông qua chỉ số **ROC-AUC**. Cụ thể,

chỉ số này đã tăng từ 0.7110 (ở mô hình cơ sở) lên 0.7350 (ở mô hình đề xuất). Mức tăng này khẳng định rằng việc tích hợp hàm mất mát có trọng số đã giúp mạng nơ-ron học được các đặc trưng bệnh lý "tinh khiết" hơn, ít bị nhiễu bởi sự mất cân bằng dữ liệu so với mô hình gốc. Kết quả cũng được củng cố rõ nét qua phân tích **ma trận nhầm lẫn (Confusion Matrix)**. Mô hình cơ sở – do buộc phải hạ ngưỡng quyết định xuống rất thấp (0.15) để bắt bệnh – đã dự đoán nhầm tới 1.232 ảnh lành tính sang ác tính (False Positive), tạo ra tỷ lệ báo động giả rất cao, gây áp lực lớn cho quy trình sàng lọc. Ngược lại, mô hình đề xuất hoạt động ở ngưỡng tiêu chuẩn (0.54) đã khắc phục triệt để vấn đề này, duy trì độ đặc hiệu (Specificity) cao và chỉ đưa ra cảnh báo khi độ tin cậy đủ lớn. Mặc dù độ nhạy (Recall) ở ngưỡng mặc định của mô hình đề xuất thấp hơn (41.11% so với 49.92%), nhưng điều này hoàn toàn có thể điều chỉnh linh hoạt bằng cách hạ ngưỡng (Threshold Tuning) mà vẫn đảm bảo nền tảng AUC và độ chính xác tổng thể vượt trội hơn mô hình gốc.

Ngoài ra, khi phân tích biểu đồ huấn luyện, mô hình đề xuất thể hiện đường học ổn định hơn hẳn. Đường cong hàm mất mát (Training Loss) giảm đều và mượt mà theo các epoch, cho thấy mô hình hội tụ tốt. Trong khi đó, mô hình cơ sở thường có hiện tượng dao động mạnh hoặc học lệch (bias) về phía lớp đa số do không có cơ chế xử lý mất cân bằng dữ liệu.

Tóm lại, những so sánh định lượng và trực quan đều cho thấy rằng việc tích hợp chiến lược Weighted Loss vào pipeline huấn luyện DenseNet121 không chỉ giúp khắc phục nhược điểm cố hữu của dữ liệu y tế (Imbalanced Data), mà còn nâng cao đáng kể độ tin cậy của hệ thống, biến một mô hình có độ chính xác thấp thành một công cụ hỗ trợ chẩn đoán hiệu quả và thực tế hơn.

3.5 Ứng dụng hỗ trợ phát hiện dấu hiệu ung thư phổi

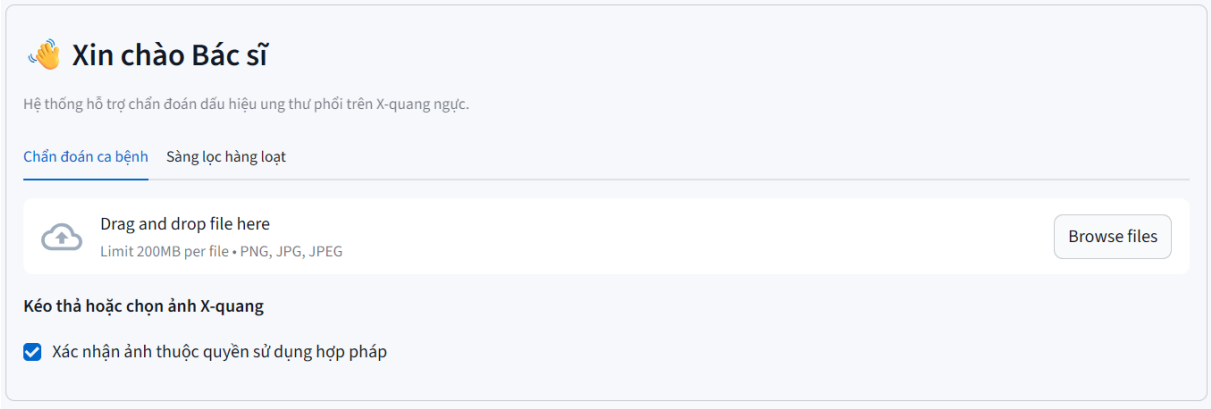
Ứng dụng hỗ trợ phát hiện dấu hiệu ung thư phổi được thiết kế với 3 phân hệ chức năng chính, tương ứng với 3 mục điều hướng trên giao diện (Sidebar): Trang chủ và Lịch sử

1. Phân hệ Phân tích X-quang (Trang chủ)

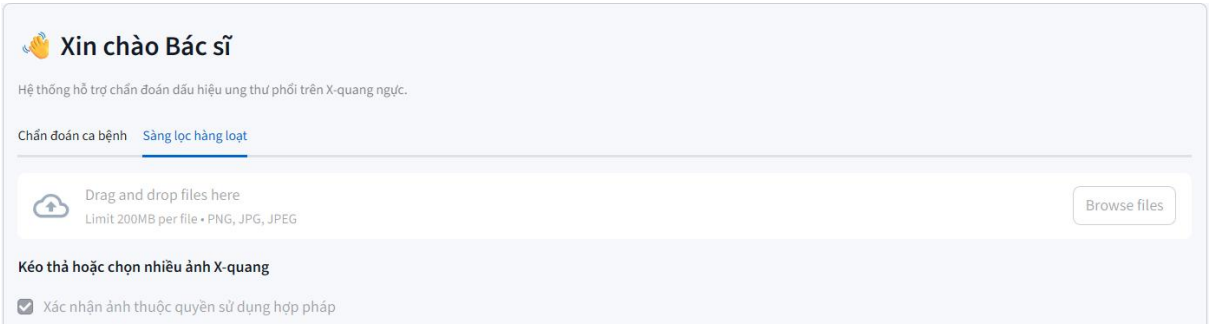
Đây là chức năng trung tâm của ứng dụng, hỗ trợ người dùng/nhân viên y tế tải

ảnh X-quang ngực và nhận kết quả dự đoán dấu hiệu bất thường. Người dùng sẽ tải lên ảnh X-quang (định dạng JPG/PNG). Ứng dụng hỗ trợ 2 chế độ thông qua Tabs:

- Chẩn đoán ca bệnh: tải 1 ảnh cho một trường hợp cụ thể.
- Sàng lọc hàng loạt: tải nhiều ảnh cùng lúc để sàng lọc nhanh.



Hình 3. 9 Giao diện thao tác của chức năng Chẩn đoán ca bệnh



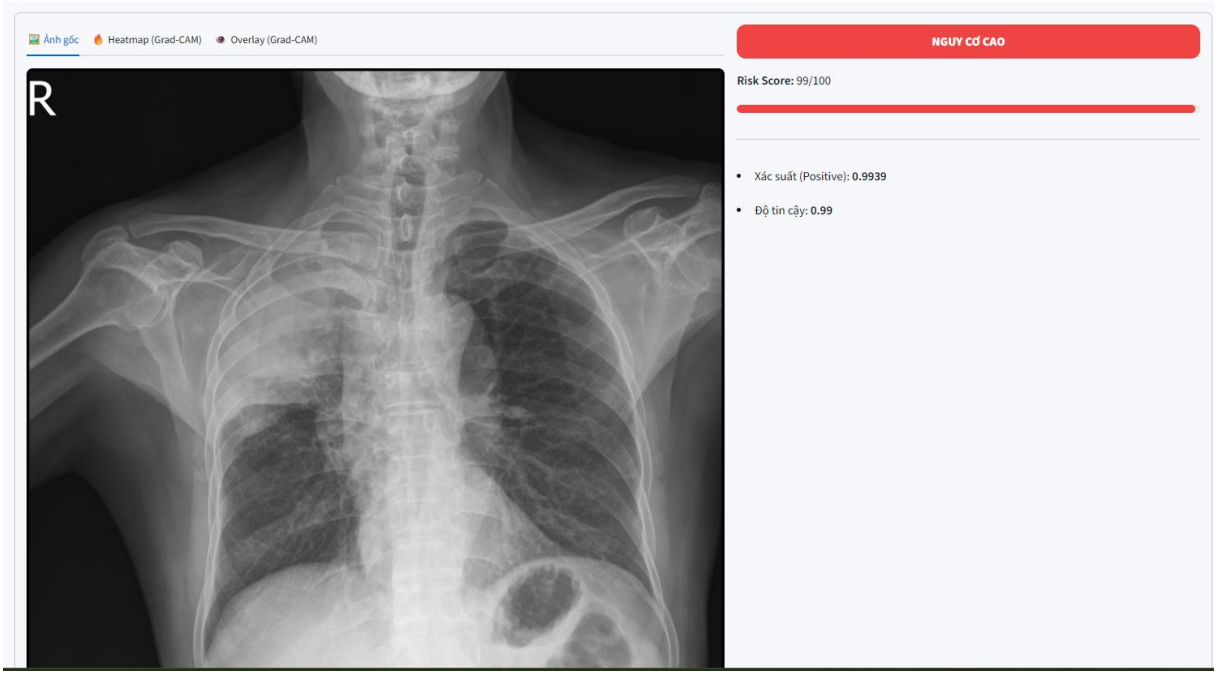
Hình 3. 10 Giao diện thao tác của chức năng Sàng lọc hàng loạt

Khi người dùng tải ảnh và xác nhận quyền sử dụng hợp pháp, hệ thống sẽ tiền xử lý ảnh, sau đó đưa ảnh vào mô hình DenseNet121 đã huấn luyện để kiểm tra và đưa ra kết quả.

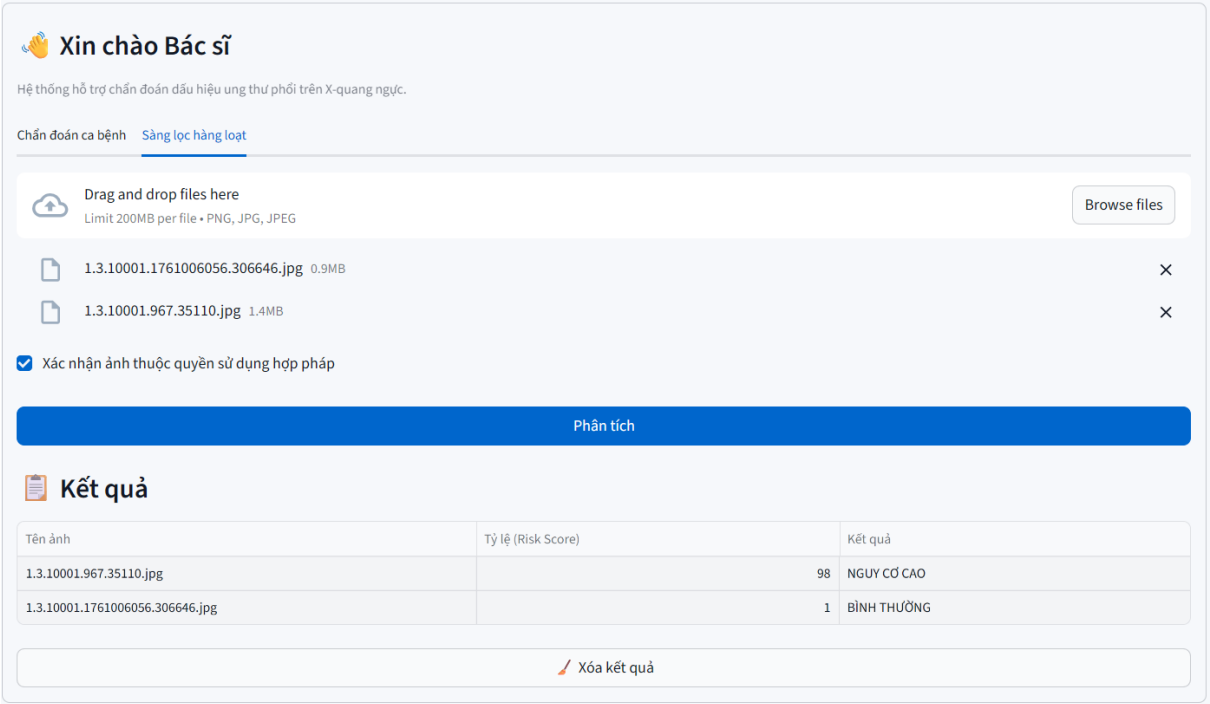
Đầu ra: Hệ thống hiển thị kết quả dưới dạng:

- Nhãn dự đoán: BÌNH THƯỜNG hoặc NGUY CƠ CAO
- Risk Score: điểm nguy cơ (0–100) và thanh biểu diễn mức nguy cơ.
- Xác suất dự đoán (Positive) và độ tin cậy.
- Hiển thị trực quan vùng chú ý của mô hình: gồm 2 tab Ảnh gốc và Overlay (Grad-CAM), giúp người dùng quan sát khu vực mà mô hình tập trung để đưa

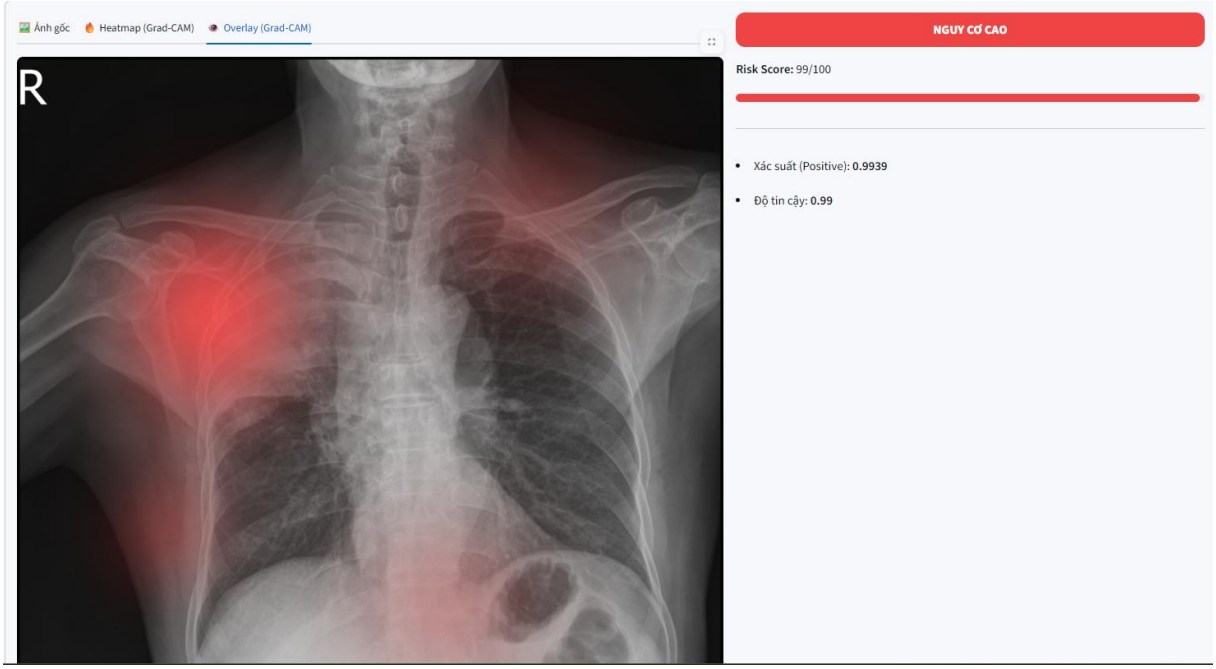
ra dự đoán.



Hình 3. 11 Giao diện kết quả phân tích của chức năng Chẩn đoán ca bệnh



Hình 3. 12 Giao diện kết quả phân tích của chức năng Sàng lọc hàng loạt



Hình 3. 13 Giao diện Vùng chú ý

Nhờ cơ chế này, người dùng không chỉ nhận được kết quả phân loại mà còn có thêm thông tin trực quan hỗ trợ giải thích quyết định của mô hình, từ đó tăng tính minh bạch khi sử dụng hệ thống trong bối cảnh hỗ trợ sàng lọc.

5. Phân hệ lịch sử (Trang lịch sử)

Phân hệ Lịch sử dùng để lưu lại các lần phân tích đã thực hiện trong phiên làm việc, giúp người dùng theo dõi và đối chiếu kết quả mà không cần tải lại ảnh từ đầu. Sau mỗi lần phân tích, hệ thống tự động ghi lại:

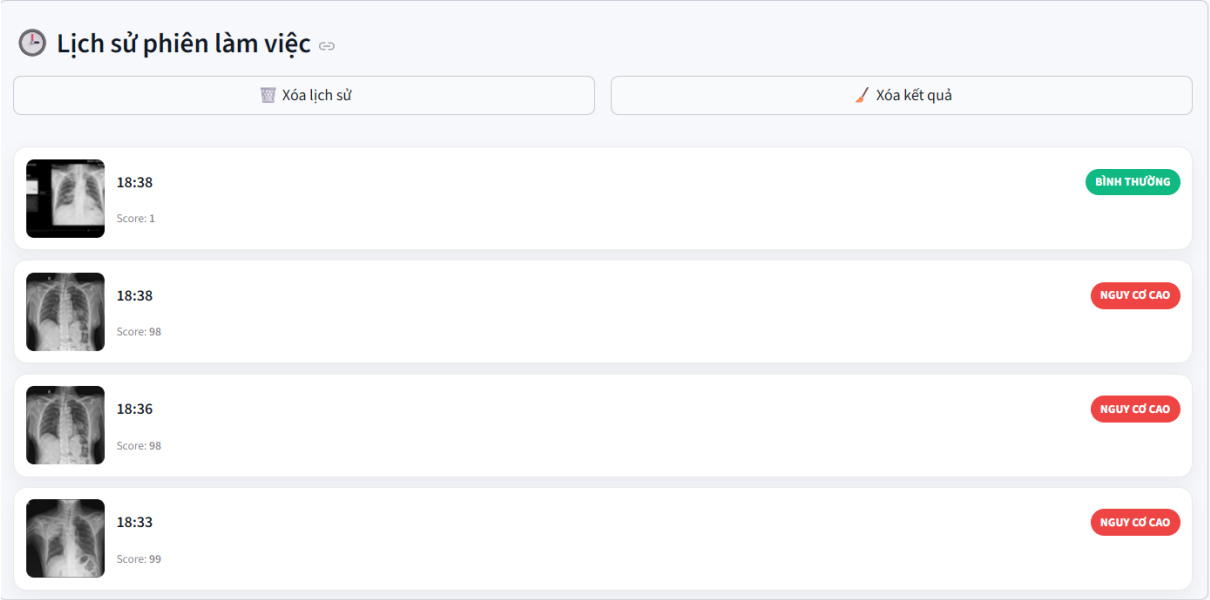
- Thời gian thực hiện (timestamp)
- Kết quả dự đoán (BÌNH THƯỜNG / NGUY CƠ CAO)
- Risk Score
- Ảnh thu nhỏ (thumbnail) của ảnh X-quang tương ứng

Lịch sử được trình bày dạng danh sách, mỗi mục gồm ảnh thu nhỏ và các thông tin tóm tắt (thời gian – kết quả – điểm nguy cơ), giúp người dùng xem nhanh nhiều trường hợp trên một màn hình. Ở trang lịch sử, người dùng còn có thể:

- Xóa lịch sử để làm mới phiên làm việc
- Xóa kết quả sàng lọc hàng loạt (nếu có) nhằm dọn dữ liệu bảng kết quả trước

khi chạy một lượt sàng lọc mới

Phân hệ này hỗ trợ việc quản lý luồng làm việc, đặc biệt hữu ích trong trường hợp cần xem lại nhiều ca phân tích liên tiếp hoặc đối chiếu kết quả sau khi sàng lọc nhiều ảnh.



Hình 3. 14 Giao diện chức năng xem Lịch sử

Phân hệ này hỗ trợ việc quản lý luồng làm việc, đặc biệt hữu ích trong trường hợp cần xem lại nhiều ca phân tích liên tiếp hoặc đối chiếu kết quả sau khi sàng lọc nhiều ảnh.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN CỦA ĐỀ TÀI

Kết quả đồ án tốt nghiệp

Trong đề tài này, chúng tôi đã xây dựng một hệ thống hỗ trợ phát hiện dấu hiệu ung thư trên ảnh X-quang ngực bằng phương pháp học sâu, với hai hướng tiếp cận chính: mô hình DenseNet121 cơ sở (Baseline) và mô hình DenseNet121 cải tiến tích hợp hàm mất mát có trọng số (Weighted Loss). Để tối ưu hóa khả năng nhận diện, chúng tôi đã áp dụng kỹ thuật tiền xử lý CLAHE (Contrast Limited Adaptive Histogram Equalization) nhằm tăng cường độ tương phản cục bộ, giúp làm nổi bật các đặc trưng bệnh lý thường bị mờ nhạt trên phim X-quang gốc.Mục tiêu trọng tâm của đề tài là giải quyết bài toán mất cân bằng dữ liệu nghiêm trọng (tỷ lệ 1:9) – một thách thức kinh điển trong chẩn đoán hình ảnh y tế, khi số lượng ca bệnh thực tế (lớp dương tính) thường ít hơn rất nhiều so với các ca bình thường.

Đầu tiên, chúng tôi triển khai mô hình DenseNet121 cơ sở (Baseline) sử dụng hàm mất mát Cross-Entropy tiêu chuẩn để thiết lập mốc tham chiếu hiệu năng. Kết quả thực nghiệm cho thấy mô hình này gặp hiện tượng 'thiên kiến lớp đa số' nghiêm trọng: dù đạt độ chính xác toàn cục (Accuracy) ở mức ổn định nhưng lại thất bại trong việc nhận diện các tổn thương ác tính, thể hiện qua chỉ số Recall cực thấp (dưới 50%) và tỷ lệ bỏ sót ca bệnh (False Negative) rất cao. Nhằm khắc phục hạn chế này, chúng tôi đề xuất quy trình cải tiến kết hợp giữa tiền xử lý và điều chỉnh thuật toán. Cụ thể, kỹ thuật CLAHE được áp dụng để tăng cường độ tương phản cho ảnh X-quang, giúp làm rõ các đặc trưng hình thái của nốt mờ. Đồng thời, hàm mất mát có trọng số (Weighted Loss) được tích hợp nhằm gia tăng 'hình phạt' đối với các lỗi dự đoán sai trên lớp bệnh.

Kết quả thực nghiệm trên tập kiểm thử độc lập cho thấy trên phương pháp cải tiến: khả năng phân tách đặc trưng (Separability) được nâng cao đáng kể, thể hiện qua việc nâng chỉ số AUC từ 0.7110 lên 0.7350 và tăng độ chính xác tổng thể lên 82.31%. Sự cải thiện đồng thời ở cả AUC và Accuracy chứng minh mô hình không chỉ học được nhiều đặc trưng bệnh lý hơn mà còn vận hành ổn định và tin cậy hơn so với mô hình gốc.

Hạn chế

Mặc dù đề tài đã đạt được những bước tiến tích cực trong việc cải thiện hiệu suất trong bài toán phân lớp ảnh có dấu hiệu ung thư phổi trên ảnh X-quang lồng ngực nhờ chiến lược Weighted Loss, tuy nhiên vẫn còn tồn tại một số hạn chế nhất định. Thứ nhất, mô hình hiện tại vẫn phải đối mặt với sự đánh đổi (trade-off) giữa Precision và Recall. Tại ngưỡng mặc định, để đảm bảo độ tin cậy cao, mô hình vẫn còn "thận trọng" dẫn đến chỉ số Recall chưa đạt mức tối ưu (khoảng 41%), đòi hỏi phải tinh chỉnh ngưỡng thủ công khi áp dụng thực tế. Thứ hai, mô hình mới chỉ dừng lại ở việc cảnh báo nguy cơ (Nguy cơ cao/Bình thường) dựa trên dấu hiệu Mass/Nodule chung, chưa phân loại chi tiết được các dạng bệnh lý phổi phức tạp khác. Thêm vào đó, việc đánh giá mô hình hoàn toàn dựa trên tập dữ liệu chuẩn hóa có sẵn, chưa có cơ hội kiểm nghiệm trên dữ liệu lâm sàng đa dạng và nhiễu hơn từ các bệnh viện tại Việt Nam.

Hướng phát triển

Trong hướng phát triển tương lai, chúng tôi mong muốn mở rộng mô hình theo hai phương diện chính. Một là về mặt dữ liệu và triển khai: sẽ tìm kiếm cơ hội hợp tác để thu thập dữ liệu X-quang thực tế tại các cơ sở y tế trong nước, từ đó đánh giá độ bền vững của mô hình (Robustness) trước các nhiễu động thực tế. Hai là về mặt kỹ thuật: có thể thử nghiệm các kiến trúc hiện đại hơn như Vision Transformer (ViT) hoặc áp dụng kỹ thuật sinh dữ liệu (GAN) – phương pháp mà đề tài hiện tại chưa khai thác – để giải quyết triệt để hơn nữa vấn đề thiếu hụt dữ liệu bệnh. Ngoài ra, việc tích hợp hệ thống vào một giao diện ứng dụng hỗ trợ chẩn đoán trực quan, có thể sử dụng trong môi trường bệnh viện, phòng khám và hỗ trợ nhiều định dạng ảnh hơn cũng là một bước tiến triển thực tiễn mà đề tài hướng đến.

TÀI LIỆU THAM KHẢO

[1] International Agency for Research on Cancer, “Latest global cancer data: Cancer burden rises to 18.1 million new cancer cases worldwide,” *GLOBOCAN 2018*, Global Cancer Observatory, 2018.

[2] M. A. Sufian, W. Hamzi, T. Sharifi, S. Zaman, L. Alsadder, E. Lee, A. Hakim, and B. Hamzi, “AI-Driven Thoracic X-ray Diagnostics: Transformative Transfer Learning for Clinical Validation in Pulmonary Radiography,” *Journal of Personalized Medicine.*

[3] A. P. R. Wismadi, A. H. U. Hayu, and M. L. Q. Hidayat, "Early Detection of Diabetes Using Machine Learning with Logistic Regression Algorithm," in *IOP Conference Series: Materials Science and Engineering*, 2021.

[4] “Early-Stage Lung Cancer Survival Rate: Know The Facts,” CareYourLungs, 2023

[5] S. Inc, "Streamlit Documentation," 2025.

PHỤ LỤC

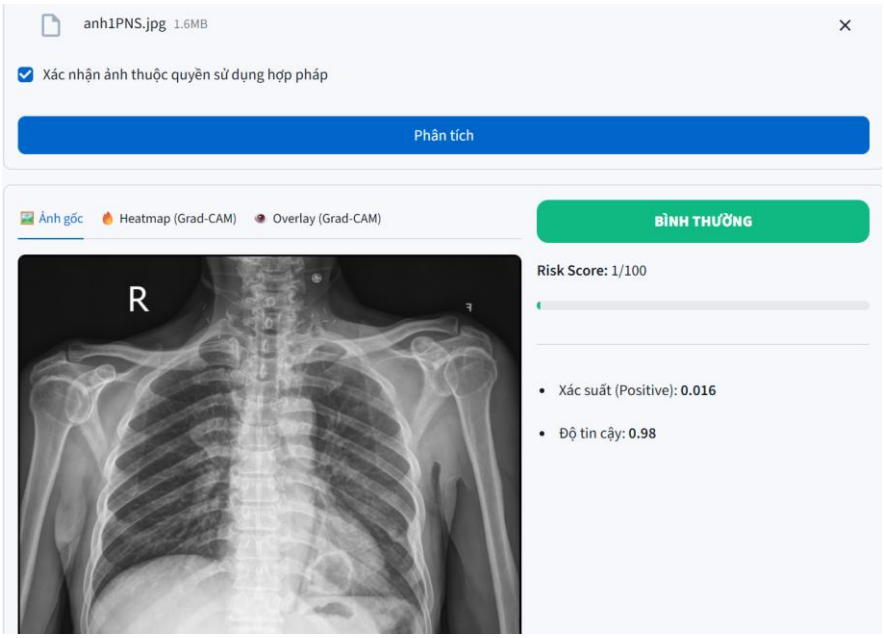
1. Kết quả dự đoán của mô hình trên ảnh X-quang lồng ngực thực tế

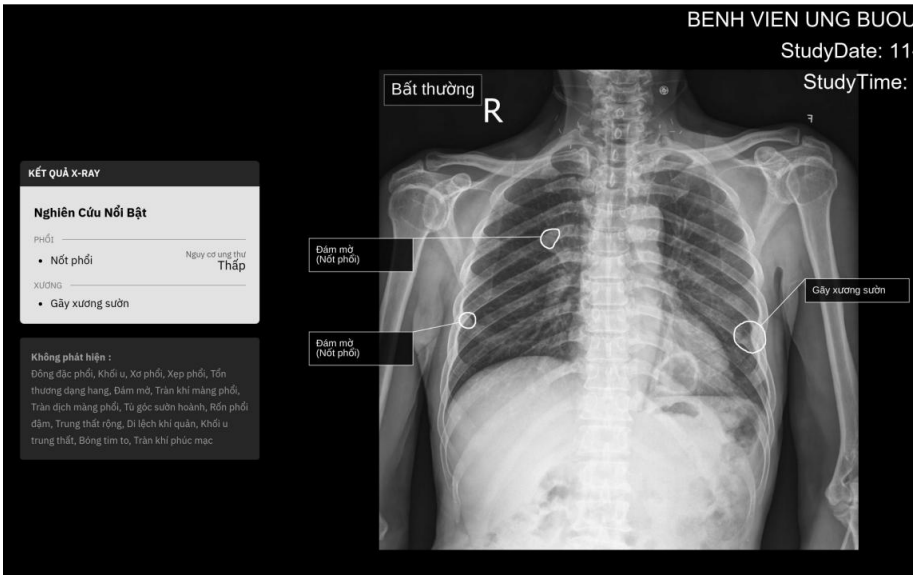
Các dữ liệu ảnh X-quang ngực thực tế dưới đây được thu thập từ Bệnh viện Ung bướu Hà Nội và là ảnh chụp của bệnh nhân Việt Nam. Tập ảnh này không được sử dụng trong quá trình huấn luyện hay kiểm định mô hình. Mục đích của phần này là minh họa khả năng dự đoán của mô hình trong điều kiện thực tế. Tập dữ liệu gồm tổng cộng 12 ảnh, trong đó có 7 ảnh được gán nhãn có dấu hiệu bất thường và 5 ảnh được gán nhãn không có dấu hiệu bất thường. Kết quả dự đoán cho thấy, đối với 7 ảnh có dấu hiệu, mô hình dự đoán đúng 6 ảnh và dự đoán sai 1 ảnh. Ngược lại, trong 5 ảnh không có dấu hiệu, mô hình chỉ dự đoán đúng 1 ảnh và dự đoán sai 4 ảnh, với xu hướng dự đoán nhầm từ không có dấu hiệu sang có dấu hiệu.

Hiện tượng này có thể được lý giải bởi việc mô hình được huấn luyện trên tập dữ liệu có sự mất cân bằng giữa các lớp, trong đó các mẫu có dấu hiệu chiếm tỷ lệ thấp hơn. Do đó, mô hình có xu hướng ưu tiên độ nhạy (Recall) đối với lớp có dấu hiệu, dẫn đến việc giảm độ đặc hiệu và làm tăng số trường hợp dương tính giả trong các ảnh không có dấu hiệu. Tuy nhiên, kết quả này chỉ mang tính minh họa cho khả năng ứng dụng thực tế của mô hình và không được sử dụng để đánh giá hiệu năng mô hình.

1.1. Kết quả dự đoán của mô hình trên tập ảnh có dấu hiệu ung thư phổi

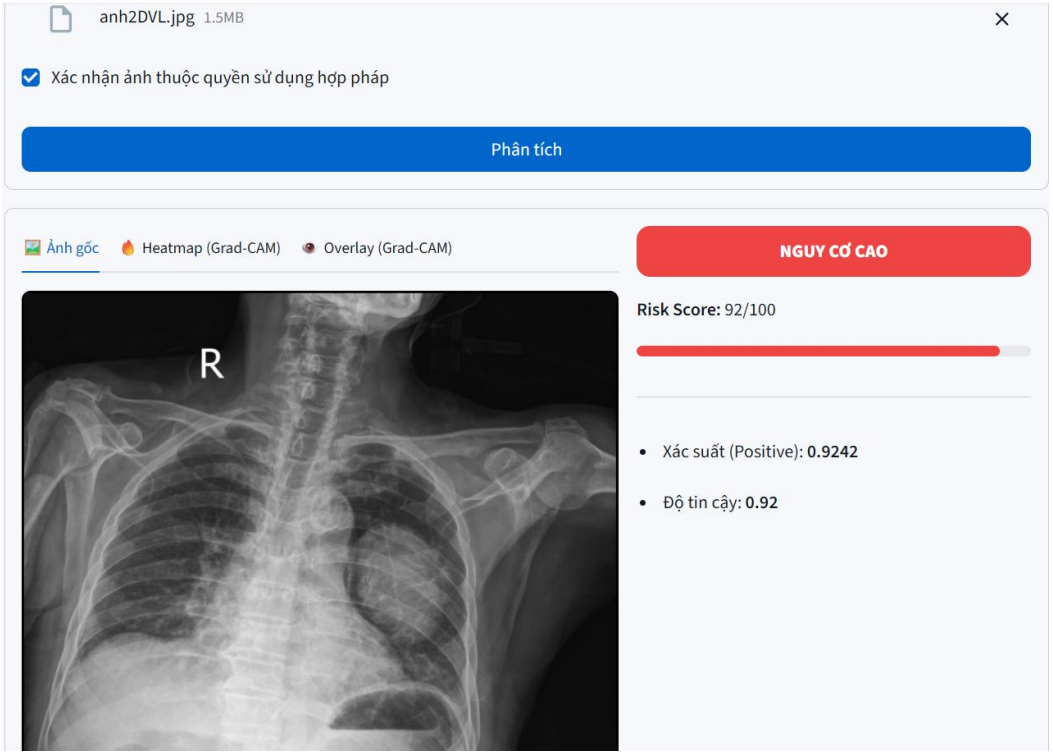
Trường hợp 1:

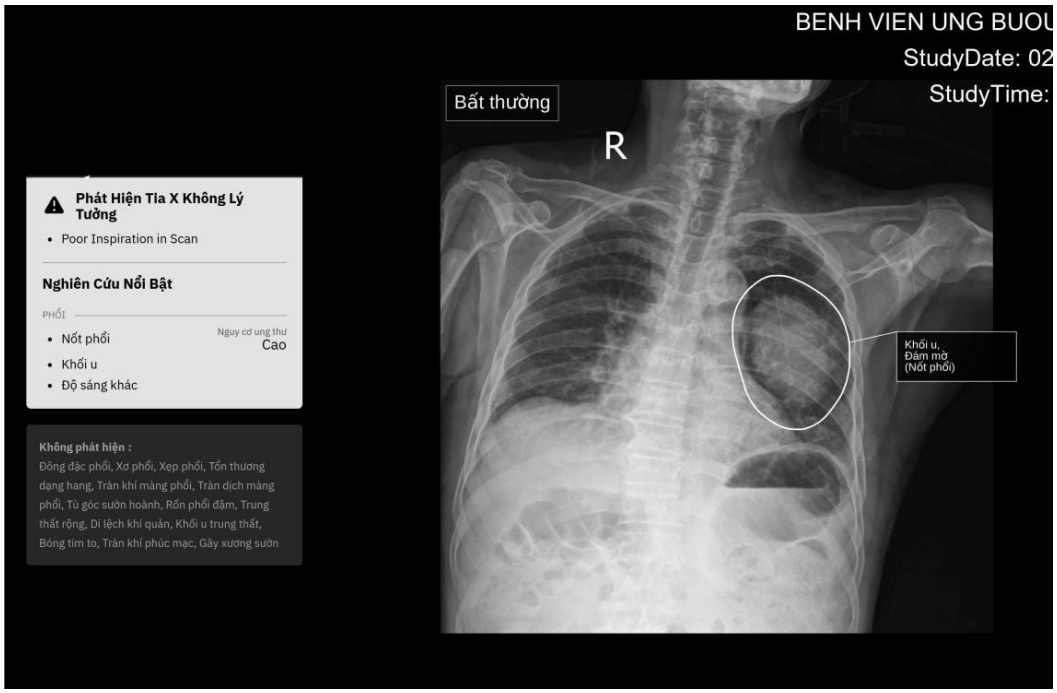




Kết quả dự đoán của mô hình cho thấy ảnh **không có dấu hiệu ung thư phổi**. Tuy nhiên, theo nhận định của bác sĩ, ảnh có **biểu hiện bất thường liên quan đến ung thư phổi ở mức nguy cơ thấp**. Sự khác biệt này cho thấy mô hình có xu hướng thận trọng trong việc phân loại các trường hợp có biểu hiện bất thường nhẹ.

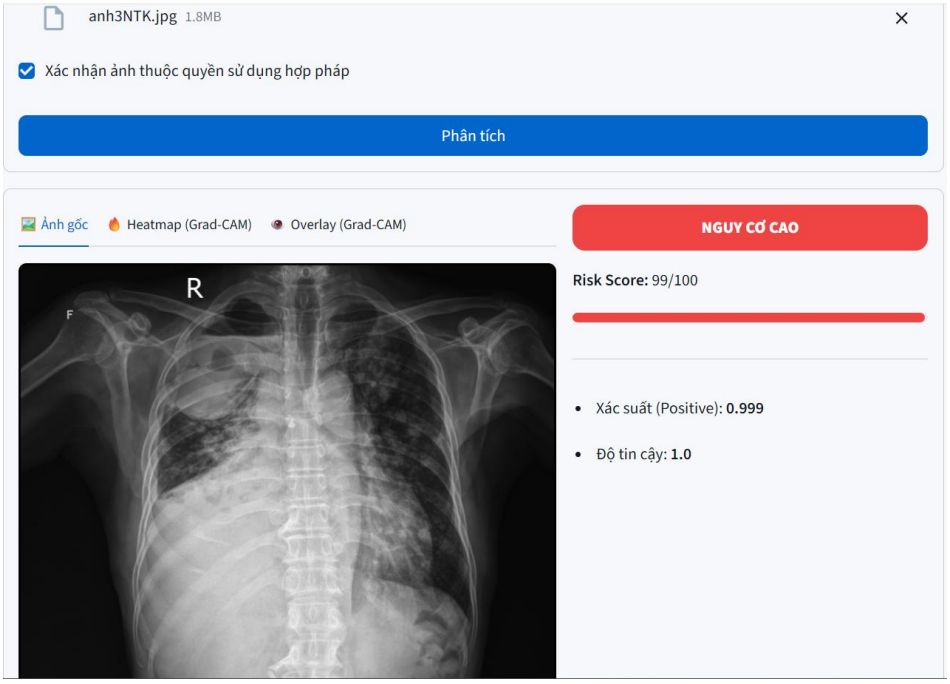
Trường hợp 2:

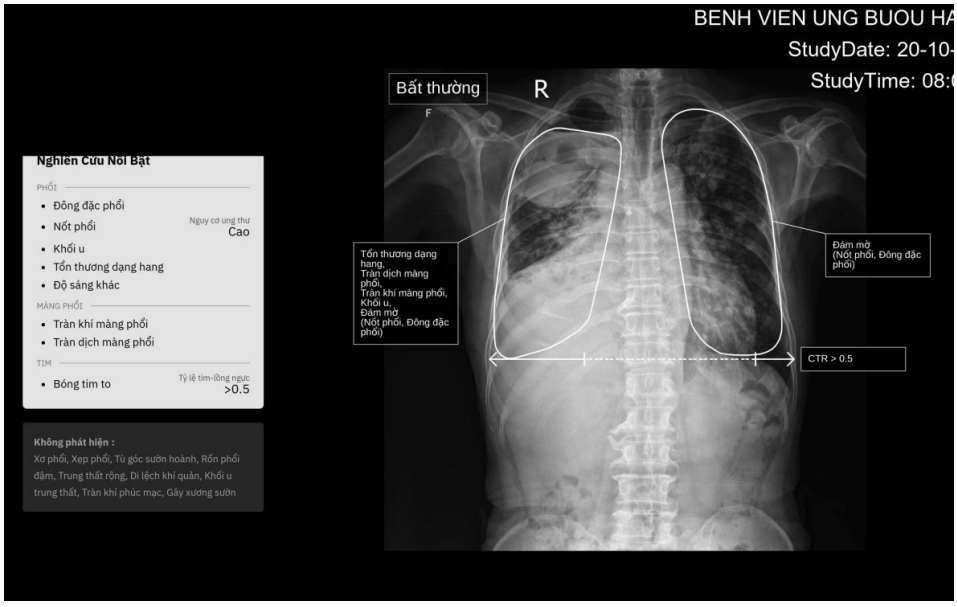




Ở trường hợp 2, mô hình và bác sĩ đều đánh giá ảnh có dấu hiệu ung thư phổi, với mức nguy cơ được mô hình dự đoán là cao.

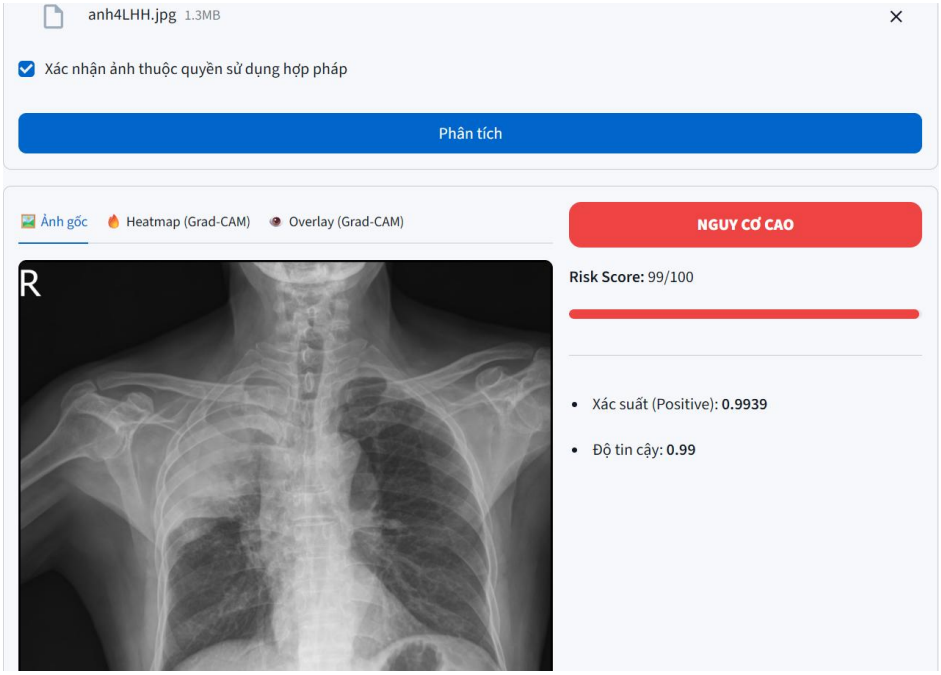
Trường hợp 3:

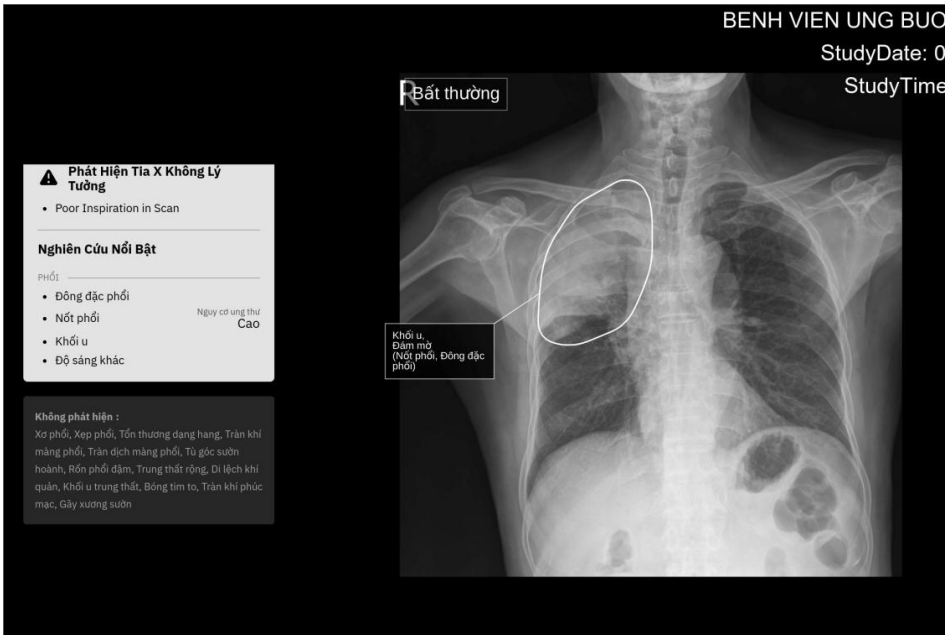




Ở trường hợp 3, mô hình và bác sĩ cũng đều đánh giá ảnh có dấu hiệu ung thư phổi, với mức nguy cơ được mô hình dự đoán là cao.

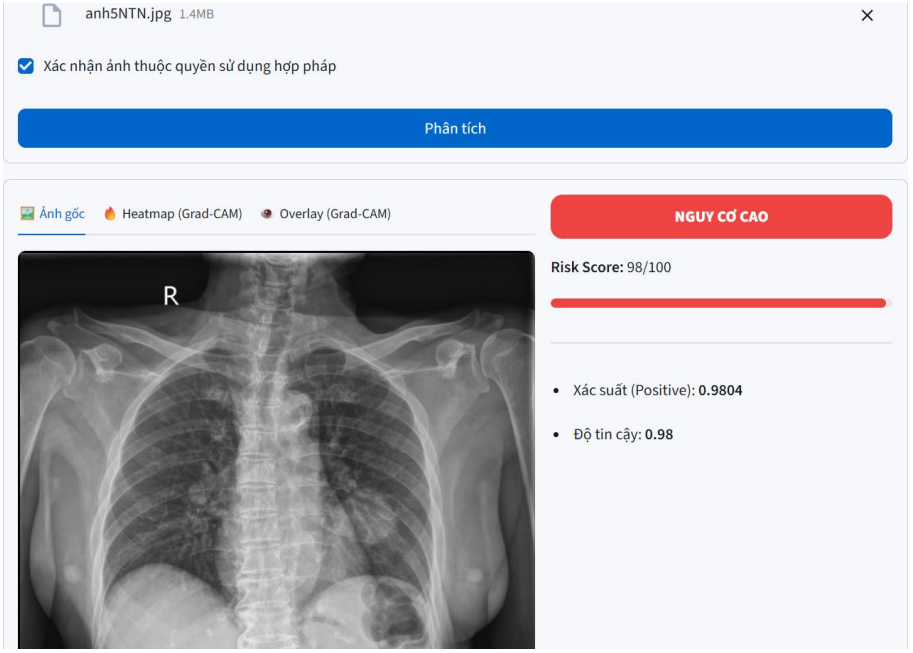
Trường hợp 4:

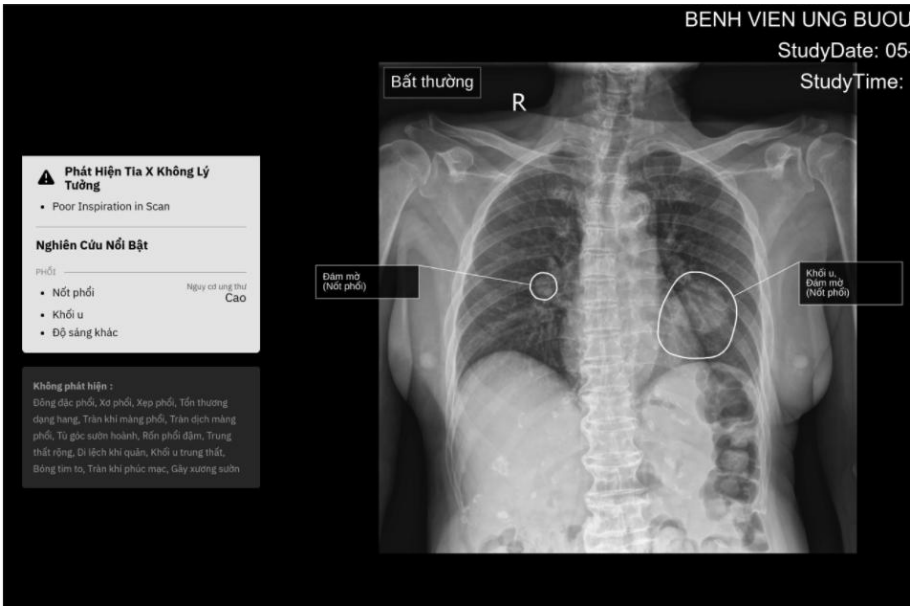




Trong trường hợp thứ tư, kết quả dự đoán của mô hình phù hợp với đánh giá của bác sĩ khi cả hai đều nhận định ảnh có dấu hiệu ung thư phổi, với mức nguy cơ được mô hình xác định là cao.

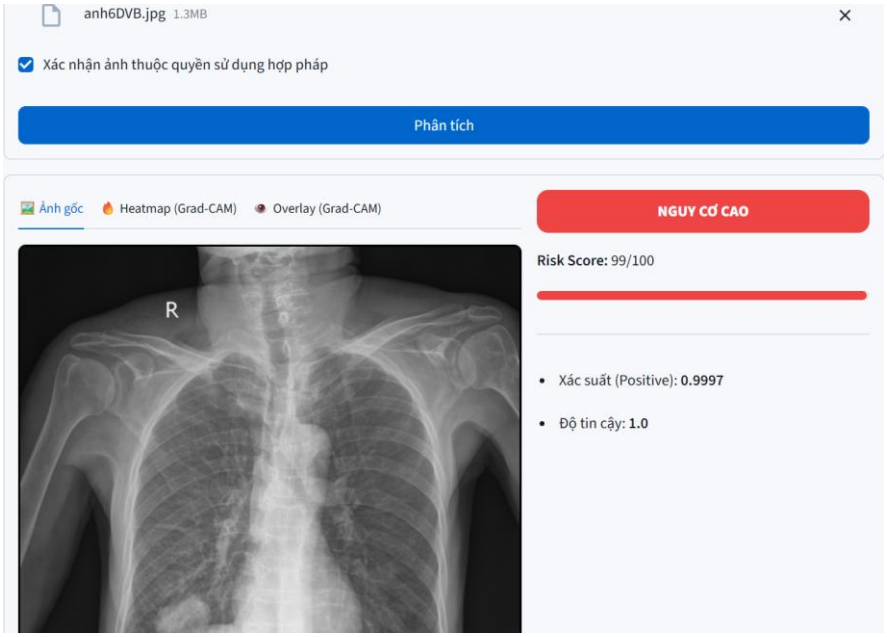
Trường hợp 5:

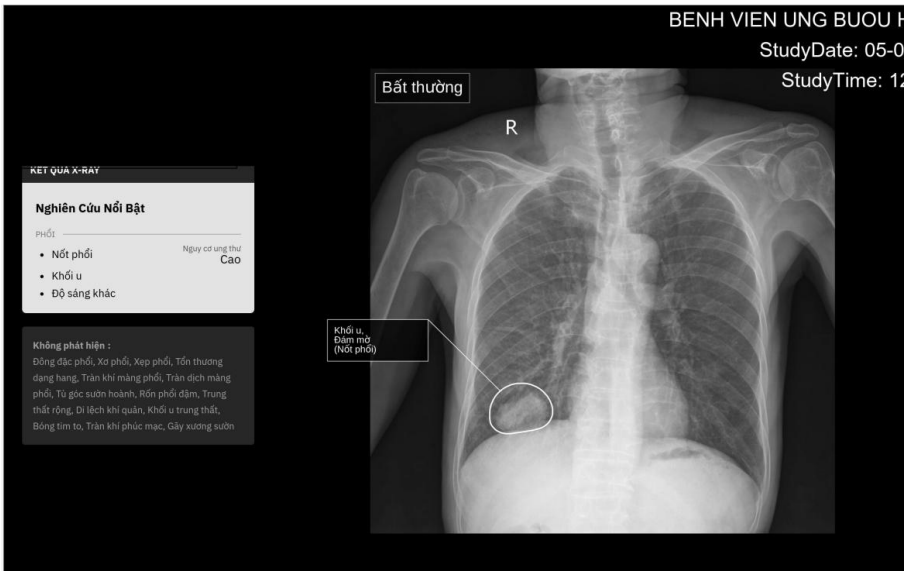




Trường hợp thứ năm cho thấy sự tương đồng giữa dự đoán của mô hình và đánh giá lâm sàng của bác sĩ, khi cả hai đều xác định ảnh có dấu hiệu ung thư phổi và mô hình đưa ra mức nguy cơ cao.

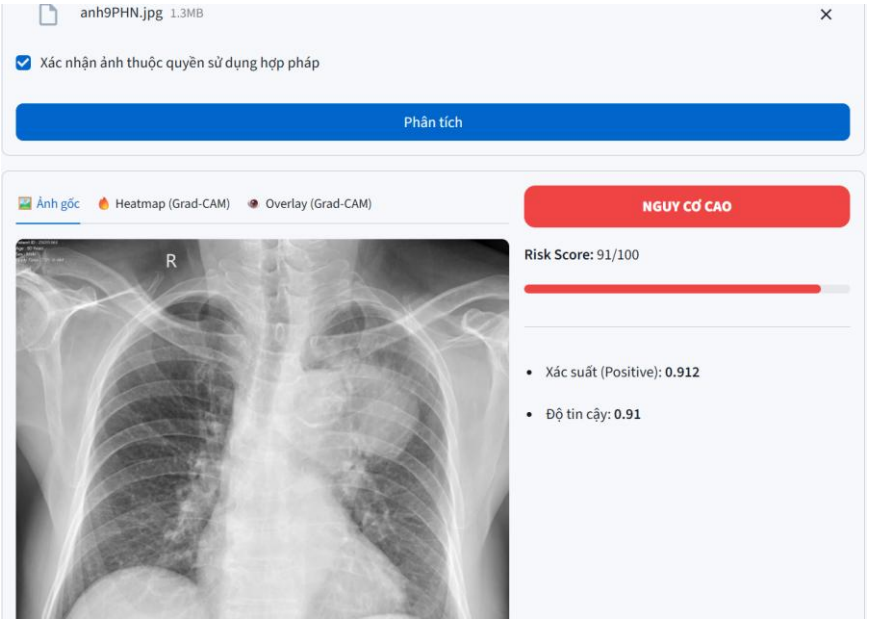
Trường hợp 6:

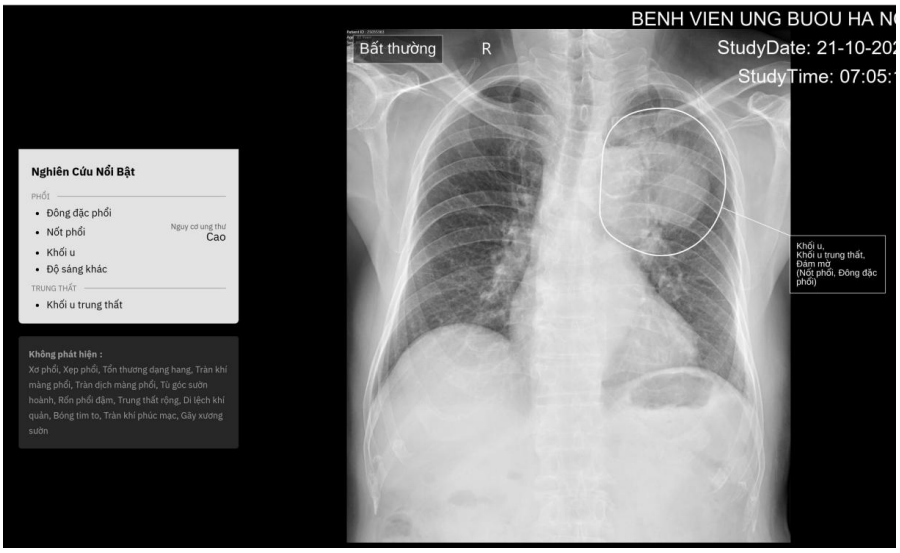




Trong trường hợp thứ sáu, mô hình đưa ra dự đoán nguy cơ cao và nhận định này phù hợp với đánh giá của bác sĩ về việc ảnh có dấu hiệu ung thư phổi.

Trường hợp 7:

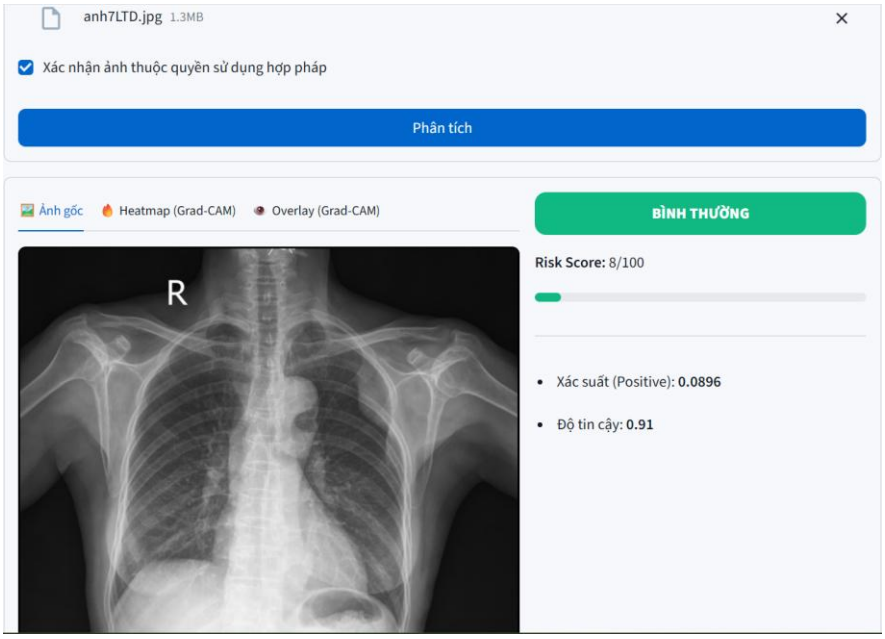


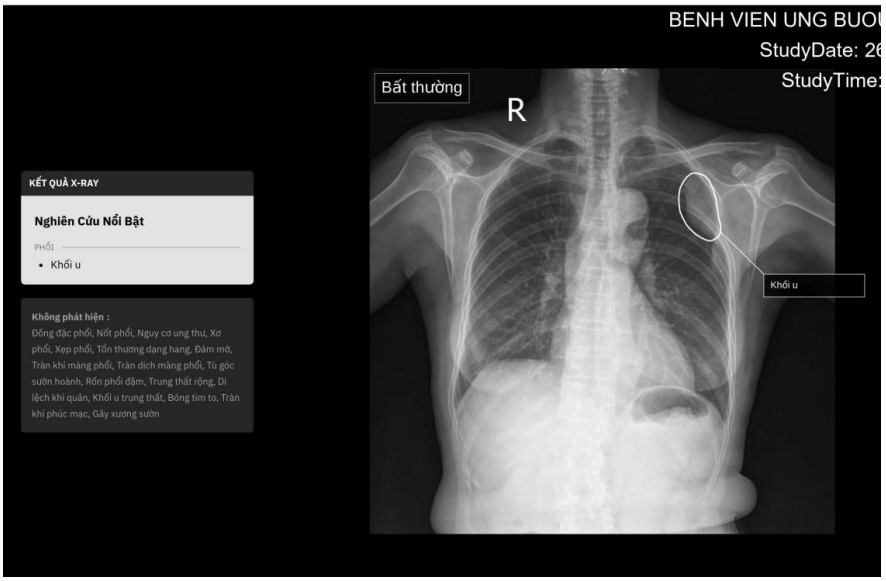


Kết quả dự đoán của mô hình ở trường hợp này cho thấy sự nhất quán với đánh giá của bác sĩ, khi cả hai đều xác định ảnh có dấu hiệu ung thư phổi và ở mức nguy cơ cao.

1.2. **Kết quả dự đoán của mô hình trên tập ảnh không có dấu hiệu ung thư phổi**

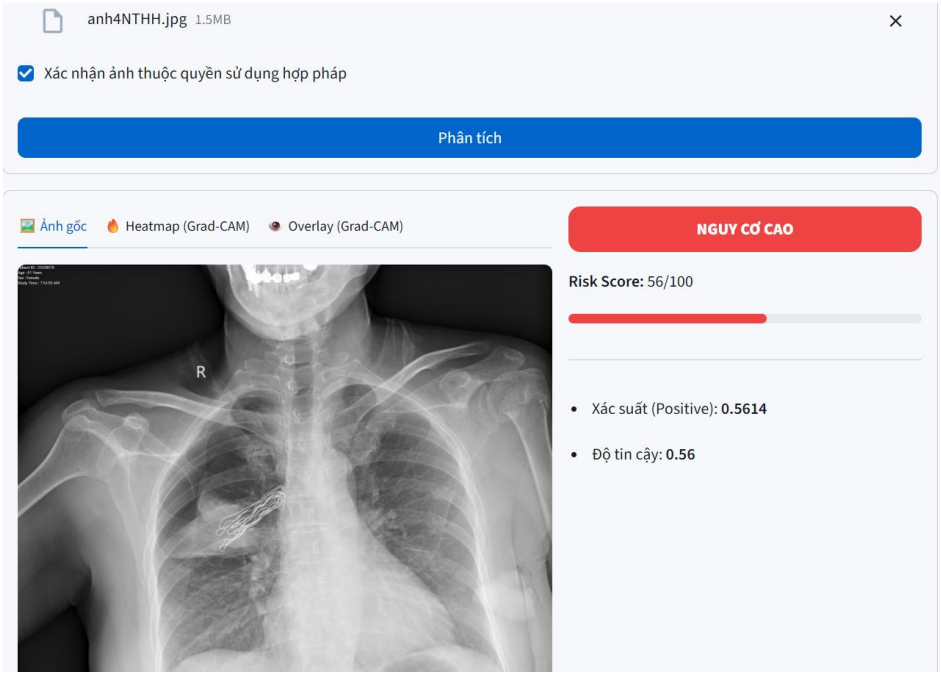
Trường hợp 1:

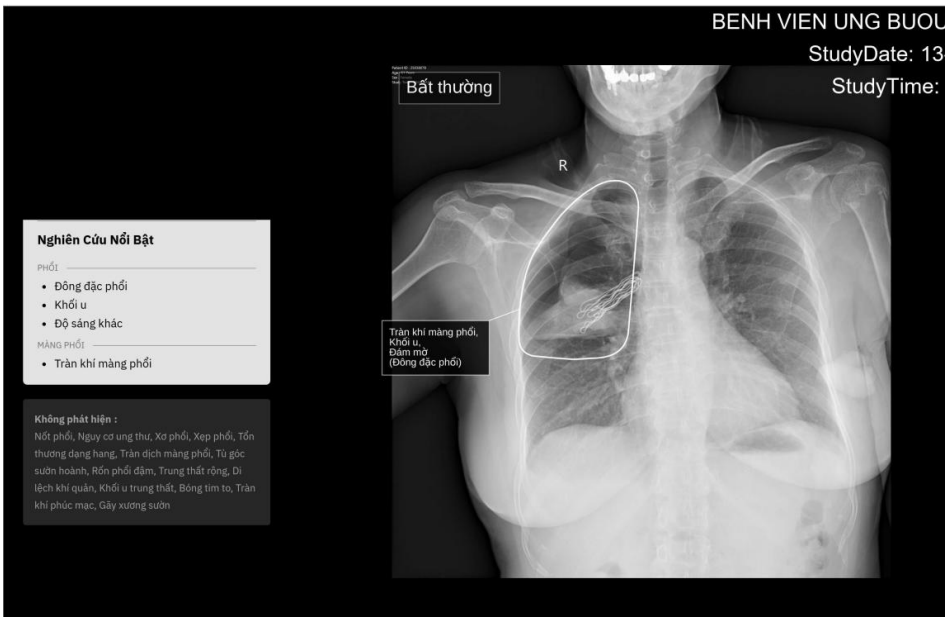




Kết quả dự đoán của mô hình ở trường hợp này cho thấy sự nhất quán với đánh giá của bác sĩ, khi cả hai đều xác định ảnh có không dấu hiệu ung thư phổi.

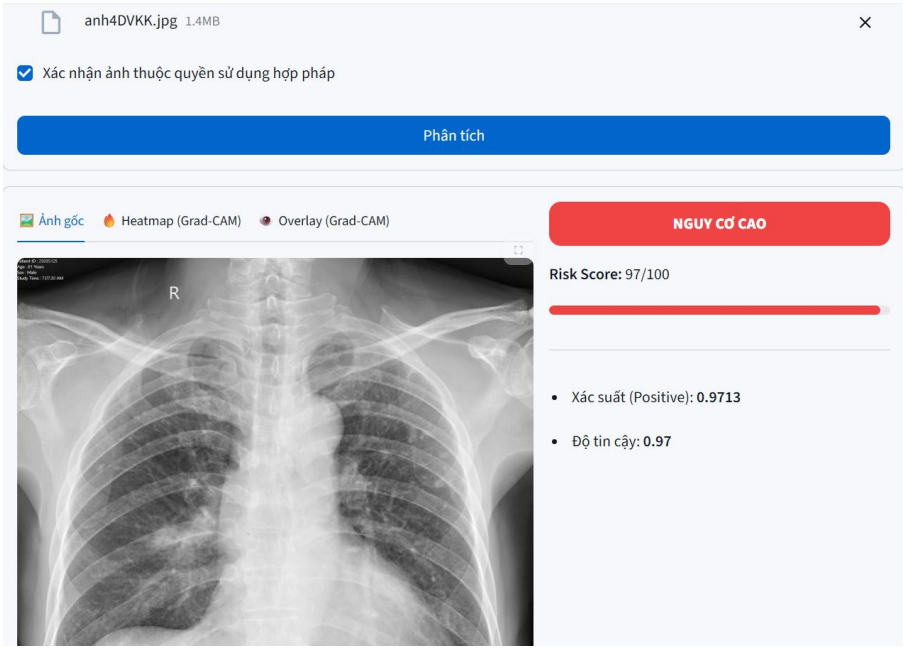
Trường hợp 2:

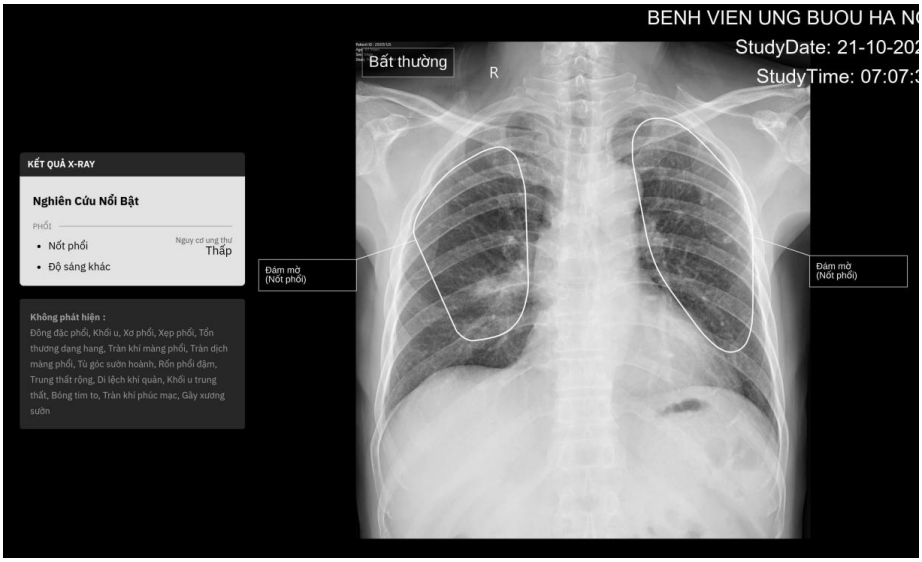




Ảnh X-quang trong trường hợp này được bác sĩ đánh giá là bình thường, trong khi mô hình lại đưa ra cảnh báo nguy cơ.

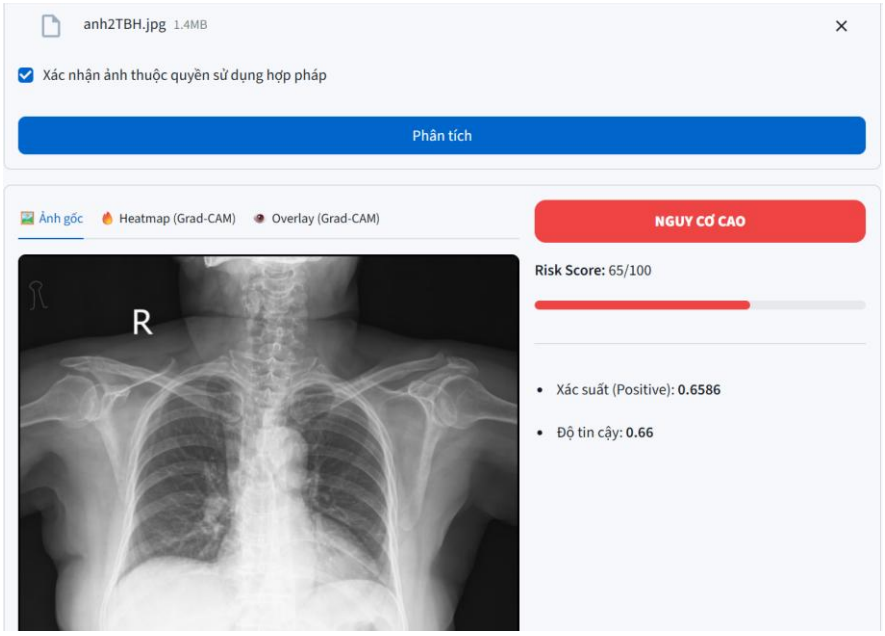
Trường hợp 3:

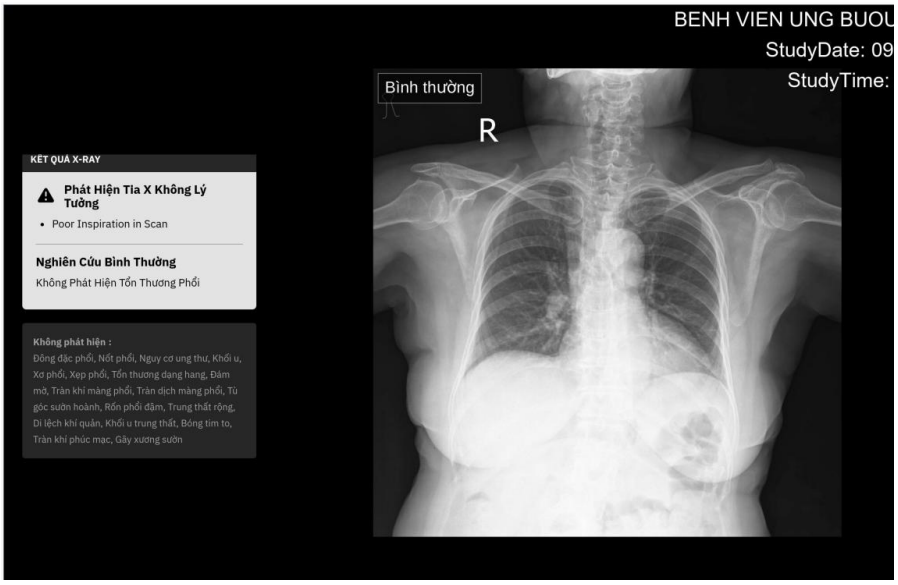




Ở trường hợp này, bác sĩ đánh giá có nguy cơ thấp tuy nhiên mô hình vẫn thận trọng và đưa vào trường hợp nguy cơ cao. Trường hợp này minh họa xu hướng thận trọng của mô hình trong việc phát hiện các dấu hiệu tiềm ẩn, đồng thời cho thấy thách thức trong việc phân biệt các ảnh không có biểu hiện bất thường rõ ràng.

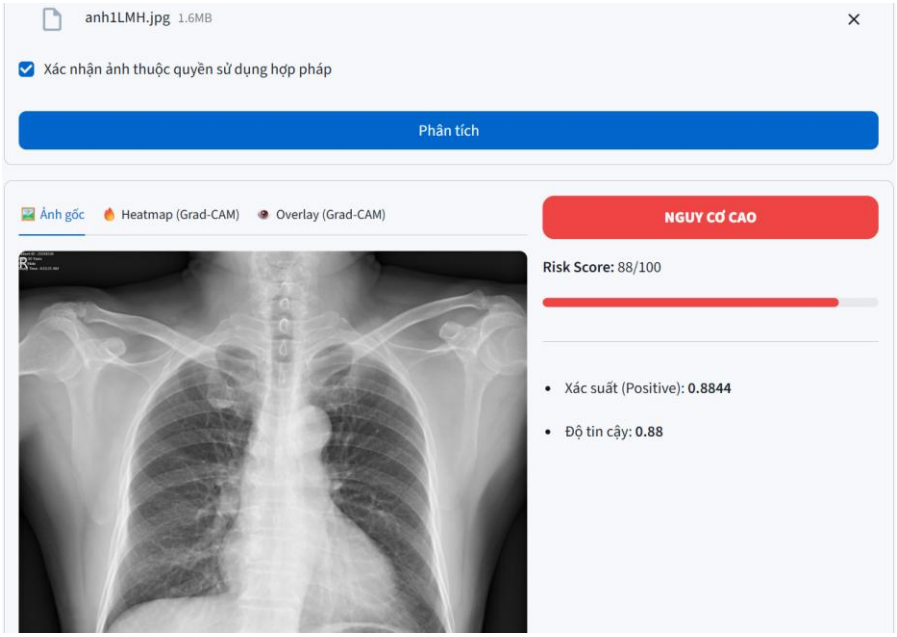
Trường hợp 4:





Trong trường hợp này, kết quả dự đoán của mô hình và đánh giá của bác sĩ có sự khác biệt, khi ảnh được đánh giá là không có dấu hiệu bất thường nhưng mô hình dự đoán có nguy cơ ung thư phổi.

Trường hợp 5:





Trường hợp này cho thấy mô hình có xu hướng dự đoán thận trọng, khi ảnh được bác sĩ đánh giá là bình thường nhưng mô hình lại xác định nguy cơ ung thư phổi ở mức cao.

2. Xây dựng mô hình phân lớp ảnh dựa trên Densenet121 cơ bản

2.1. Xây dựng và huấn luyện mô hình

Mô hình phân lớp ảnh dựa trên kiến trúc DenseNet121 cơ sở (Densely Connected Convolutional Networks), triển khai thông qua thư viện PyTorch. Mục tiêu chính của mô hình là thiết lập một mốc tham chiếu hiệu năng (Baseline) bằng cách học cách trích xuất các đặc trưng phân cấp từ ảnh X-quang phổi mà không áp dụng các kỹ thuật xử lý mất cân bằng chuyên sâu.

1. Kiến trúc mạng xương sống và khối trích xuất đặc trưng:

Quá trình xây dựng bắt đầu với việc sử dụng mạng DenseNet121 đã được huấn luyện trước (pre-trained) trên tập dữ liệu ImageNet. Kiến trúc này đặc trưng bởi các "Dense Blocks", nơi mỗi lớp nhận đầu vào là bản đồ đặc trưng từ tất cả các lớp trước đó, giúp tối ưu hóa việc truyền tải tín hiệu và giảm thiểu hiện tượng triệt tiêu đạo hàm. Dữ liệu đầu vào là các hình ảnh X-quang đã được chuẩn hóa về kích thước 224x224 pixel với 3 kênh màu. Khối trích xuất đặc trưng bao gồm:

- Lớp tích chập đầu tiên: Sử dụng kernel kích thước 7x7 với bước nhảy (stride) là 2 để giảm chiều dữ liệu ngay từ đầu.
- Các khối Dense Blocks (1, 2, 3, 4): Bao gồm các chuỗi lớp tích chập 1x1 và 3x3 xếp chồng, xen kẽ với các lớp "Transition Layers" (tích chập 1x1 và Average Pooling 2x2) để kiểm soát số lượng kênh và kích thước bản đồ đặc trưng. Việc sử dụng 121 lớp sâu cho phép mô hình học được những chi tiết bệnh lý trừu tượng như cấu trúc nốt mờ hoặc khối u phổi.

2. Khối phân loại và hàm kích hoạt:

Sau khi đi qua lớp Global Average Pooling để làm phẳng các đặc trưng bậc cao thành một vector 1024 chiều, dữ liệu được đưa vào khối phân loại cuối cùng:

- Lớp kết nối đầy đủ (Linear Layer): Được thiết kế lại với 1024 đơn vị đầu vào và 1 đơn vị đầu ra duy nhất cho bài toán phân loại nhị phân.
- Hàm kích hoạt Sigmoid: Được áp dụng tại đầu ra để đưa về giá trị xác suất trong khoảng [0, 1], phù hợp để phân loại giữa hai trạng thái "Lành tính" (0) và "Ác tính" (1).

3. Thiết lập tham số và huấn luyện mô hình:

Mô hình sau khi thiết kế được cấu hình với thuật toán tối ưu hóa Adam và tốc độ học (learning rate) khởi tạo là $1\ x\ 10^{-4}$. Hàm mất mát được lựa chọn là Binary Cross-Entropy (BCE) Loss tiêu chuẩn. Khác với mô hình cải tiến, phiên bản cơ sở này không áp dụng trọng số Loss (unweighted), nghĩa là mọi sai số trên lớp lành tính và ác tính đều được tính toán với vai trò ngang nhau.

4. Quy trình huấn luyện và Kiểm định:

Quá trình huấn luyện được thực hiện theo chiến lược 5-Fold Cross-Validation để đảm bảo tính tổng quát hóa. Trong mỗi Fold, mô hình thực hiện tối đa 20 epoch huấn luyện:

- **Cơ chế huấn luyện:** Dữ liệu được cung cấp theo từng lô (batch size = 32). Sau mỗi epoch, mô hình được đánh giá ngay lập tức trên tập kiểm định (Validation Set) để theo dõi chỉ số **Validation AUC**.
- **Kết quả ghi nhận:** Lịch sử huấn luyện cho thấy hàm mất mát (Loss) giảm dần từ mức 0.45 và hội tụ về quanh ngưỡng 0.15. Tuy nhiên, do không có cơ chế xử lý mất cân bằng, mô hình cho thấy xu hướng thiên kiến rõ rệt, dẫn đến việc phải sử dụng ngưỡng cắt rất thấp là **0.1569** tại giai đoạn kiểm thử cuối cùng để có thể nhận diện được các ca bệnh.

2.2. Kết quả của mô hình

Lớp	Precision	Recall	F1-Score	Support
Benign (Lành tính)	0.9341	0.9341	0.8553	5,833
Malignant (Ác tính)	0.2076	0.4992	0.2934	647
Accuracy			0.7599	6,480
Macro avg	0.5709	0.6440	0.5744	6,480
Weighted avg	0.8616	0.7599	0.7992	6,480

Bảng 1 Bảng kết quả mô hình Densenet121 thuần

Chỉ số AUC tổng hợp:

- ROC-AUC Score: 0.7110
- Precision-Recall AUC (AP): 0.2610

Mô hình DenseNet121 cơ sở được triển khai nhằm thiết lập một chuẩn tham chiếu ban đầu (baseline) cho bài toán phân loại hình ảnh X-quang ngực. Sau khi huấn luyện trên tập dữ liệu gốc có sự mất cân bằng nghiêm trọng (tỷ lệ Lành tính : Ác tính xấp xỉ 9:1), mô hình đạt độ chính xác tổng thể là 75.99%. Tuy nhiên, kết quả thực nghiệm cho thấy sự hạn chế rõ rệt của mô hình cơ sở trong việc nhận diện lớp thiểu số (Ác tính). Cụ thể, dù đã chấp nhận hạ ngưỡng quyết định xuống mức rất thấp (0.1569) để ưu tiên khả năng bắt bệnh, chỉ số Recall cũng chỉ đạt 0.4992 và F1-score của lớp ác tính thấp ở mức 0.2934. Điều này phản ánh xu hướng thiên kiến mạnh mẽ về phía lớp đa số của mạng nơ-ron khi không có cơ chế xử lý mất cân bằng, dẫn đến việc bỏ sót 324 ca bệnh và đồng thời gây ra 1,232 ca báo động giả. Biểu đồ ROC ghi nhận mức AUC khiêm tốn là 0.711, khẳng định tính cần thiết của việc áp dụng các kỹ thuật cải tiến như tiền xử lý CLAHE và hàm mất mát có trọng số (Weighted Loss) để tối ưu hóa khả năng trích xuất đặc trưng bệnh lý trong các kịch bản thực tế.